


PLÁN [OBNOVY]



Financované
Európskou úniou
NextGenerationEU



ŽILINSKÁ UNIVERZITA V ŽILINE
Výskumné centrum
UNIZA



Financované
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD VLÁDY
SLOVENSKEJ REPUBLIKY



MINISTERSTVO
ŠKOLSTVA, VÝSKUMU,
VÝVOJA A MLÁDEŽE
SLOVENSKEJ REPUBLIKY



VÝSKUMNÁ
AGENTÚRA

A Statistical Approach to Monitor Quantisation in Neural Network Training

Principal investigator: Ing. Roman Budjac, PhD.

Rast komplexnosti modelov

- Neurónové siete dosahujú presvedčivé výsledky, ale ich veľkosť rastie exponenciálne
- Modely ako GPT-3 majú 175 miliárd parametrov
- Znemožňuje nasadenie na edge zariadeniach

Energetická náročnosť

- Trénovanie veľkých modelov vyžaduje enormné množstvo energie
- Jeden tréning GPT-3 spotreboval energiu ekvivalentnú spotrebe 126 domácností za rok

Súčasný výzvy v priemysle

- Potreba efektívnych riešení a inovácií
- Priemysel potrebuje efektívne metódy kompresie bez významnej straty presnosti
- Existujúce kompresné techniky (pruning, kvantizácia) sú často ad-hoc
- Chýba systematický prístup k monitorovaniu kvality
- Chýba metodológia na hodnotenie vplyvu kompresie na funkčnosť modelu bez systematického prístupu

Súčasnú výzvy v priemysle

- WP1: Analýza a testovanie vhodných štatistických metód (M1-M6)
- WP2: Implementácia štatistických metód do kvantizačného procesu (M7-M12)
- WP3: Vývoj novej trénovacej stratégie (M13-M17)
- WP4: Overenie konceptu a publikovanie výsledkov (M18-M24)

Harmonogram a míľniky projektu:

M1 (6. mesiac): Analýza štatistických metód

M2 (12. mesiac): Implementácia do tréningového procesu

M3 (18. mesiac): Nová tréningová stratégia

M4 (20. mesiac): Overenie konceptu

Plánované výstupy projektu

Publikácie

- 1x Publikácia v Q2 časopise (SCOPUS/WOS)
- 2x Konferenčné príspevky (SCOPUS)
- **Ostatné výstupy**
- 4x Semináre
- 1x Priebežná správa
- 2x Zdrojový kód
- 1x Záverečná správa

Dostupné zdroje a infraštruktúra

Potvrdené zdroje

- Pracovná stanica s výkonným grafickým procesorom
- Administratívna podpora od Výskumného centra Žilinskej Univerzity

Zabezpečenie hostiteľskej organizácie:

- Prístup k výkonnému hardvéru
- Administratívna podpora

- **Riziko 1:** Nedostatočné hardvérové vybavenie
Pravdepodobnosť: stredná, Závažnosť: stredná
Opatrenie: Hostiteľská organizácia zabezpečí prístup k vysokovýkonnému GPU
- **Riziko 2:** Štatistické metódy nebudú vhodné na porovnanie váh
Pravdepodobnosť: nízka, Závažnosť: stredná
Opatrenie: Využitie niekoľkých alternatívnych metód, priebežná modifikácia metodiky
- **Riziko 3:** Neočakávané výsledky štatistických metód
Pravdepodobnosť: nízka až stredná, Závažnosť: stredná
Opatrenie: Iteratívny prístup, priebežné vyhodnocovanie účinnosti metód

Identifikované riziká projektu

Riziko 1: Nedostatočné hardvérové vybavenie

Pravdepodobnosť: stredná, Závažnosť: stredná

Opatrenie: Hostiteľská organizácia zabezpečí prístup k vysokovýkonnému GPU

Riziko 2: Štatistické metódy nebudú vhodné na porovnanie váh

Pravdepodobnosť: nízka, Závažnosť: stredná

Opatrenie: Využitie niekoľkých alternatívnych metód, priebežná modifikácia metodiky

Riziko 3: Neočakávané výsledky štatistických metód

Pravdepodobnosť: nízka až stredná, Závažnosť: stredná

Opatrenie: Iteratívny prístup, priebežné vyhodnocovanie účinnosti metód

• **Najbližšie aktivity**

- Vytvorenie GitHub repozitára projektu
- Príprava analýzy súčasného stavu problematiky a analýz štatistických metód
- Naplánovanie ďalšieho seminára podľa harmonogramu
- Zabezpečenie prístupu k výkonnému hardvéru
- Administratívna

- **Diskusia**