

Výstup D1 Pracovní balík WP.1 Seminár č.1 Správa

Vypracoval: Ing. Roman Budjač, PhD.

Správa z úvodného stretnutia (Kickoff Meeting)

Projekt: SAMQ-NN - A Statistical Approach to Monitor Quantisation in Neural Network Training

Základné informácie o stretnutí

- **Dátum:** 3. Jún 2024
- **Miesto:** Výskumné centrum, zasadacia miestnosť č. 3.15,

Program stretnutia

1. Predstavenie projektu

Na stretnutí boli predstavené hlavné ciele projektu a predstava o postupe a implementácie projektu SAMQ-NN zameraný na:

-
- Analýzu vplyvu kvantizácie na trénovací proces neurónových sietí
- Vývoj štatistických metód na porovnávanie distribúcií váh
- Implementáciu novej trénovacej stratégie využívajúcej štatistické metódy

Takisto boli predstavené súčasné výzvy Súčasné výzvy v odbore umelej inteligencie a v priemysle:

- Neurónové siete dosahujú presvedčivé výsledky, ale ich veľkosť (komplexnosť) rastie exponenciálne.
- Modely ako GPT-3 majú 175 miliárd parametrov, čo znemožňuje ich nasadenie na edge zariadeniach.
- Trénovanie veľkých modelov vyžaduje enormné množstvo energie - jeden tréning GPT-3 spotreboval energiu ekvivalentnú spotrebe 126 domácností za rok.
- Priemysel potrebuje efektívne metódy kompresie bez významnej straty presnosti.
- Existujúce kompresné techniky (pruning, kvantizácia) sú často ad-hoc bez systematického prístupu k monitorovaniu kvality.
- Chýba metodológia na hodnotenie vplyvu kompresie na funkčnosť modelu.

Počas seminára boli predstavené pracovné balíky projektu a harmonogram ich implementácie počas doby riešenia projektu.

- **WP1:** Analýza a testovanie vhodných štatistických metód (M1-M6)
- **WP2:** Implementácia štatistických metód do kvantizačného procesu (M7-M12)
- **WP3:** Vývoj novej trénovacej stratégie (M13-M17)
- **WP4:** Overenie konceptu a publikovanie výsledkov (M18-M24)

3. Infraštruktúra a zdroje

Potvrdené dostupné zdroje:

- Pracovná stanica s výkonným grafickým procesorom
- Administratívna podpora od Výskumného centra Žilinskej Univerzity

4. Harmonogram a míľniky

Prezentované boli kľúčové míľniky výskumného projektu:

- **M1 (6. mesiac):** Analýza štatistických metód
- **M2 (12. mesiac):** Implementácia do tréningového procesu
- **M3 (18. mesiac):** Nová tréningová stratégia
- **M4 (20. mesiac):** Overenie konceptu

5. Prezentácia výstupov projektu

Boli odprezentované plánované výstupy projektu:

- 1x Publikácia v Q2 časopise (SCOPUS/WOS)
- 2x Konferenčné príspevky (SCOPUS)
- 4x Seminára
- 1x Priebežná správa
- 2x Zdrojový kód
- 1x Záverečná správa

6. Riziká a opatrenia - diskusia

Boli prediskutované riziká a určený postup ako sa s nimi vysporiadať počas implementácie projektu:

Riziko 1: Riziko nedostatočného hardvérového vybavenia stredná pravdepodobnosť, stredná závažnosť.

Opatrenie 1: Hostiteľská organizácia zabezpečí prístup k vysokovýkonnému grafickému hardvéru (GPU), ktorý poskytuje dostatočnú výpočtovú kapacitu pre experimenty vykonávané ako súčasť projektu.

Riziko 2: Štatistické metódy nebudú vhodné na porovnanie váh v neurónových sieťach. Závažnosť stredná, pravdepodobnosť nízka.

Opatrenie 2: Negatívnym vplyvom tohto rizika je možné využitím niekoľkých alternatívnych metód porovnávania distribúcií. V prípade nevyhovujúcich výsledkov sme priebežne modifikovali metodiku na základe dosiahnutých dát.

Riziko 3: Štatistické metódy na porovnávanie rozloženia váh nedosiahnu v prípade neurónovej siete očakávané výsledky. Závažnosť: stredná Pravdepodobnosť: nízka až stredná

Opatrenie 3: Negatívny vplyv tohto rizika je možné eliminovať iteratívnym prístupom. Tj. priebežne vyhodnocovať účinnosť použitých metód a ich dopad na metriky modelov neurónových sietí.

7. Prezentácia najbližších aktivít


Vytvorenie GitHub repozitára projektu

1. Príprava analýzy súčasného stavu problematiky a analýz štatistických metód
2. Naplánovanie ďalšieho seminára podľa harmonogramu

Hostiteľská organizácia zabezpečí :

- Zabezpečenie prístupu k výkonnému hardvéru
- Administratívna podpora

8. Fotodokumentácia zo seminára



Obrázok 1 Fotodokumentácia z prvého seminára projektu

8. Záver

Prvý seminár v rámci WP1 (Mesiac 1) úspešne predstavil výskumný problém kvantizácie neurónových sietí a navrhované štatistické prístupy pre monitoring distribúcie váh. Účastníci potvrdili relevanciu a inovatívnosť výskumu, ktorý integruje štatistické metódy do procesu kvantizácie. Hlavné odporúčania zahŕňali prioritizáciu Kullback Leibnerovej a Jensen Shanonovej divergencie, ako primárne metódy a potrebu detailného experimentálneho dizajnu. Seminár poskytol potrebný základ pre ďalšie fázy projektu a potvrdil správnosť zvoleného metodologického prístupu pre riešenie identifikovaného výskumného problému.

Dátum: 3.Jún 2024

Ing. Roman Budjač, PhD.