



Financovaný
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD VLÁDY
SLOVENSKEJ REPUBLIKY



MINISTERSTVO
ŠKOLSTVA, VÝSKUMU,
VÝVOJA A MLÁDEŽE
SLOVENSKEJ REPUBLIKY



VÝSKUMNÁ
AGENTÚRA

Výstup D2 Pracovní balík WP.1 Analýza vhodných štatistických metód

Vypracoval: Ing. Roman Budjač, PhD.



V úvodnej fáze projektu sme vykonali prieskum porovnávania distribúcií. Pozornosť sme venovali základom vlastností štatistických funkcií pre porovnávanie distribúcií ako aj aplikáciám v strojovom učení. Zamerali sme sa na metódy porovnávania distribúcií, ktoré môžu byť následne použité pre porovnanie distribúcií váh pred procesom kvantizácie a po procese kvantizácie neurónového modelu s cieľom znížiť jeho komplexnosť.

Na základe toho sme identifikovali nasledovné štatistické metódy:

- a) Kullback-Leiblerova divergencia (KL divergencia)
- b) Jensen-Shannonova divergencia (JS divergencia)
- c) Kosínusová podobnosť

Každá metóda bola hodnotená podľa kritérií:

- Citlivosť: Ako citlivo dokáže odhaliť malé zmeny v distribúcii váh.
- Výpočtová efektivita: Časová a pamäťová náročnosť výpočtu v kontexte experimentov s veľkými modelmi.
- Interpretovateľnosť: Jednoduchosť interpretácie výsledného čísla

Aj keď niektoré metódy sa môžu zdať viac náročné na výpočet pri prvých testoch sa metódy väčším nárokom na výpočet dokázali poskytnúť viac informácií a prejavili schopnosť citlivejšie reagovať na malé zmeny.

a) Kullback–Leiblerova divergencia (KL divergencia)

KL divergencia je štatistická metóda používaná na kvantifikáciu rozdielu medzi dvoma pravdepodobnostnými rozdeleniami. Meria, koľko informácie sa stratí, keď jedno rozdelenie slúži ako aproximácia druhého. Táto vlastnosť ju robí potenciálne užitočnou v oblastiach ako sú strojové učenie, teória informácií a analýza dát.

Matematická definícia:

Pre dve pravdepodobnostné rozdelenia P a Q, definovaná ako:

$$D_{KL}(P || Q) = \sum_{i=1}^n P(i) * \log(P(i) / Q(i))$$

Výsledok KL divergencie je vždy nezáporný, pričom:

- Hodnota 0 znamená úplnú zhodu distribúcií (žiadny rozdiel),
- Vyššia hodnota indikuje väčšiu rozdielnosť medzi distribúciami.

Kullback-Leiblerova divergencia je fundamentálna informačno-teoretická metrika, ktorá kvantifikuje rozdiel medzi dvoma pravdepodobnostnými distribúciami [1]. Taktiež nazývaná aj ako relatívna entropia. KL divergencia meria koľko dodatočnej informácie je potrebnej na zakódovanie dát z jednej distribúcie pomocou kódu vytvoreného pre



inú distribúciu. Táto asymetrická miera poskytuje informáciu o tom, ako sa porovnávaná distribúcia líši od referenčnej distribúcie.

V oblasti strojového učenia má KL divergencia významné uplatnenie v rôznych disciplínach. Pri trénoch generatívnych modelov, ako sú variačné autoenkóдеры (VAE), funguje ako regularizačný prvok, ktorý zabezpečuje, že latentné reprezentácie sa približujú k vopred stanovenej distribúcii [4]. V kontexte kompresie neurónových sietí je predpokladom, že by mohla kvantifikovať stratu informácií pri kvantizácii váh alebo aktivácií. Pri destilácii znalostí slúži na meranie rozdielu medzi výstupnými distribúciami učiteľského a študentského modelu. V bayesovskej inferencii vyjadruje rozdiel medzi apriórными a posteriornými distribúciami, zatiaľ čo v teórii informácie kvantifikuje neefektívnosť použitia nesprávneho pravdepodobnostného modelu [2], [9].

Matematicky je KL divergencia pre dve diskkrétne pravdepodobnostné distribúcie P a Q definovaná ako súčet súčinov pravdepodobností z distribúcie P a logaritmov pomeru pravdepodobností P/Q . Pre spojité distribúcie sa sumácia nahrádza integrálom. Výsledná hodnota je vždy nezáporná, pričom nulová hodnota indikuje identické distribúcie [1]. Čím vyššia je hodnota KL divergencie, tým väčší je rozdiel medzi distribúciami. Dôležitou vlastnosťou je asymetria - $KL(P||Q)$ sa vo všeobecnosti nerovná $KL(Q||P)$, čo znamená, že záleží na tom, ktorú distribúciu považujeme za referenčnú.

V prípade kvantizácie neurónových sietí má KL divergencia potenciál indikovať ako kvantizácia mení distribúciu váh modelu. Pred kvantizáciou majú váhy zvyčajne spojitú distribúciu s hodnotami v pohyblivej rádovej čiarkke, ale po kvantizácii sú obmedzené na diskkrétne množinu hodnôt [11]. KL divergencia dokáže zachytiť túto zmenu a kvantifikovať stratu informácií. Pri uniformnej kvantizácii, kde sú kvantizačné úrovne rovnomerne rozložené. Neuniformná kvantizácia, ktorá prispôsobuje kvantizačné úrovne skutočnej distribúcii váh, dosahuje nižšie hodnoty KL divergencie pri rovnakom počte bitov [10].

Interpretácia hodnôt KL divergencie v kontexte kvantizácie vyžaduje pochopenie špecifik konkrétnej architektúry a úlohy. Embedding vrstvy v jazykových modeloch môžu tolerovať prekvapivo vysoké hodnoty KL divergencie bez výraznej degradácie výkonu, často kvôli redundancii v reprezentáciách [13].

Praktické využitie KL divergencie pri sledovaní kvantizácie z nášho pohľadu zahŕňa niekoľko stratégií. Postupná kvantizácia po vrstvách umožňuje identifikovať kritické vrstvy s vysokou KL divergenciou a aplikovať na ne jemnejšiu kvantizáciu. Adaptívna kvantizácia by mohla dynamicky prispôbovať počet bitov pre každú vrstvu na základe cieľovej KL divergencie. Pri mixed-precision kvantizácii má KL divergencia potenciál byť použitá ako kritérium na rozhodovanie o bitovej šírke pre jednotlivé vrstvy alebo jednotlivé kanály. Monitorovanie KL divergencie počas quantization-aware training (QAT) predpokladá možnosť optimalizovať proces učenia a predchádzať degradácií modelu.



Výhody KL divergencie zahŕňajú jej silné teoretické základy v teórii informácie [1], prirodzenú interpretáciu, ako miery straty informácie, navyše sa predpokladá schopnosť zachytiť jemné rozdiely v distribúciách.

Z iného uhla pohľadu má aj významné obmedzenia. Asymetria KL divergencie spolu s požiadavkou na presné pravdepodobnostné distribúcie môže predstavovať výzvu, no zároveň poskytuje priestor na presnejšie a citlivejšie analýzy aj v kontexte spojitých váh [12] môže byť nekonečná ak distribúcií nie sú identické, a rozdiely v pravdepodobnostiach môžu viesť k veľkým zmenám v divergencii.

Zaujímavá je tiež možnosť KL divergenciu využiť v kombinácii s inými metrikami spomenutými v vyššie, tj. kosínusová podobnosť alebo JS divergenciu pre komplexnejší pohľad na zmeny v distribúcii. A to najmä v prípade použitia QAT metódy [13]. Pri implementácii je dôležité správne ošetriť numerické problémy, najmä pri práci s logaritmi malých čísiel. Pre vizualizáciu sa javí ako užitočné, sledovať vývoj KL divergencie počas tréningu alebo postupnej kvantizácie. KL divergencia predstavuje perspektívnu metriku na porovnávanie kvantizačných metód. Vďaka svojim špecifickým vlastnostiam dokáže efektívne zachytiť zmeny v rozložení váhových parametrov neurónových sietí počas kvantizačného procesu. Pričom jej schopnosť kvantifikovať stratu informácie ju robí užitočným nástrojom.

Výhody:

- KL divergencia je veľmi citlivá na malé rozdiely medzi porovnávanými pravdepodobnostnými rozdeleniami, čo umožňuje presne detegovať aj subtílné zmeny vo váhach modelov alebo v správaní dátových rozložení.
- Výsledná hodnota má jasnú interpretáciu – vyjadruje množstvo informácie (v bitoch alebo natách), ktorá by bola „stratená“, ak by sa namiesto skutočného rozdelenia PP použilo aproximujúce rozdelenie Q. Táto vlastnosť je cenná pri kvantitatívnom hodnotení modelov alebo počas optimalizácie modelových parametrov.
- KL divergencia má mnoho praktických využití – v našom prípade predpokladáme, že bude dobre ukazovať ako jeden model napodobňuje druhý, sleduje zmeny v neurónových sieťach po ich úprave (napríklad po kvantizácii), kontroluje priebeh tréningu modelov a dokáže odhaliť nezvyčajné vstupy, ktoré sa líšia od tréningových dát.
- Je základom pre odvodenie ďalších ďalších metrík, ako je Jensen–Shannonova divergencia alebo rôzne regularizačné techniky vo variácii autoenkóderoch (VAE).

Obmedzenia:

- KL divergencia je asymetrická. Z toho dôvodu nemôže slúžiť ako plnohodnotná metrika vzdialenosti (nesplňa metriku symetrie), čo môže byť limitujúce pri niektorých porovnávacích analýzach.
- Horná hranica KL divergencie nie je ohraničená (teda môže nadobúdať arbitrárne vysoké hodnoty), čo sťažuje priamu interpretáciu veľkých hodnôt a môže spôsobovať numerickú nestabilitu pri extrémnych rozdeleniach.
- Ak existujú hodnoty, pre ktoré $P(i) > 0$ a $Q(i) = 0$, výsledok je formálne nekonečno (divergencia nie je definovaná), čo je prakticky dôležité pri



prácach s diskretnými rozdeleniami alebo v situáciách s limitovanými údajmi (napríklad v prípade vzácnych udalostí).

- V praxi môže byť KL divergencia citlivá na voľbu bazových rozdelení a na numerické chyby spôsobené zaokrúhľovaním či chýbajúcimi pravdepodobnosťami. Preto je často nutné zaviesť aditívne vyhladzovanie alebo iné techniky pre stabilizáciu výpočtu.
- Pri porovnávaní modelov s veľmi odlišnými distribúciami môže byť výsledok zavádzajúci alebo ťažko interpretovateľný, najmä ak referenčné rozdelenie Q nevystihuje všetky možné hodnoty pozorované v P .

V kontexte kvantizácie neurónových sietí sa bude táto metrika využívať na porovnanie rozloženia váh pred a po procese kvantizácie. Vysoká hodnota KL divergencie indikuje, že došlo k výraznej zmene v distribúcii váh, čo môže potenciálne viesť k zhoršeniu výkonu modelu. Tento nástroj je preto kľúčový pri identifikácii problematických oblastí v procese kvantizácie. Pravidelné monitorovanie KL divergencie počas tréningového procesu môže poskytovať informácie o vplyve kvantizácie na jednotlivé vrstvy neurónovej siete. To nám umožňuje identifikovať potenciálne citlivé vrstvy, ktoré môžu vyžadovať modifikáciu stratégie. To umožňuje navrhnúť metódy pre optimalizovanie procesov kvantizácie, s cieľom udržať výkonnosť modelu aj pri zníženej bitovej presnosti.

[1] S. Kullback and R. A. Leibler, "On information and sufficiency," *The Annals of Mathematical Statistics*, vol. 22, no. 1, pp. 79-86, Mar. 1951.

[2] B. Jacob et al., "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 2018, pp. 2704-2713.

[3] Y. Guo, A. Yao, and Y. Chen, "Dynamic network surgery for efficient DNNs," in *Advances in Neural Information Processing Systems (NIPS)*, Barcelona, Spain, 2016, pp. 1379-1387.

[4] D. P. Kingma and M. Welling, "Auto-encoding variational Bayes," in *Proc. 2nd Int. Conf. Learning Representations (ICLR)*, Banff, AB, Canada, 2014.

[5] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," *arXiv preprint arXiv:1503.02531*, 2015.

[6] K. Wang, Z. Liu, Y. Lin, J. Lin, and S. Han, "HAQ: Hardware-aware automated quantization with mixed precision," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA, 2019, pp. 8612-8620.

[7] R. Banner, Y. Nahshan, and D. Soudry, "Post training 4-bit quantization of convolutional networks for rapid-deployment," in *Advances in Neural Information Processing Systems (NeurIPS)*, Vancouver, BC, Canada, 2019, pp. 7950-7958.



[8] A. Zhou, A. Yao, Y. Guo, L. Xu, and Y. Chen, "Incremental network quantization: Towards lossless CNNs with low-precision weights," in *Proc. 5th Int. Conf. Learning Representations (ICLR)*, Toulon, France, 2017.

[9] S. Han, H. Mao, and W. J. Dally, "Deep compression: Compressing deep neural networks with pruning, trained quantization and Huffman coding," in *Proc. 4th Int. Conf. Learning Representations (ICLR)*, San Juan, Puerto Rico, 2016.

[10] E. Park, S. Yoo, and P. Vajda, "Value-aware quantization for training and inference of neural networks," in *Proc. European Conf. Computer Vision (ECCV)*, Munich, Germany, 2018, pp. 580-595.

[11] J. Wu, C. Leng, Y. Wang, Q. Hu, and J. Cheng, "Quantized convolutional neural networks for mobile devices," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016, pp. 4820-4828.

[12] M. Nagel, M. Baalen, T. Blankevoort, and M. Welling, "Data-free quantization through weight equalization and bias correction," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, Seoul, Korea, 2019, pp. 1325-1334.

[13] Y. Choukroun, E. Kravchik, F. Yang, and P. Kisilev, "Low-bit quantization of neural networks for efficient inference," in *Proc. IEEE/CVF Int. Conf. Computer Vision Workshops (ICCVW)*, Seoul, Korea, 2019, pp. 3009-3018.

[14] A. Mishra and D. Marr, "Apprentice: Using knowledge distillation techniques to improve low-precision network accuracy," in *Proc. 6th Int. Conf. Learning Representations (ICLR)*, Vancouver, BC, Canada, 2018.

[15] Z. Dong, Z. Yao, A. Gholami, M. W. Mahoney, and K. Keutzer, "HAWQ: Hessian aware quantization of neural networks with mixed-precision," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, Seoul, Korea, 2019, pp. 293-302.

Ďalšou z analyzovaných metrík, ktorou možno hodnotiť rozdiely medzi rozloženími váh pred a po kvantizácii, je Kosínusová podobnosť.

b) Kosínusová podobnosť

Je fundamentálna geometrická metrika, ktorá kvantifikuje podobnosť medzi dvoma nenulovými vektormi vo viacrozmernom priestore meraním kosínusu uhla medzi nimi [1]. Táto metrika [2], sa stala významným nástrojom v modernom strojovom učení vďaka svojej schopnosti posudzovať smerovú podobnosť vektorov nezávisle od ich veľkosti. Jej invariantnosť a výpočtová efektívnosť jej dáva schopnosť na širšie spektrum aplikácií od spracovania prirodzeného jazyka (NLP) po analýzu neurónových sietí. V kontexte projektu má potenciál podobný na porovnanie váhových vektorov jednotlivých vrstiev alebo filtrov.



Matematická definícia: Pre dva vektory A a B je kosínusová podobnosť definovaná ako:

$$\cos(\theta) = (A \cdot B) / (||A|| \cdot ||B||)$$

kde:

- $A \cdot B$ je skalárny súčin vektorov
- $||A||$ a $||B||$ sú Euklidovské normy vektorov

Výsledkom kosínusovej podobnosti je:

- Hodnota je vždy v intervale $[-1, 1]$
- Hodnota 1 znamená identický smer vektorov (maximálna podobnosť)
- Hodnota 0 znamená ortogonálne (kolmé) vektory
- Hodnota -1 znamená opačný smer (maximálna nepodobnosť)

V oblasti spracovania prirodzeného jazyka je kosínusová podobnosť štandardom pre meranie sémantickej podobnosti textových dokumentov [3]. Pri reprezentácii dokumentov pomocou vektorových modelov ako TF-IDF alebo modernými word embeddings typu Word2Vec [4] či BERT [5], kosínusová podobnosť umožňuje efektívne porovnávať dokumenty rôznej dĺžky bez skreslenia spôsobeného počtom slov. V počítačovom videní sa využíva na porovnávanie príznakových vektorov extrahovaných z konvolučných neurónových sietí [6], čo umožňuje úlohy ako rozpoznávanie tvárí alebo vyhľadávanie podobných obrázkov [7], [8].

Matematicky je kosínusová podobnosť pre dva vektory A a B definovaná ako normalizovaný skalárny súčin, čo zodpovedá kosínusu uhla θ medzi nimi. Pre vektory v n -rozmernom priestore sa vypočíta ako podiel skalárneho súčinu vektorov a súčinu ich Euklidovských noriem [1]. Výsledná hodnota sa pohybuje v intervale $[-1, 1]$, kde 1 indikuje perfektnú zhodu smeru (nulový uhol), 0 znamená ortogonálnosť (90° uhol), a -1 vyjadruje presne opačné smery (180° uhol). Táto normalizácia zabezpečuje, že metrika je necitlivá na absolútnu veľkosť vektorov.

$$\cos(\theta) = (A \cdot B) / (||A|| \cdot ||B||)$$

Pri aplikácii na analýzu kvantizácie neurónových sietí poskytuje kosínusová podobnosť iný prístup k porovnávaní distribúcií ako ostatné hodnotené metódy. Zatiaľ čo KL divergencia meria zmeny v pravdepodobnostnom rozložení váh, kosínusová podobnosť zachytáva zachovanie relatívnych vzťahov medzi váhami [9].

Výhody kosínusovej podobnosti zahŕňajú jej výpočtovú efektívnosť s lineárnou komplexitou $O(n)$, intuitívnu geometrickú interpretáciu a širokú podporu vo všetkých hlavných frameworkoch pre strojové učenie [10]. Implementácia je relatívne jednoduchá a numericky stabilná pre väčšinu praktických aplikácií. Navyše, kosínusová podobnosť je funkčná s riedkymi vektormi, čo je výhodné pri práci s vysoko rozmernými reprezentáciami.



Obmedzenia tejto metriky :

Necitlivosť na veľkosť vektorov, hoci často výhodná, môže maskovať dôležité zmeny v absolútnych hodnotách váh [11]. Pri vektoroch blízkyh nule môže dochádzať k numerickej nestabilite, čo vyžaduje špeciálne ošetrovanie v implementácii. Kosínusová podobnosť tiež nedokáže zachytiť nelineárne vzťahy, čo môže byť limitujúce pri analýze hlbokých sietí s komplexnými interakciami [12].

Je vhodné kombinovať kosínusovú podobnosť kombinovať s komplementárnymi metrikami pre holistický pohľad na efekty kvantizácie. Kombinácia s L2 normou poskytuje informáciu o zmenách veľkosti aj smeru [13], zatiaľ čo použitie spolu s KL divergenciou umožňuje zachytiť distribučné aj smerové zmeny. Pre vizualizáciu je efektívne vytvárať heatmappy kosínusovej podobnosti medzi vrstvami pred a po kvantizácii, čo umožňuje rýchlu identifikáciu problematických oblastí modelu.

Referencie:

- [1] A. Singhal, "Modern information retrieval: A brief overview," *IEEE Data Engineering Bulletin*, vol. 24, no. 4, pp. 35-43, Dec. 2001.
- [2] G. Salton and M. J. McGill, *Introduction to Modern Information Retrieval*. New York, NY, USA: McGraw-Hill, 1983.
- [3] A. Huang, "Similarity measures for text document clustering," in *Proc. 6th New Zealand Computer Science Research Student Conf.*, Christchurch, New Zealand, 2008, pp. 49-56.
- [4] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," in *Proc. Int. Conf. Learning Representations (ICLR)*, Scottsdale, AZ, USA, 2013.
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. Conf. North American Chapter Association for Computational Linguistics*, Minneapolis, MN, USA, 2019, pp. 4171-4186.
- [6] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *Proc. 3rd Int. Conf. Learning Representations (ICLR)*, San Diego, CA, USA, 2015.
- [7] S. Han, J. Pool, J. Tran, and W. J. Dally, "Learning both weights and connections for efficient neural networks," in *Advances in Neural Information Processing Systems (NIPS)*, Montreal, QC, Canada, 2015, pp. 1135-1143.
- [8] Y. Li et al., "Exploiting kernel sparsity and entropy for interpretable CNN compression," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA, 2019, pp. 2800-2809.



[9] I. Hubara, M. Courbariaux, D. Soudry, R. El-Yaniv, and Y. Bengio, "Quantized neural networks: Training neural networks with low precision weights and activations," *Journal of Machine Learning Research*, vol. 18, no. 1, pp. 6869-6898, 2017.

[10] A. Paszke et al., "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems (NeurIPS)*, Vancouver, BC, Canada, 2019, pp. 8024-8035.

[11] Y. Bengio, P. Simard, and P. Frasconi, "Learning long-term dependencies with gradient descent is difficult," *IEEE Trans. Neural Networks*, vol. 5, no. 2, pp. 157-166, Mar. 1994.

[12] D. Molchanov, A. Ashukha, and D. Vetrov, "Variational dropout sparsifies deep neural networks," in *Proc. 34th Int. Conf. Machine Learning (ICML)*, Sydney, NSW, Australia, 2017, pp. 2498-2507.

[13] X. Glorot and Y. Bengio, "Understanding the difficulty of training deep feedforward neural networks," in *Proc. 13th Int. Conf. Artificial Intelligence and Statistics*, Sardinia, Italy, 2010, pp. 249-256.

b) Jensen-Shannonova divergencia

Je symetrická štatistická metrika, ktorá kvantifikuje podobnosť medzi dvoma pravdepodobnostnými distribúciami [1]. Vyvinutá ako symetrická modifikácia Kullback-Leibler divergencie, JS divergencia rieši kľúčové obmedzenia svojho asymetrického predchodcu a poskytuje robustnú, ohraničenú mieru rozdielnosti distribúcií [2]. Táto metrika, sa stala dôležitým nástrojom v strojovom učení vďaka svojej matematickému prínosu a praktickým vlastnostiam, najmä jej konečnosti a symetrii.

Matematicky definovaná ako:

$$JS(P||Q) = \frac{1}{2} \cdot D_{KL}(P||M) + \frac{1}{2} \cdot D_{KL}(Q||M)$$

V kontexte strojového učenia nachádza JS divergencia široké uplatnenie v kritických oblastiach. Pri trénovaní generatívnych adversariálnych sietí (GANs) slúži ako stabilnejšia alternatíva k štandardným stratovým funkciám, poskytujúc gradientový signál aj keď sa distribúcie neprekrývajú [3]. V oblasti spracovania prirodzeného jazyka sa využíva na meranie podobnosti distribúcií slov alebo tém, čo je kľúčové pre úlohy ako detekcia zmeny témy alebo porovnávanie jazykových modelov [4]. Pri kompresii neurónových sietí môže poskytnúť pohľad na zmeny distribúcie váh, kombinujúc výhody KL divergencie s dodatočnou symetriou a ohraničenosťou. V klastrovacej analýze slúži ako metrika vzdialenosti pre hierarchické zhľukovanie pravdepodobnostných distribúcií [5], [6].

Matematicky je JS divergencia vyjadrená ako vážený priemer dvoch KL divergencií - prvej medzi distribúciou P a priemernou distribúciou M, a druhej medzi distribúciou Q a tou istou priemernou distribúciou M. Pri aplikácii na kvantizáciu neurónových sietí



poskytuje JS divergencia rôzne výhody. Jej symetria znamená, že nezáleží na tom, či považujeme originálne váhy za referenčné voči kvantizovaným alebo naopak, čo je koncepčne jednoduché a prakticky užitočné [7], [8].

Výhody JS divergencie zahŕňajú jej matematickú robustnosť - vždy poskytuje konečné hodnoty, čo je kritické pri práci s diskretizovanými váhami [9]. Symetria eliminuje potrebu rozhodovania o referenčnej distribúcii, zjednodušujúc interpretáciu. Ohraničenosť umožňuje priame porovnanie naprieč rôznymi vrstvami a modelmi bez normalizácie. Spojitosť a diferencovateľnosť robia JS divergenciu vhodnou pre gradientové optimalizačné metódy [10]. Navyše, JS divergencia prirodzene interpoluje medzi distribúciami, čo je užitočné pri postupnej kvantizácii.

Obmedzenia JS divergencie:

Výpočtová náročnosť je vyššia než pri jednoduchej KL divergencii kvôli potrebe počítať priemernú distribúciu [11]. Pri vysokorozmerných distribúciách môže byť citlivá na spôsob odhadu hustoty pravdepodobnosti. JS divergencia tiež nemusí zachytávať jemné lokálne rozdiely tak dobre ako niektoré alternatívne metriky ako Wasserstein vzdialenosť [12]. Pri extrémne riedkych distribúciách môže poskytovať príliš optimistické hodnoty kvôli svojej tendencii priemerovať rozdiely.

Kombinácia s perceptuálnymi metrikami poskytuje holistický pohľad na zachovanie funkcionality modelu [13]. Pre vizualizáciu je efektívne vytvárať distribučné grafy ukazujúce originálne, kvantizované a priemerné distribúcie, čo umožňuje intuitívne pochopenie toho, čo JS divergencia meria [14]. Pri implementácii je kritické efektívne počítať priemernú distribúciu, používať numericky stabilné implementácie logaritmov, a ukladať medzivýsledky pri opakovaných výpočtoch. Pre veľké modely sa odporúča sampling-based aproximácia JS divergencie, ktorá poskytuje dostatočnú presnosť pri zlomku výpočtových nákladov [15].

Referencie:

- [1] J. Lin, "Divergence measures based on the Shannon entropy," *IEEE Trans. Information Theory*, vol. 37, no. 1, pp. 145-151, Jan. 1991.
- [2] D. M. Endres and J. E. Schindelin, "A new metric for probability distributions," *IEEE Trans. Information Theory*, vol. 49, no. 7, pp. 1858-1860, Jul. 2003.
- [3] M. Arjovsky, S. Chintala, and L. Bottou, "Wasserstein generative adversarial networks," in *Proc. 34th Int. Conf. Machine Learning (ICML)*, Sydney, NSW, Australia, 2017, pp. 214-223.
- [4] Y. K. Chia, S. Witteveen, and M. Andrews, "Transformer to CNN: Label-scarce distillation for efficient text classification," *arXiv preprint arXiv:1909.03508*, 2019.



- [5] Thiagarajan, B., & Ghosh, J. (2022). Generalized Jensen–Shannon Divergence Losses for Improved Variational Inference in Bayesian Neural Networks. arXiv preprint arXiv:2202.07408.
- [6] M. Cuturi and A. Doucet, "Fast computation of Wasserstein barycenters," in *Proc. 31st Int. Conf. Machine Learning (ICML)*, Beijing, China, 2014, pp. 685-693.
- [7] F. Österreicher and I. Vajda, "A new class of metric divergences on probability spaces and its applicability in statistics," *Annals of the Institute of Statistical Mathematics*, vol. 55, no. 3, pp. 639-653, Sep. 2003.
- [8] A. Polino, R. Pascanu, and D. Alistarh, "Model compression via distillation and quantization," in *Proc. 6th Int. Conf. Learning Representations (ICLR)*, Vancouver, BC, Canada, 2018.
- [9] P. Stock, A. Joulin, R. Gribonval, B. Graham, and H. Jégou, "And the bit goes down: Revisiting the quantization of neural networks," in *Proc. 8th Int. Conf. Learning Representations (ICLR)*, Addis Ababa, Ethiopia, 2020.
- [10] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [11] L. Theis, W. Shi, A. Cunningham, and F. Huszár, "Lossy image compression with compressive autoencoders," in *Proc. 5th Int. Conf. Learning Representations (ICLR)*, Toulon, France, 2017.
- [12] C. Villani, *Optimal Transport: Old and New*. Berlin, Germany: Springer-Verlag, 2008.
- [13] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 2018, pp. 586-595.
- [14] F. Nielsen and R. Nock, "On the chi square and higher-order chi distances for approximating f-divergences," *IEEE Signal Processing Letters*, vol. 21, no. 1, pp. 10-13, Jan. 2014.
- [15] S. Wang, Z. Su, L. Ying, and X. Peng, "Accelerating magnetic resonance imaging via deep learning," in *Proc. IEEE 13th Int. Symp. Biomedical Imaging (ISBI)*, Prague, Czech Republic, 2016, pp. 514-517.