



Financovaný
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD VLÁDY
SLOVENSKEJ REPUBLIKY



VÝSKUMNÁ
INOVÁČNA
AUTORITA



MINISTERSTVO
ŠKOLSTVA, VÝSKUMU,
VÝVOJA A MLÁDEŽE
SLOVENSKEJ REPUBLIKY



VÝSKUMNÁ
AGENTÚRA

Výstup D3

Pracovný balík WP.1

Testovanie štatistických metód na porovnávanie rozdelenia.

Vypracoval: Ing. Roman Budjač, PhD.



Financovaný
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD VLÁDY
SLOVENSKEJ REPUBLIKY



VÝSKUMNÁ
A INOVÁCNA
AUTORITA



MINISTERSTVO
ŠKOLSTVA, VÝSKUMU,
VÝVOJA A MLÁDEŽE
SLOVENSKEJ REPUBLIKY



VÝSKUMNÁ
AGENTÚRA

Porovnanie štatistických metrík Kullback-Leiblerovej (KL) a Jensen-Shannonovej (JS) divergencie je kľúčovým prvkom hodnotenia distribučných zmien v procese kvantizácie váh neurónových sietí. Implementácia týchto metrík v rámci systému SAMQ-NN bola realizovaná s cieľom umožniť komplexnú analýzu vplyvu kvantizácie na štruktúru váh modelu.

V nasledujúcom texte sú podrobne rozobrané matematické vlastnosti, praktická implementácia, interpretačné rámce a aplikačné dôsledky týchto Porovnanie štatistických metrík Kullback-Leiblerovej (KL) a Jensen-Shannonovej (JS) divergencie je kľúčovým prvkom hodnotenia distribučných zmien v procese kvantizácie váh neurónových sietí. V nasledujúcom reporte sú podrobne rozobrané matematické vlastnosti, praktická implementácia, interpretačné rámce a aplikačné dôsledky týchto metrík. Výsledky boli publikované v článku *Layer-wise Statistical Analysis: A Time-Sensitive Framework for Implementing Statistical Methods in Neural Network Training Sessions*

Matematický základ a význam metrík

KL divergencia je v literatúre často označovaná ako miera informačnej straty medzi dvoma rozdeleniami. Z formálneho hľadiska ide o asymetrickú mieru, ktorá kvantifikuje, o koľko je "originálne" rozdelenie vzdialené od "cieľového" rozdelenia, pričom výsledná hodnota môže nadobúdať hodnoty od nuly až po nekonečno. Tieto vlastnosti poskytujú na veľmi citlivé rozlišovanie zmien v prípadoch, kedy kvantizácia zásadne ovplyvní malú, ale významnú časť rozdelenia – typicky v chvostoch, kde môžu byť uložené napr. rozhodujúce váhy.

Z pohľadu implementácie je potrebné zabezpečiť, aby výpočet KL divergencie nebol ovplyvnený numerickými nestabilitami, napríklad v prípadoch výskytu nulových pravdepodobností v rozdelení kvantizovaných váh. Preto sú histogramy pred samotným výpočtom regularizované a následne normalizované, aby reprezentovali platné pravdepodobnostné rozdelenia. Celý výpočet možno ilustrovať nasledovným kódom:

```
def calculate_kl_divergence(dist1, dist2, bins=100, epsilon=1e-10):
    min_val = min(np.min(dist1), np.min(dist2))
    max_val = max(np.max(dist1), np.max(dist2))
    hist1, bin_edges = np.histogram(dist1, bins=bins, range=(min_val, max_val),
density=True)
    hist2, _ = np.histogram(dist2, bins=bins, range=(min_val, max_val), density=True)
    hist1 += epsilon
    hist2 += epsilon
    hist1 /= np.sum(hist1)
    hist2 /= np.sum(hist2)
    kl_div = entropy(hist1, hist2)
    return kl_div
```

JS divergencia rozširuje koncept KL divergencie tým, že zabezpečuje symetriu a ohraničenosť výsledných hodnôt v intervale $[0, 1]$. Jej výpočet spočíva v priemerovaní KL divergencie oboch rozdelení voči ich priemeru, čím sa minimalizuje vplyv

extrémnych hodnôt a zabraňuje sa vzniku nekonečných či nedefinovaných výsledkov. Táto vlastnosť je veľmi dôležitá najmä v aplikáciách, kde je potrebné automaticky nastavovať rozhodovacie prahy alebo porovnávať viacero modelov medzi sebou. Výpočet JS divergencie prebieha podľa nasledovného postupu:

```
def calculate_js_divergence(dist1, dist2, bins=100, epsilon=1e-10):  
    min_val = min(np.min(dist1), np.min(dist2))  
    max_val = max(np.max(dist1), np.max(dist2))  
    hist1, bin_edges = np.histogram(dist1, bins=bins, range=(min_val, max_val),  
density=True)  
    hist2, _ = np.histogram(dist2, bins=bins, range=(min_val, max_val), density=True)  
    hist1 += epsilon  
    hist2 += epsilon  
    hist1 /= np.sum(hist1)  
    hist2 /= np.sum(hist2)  
    m = 0.5 * (hist1 + hist2)  
    js_div = 0.5 * (entropy(hist1, m) + entropy(hist2, m))  
    return js_div
```

Obe metriky tak využívajú identické predspracovanie vstupných dát, čo je základným predpokladom pre ich správnu komparáciu. V praxi je tento spoločný krok realizovaný v systéme tak, že po vybraní vrstvy a extrakcii váh sa automaticky vypočítajú hodnoty KL a JS divergencie, aj spolu s kosínusovou podobnosťou, ktorá slúži ako pomocný ukazovateľ lineárnej podobnosti rozdelení:

```
if original_weights is not None and quantized_weights is not None:  
    flat_original = original_weights.flatten()  
    flat_quantized = quantized_weights.flatten()  
    kl_div = calculate_kl_divergence(flat_original, flat_quantized)  
    js_div = calculate_js_divergence(flat_original, flat_quantized)  
    cos_sim = calculate_cosine_similarity(flat_original, flat_quantized)
```

Interpretačné rámce a rozdiely v citlivosti

Významná výhoda KL divergencie je jej vysoká citlivosť na málo sa vyskytujúce váhové hodnoty a na zmeny v chvostoch distribúcie. To znamená, že aj menšie rozdiely v tejto oblasti môžu mať za následok výrazné zvýšenie hodnoty KL divergencie. V kontexte kvantizácie to umožňuje včasne identifikovať scenáre, kde dôjde k strate rozhodujúcich informácií, napríklad ak sa kvantizáciou odstráni váha s nízkou, ale významnou hodnotou pre rozhodovanie modelu. Čo dopredu nevieme a dokážeme to zhodnotiť až porovnaním distribúcií váh a ostatných metrík ako napr. Presnosť modelu.

JS divergencia, naopak, poskytuje konzistentné meranie celkových distribučných zmien a jej hodnota je menej ovplyvnená zriedkavými extrémnymi odchýlkami. Je preto výhodná pre nastavenie automatizovaných prahov (napríklad v CI pipeline alebo v produkčných systémoch), kde sa vyžaduje stabilné a ľahko interpretovateľné rozhodovanie.

Analýzu vlastností metrík možno podporiť automatizovaným pomerovým hodnotením, kde sa pomer KL a JS divergencie využíva na identifikáciu typu detegovanej zmeny:

```
def analyze_detection_differences(original, quantized):
    kl_div = calculate_kl_divergence(original, quantized)
    js_div = calculate_js_divergence(original, quantized)
    ratio = kl_div / js_div if js_div > 0 else float('inf')
    if ratio < 2.0:
        pattern = "Symetrická degradácia – metriky sa zhodujú"
    elif 2.0 <= ratio < 5.0:
        pattern = "Mierna asymetria – KL detekuje jemnejšie zmeny"
    elif ratio >= 5.0:
        pattern = "Výrazná asymetria – KL odhaľuje zásadné informačné straty"
    return {
        'kl_divergence': kl_div,
        'js_divergence': js_div,
        'ratio': ratio,
        'detection_pattern': pattern
    }
```

Z praktického pohľadu sa často ukazuje, že pri miernej kvantizácii (napr. 8 bitov) sú hodnoty JS divergencie veľmi nízke a KL divergencia naznačuje len jemnú informačnú stratu. Pri veľmi agresívnej kvantizácii však hodnota KL divergencia prudko rastie, zatiaľ čo JS divergencia zostáva ohraničená – tento rozdiel v správaní umožňuje jednoznačne identifikovať, kedy už kvantizácia vedie k stratám, ktoré sú pre model kritické.

Prezentácia výsledkov

Výpočty oboch metrík sú prezentované v používateľskom rozhraní spoločne so stručným popisom interpretačných možností. Vizualizácia distribúcií vo forme prekrývajúcich sa histogramov navyše poskytuje intuitívny pohľad na to, kde presne sa rozdelenia líšia, čo je dôležité najmä pri rozhodovaní o potrebe úpravy kvantizačných parametrov. Typická ukážka zobrazovacieho bloku je nasledovná:

```
st.subheader("Distribution Similarity Metrics")
col1, col2, col3 = st.columns(3)
with col1:
    st.metric("KL Divergence", f"{kl_div:.6f}")
    st.markdown("**Meria asymetrickú informačnú stratu**")
with col2:
    st.metric("JS Divergence", f"{js_div:.6f}")
    st.markdown("**Symetrické a stabilné meranie**")
with col3:
    st.metric("Cosine Similarity", f"{cos_sim:.6f}")
    st.markdown("**Vyššie je lepšie (max=1)**")
```

Distribution Overlay Comparison: cnn_conv1_W



Obrázok 1 Vizualizácia distribúcií.

Výsledky týchto metrík môžu byť následne použité v automatizovaných rozhodovacích algoritmoch, ktoré odporúčajú buď akceptáciu, alebo potrebu opätovnej kvantizácie, prípadne upozornenie na možné riziko degradácie modelu. Tieto úvahy sú pravdepodobne mimo riešiteľský

Záver

Zavedenie paralelného sledovania KL a JS divergencie v jednom analytickom pohľade poskytuje detailný základ pre hodnotenie kvantizácie v neurónových sieťach. Kým JS divergencia plní úlohu univerzálneho, stabilného skríningu kvality rozdelenia váh, KL divergencia umožňuje podrobnejšiu analýzu z pohľadu zachovania dôležitých informačných štruktúr v modeli. Kombinácia týchto metrík výrazne zvyšuje istotu pri výbere kvantizačných parametrov a zároveň minimalizuje riziko nepozorovaného zhoršenia výkonnosti modelu po kvantizácii. Otvorená je tiež otázka o možnej kombinovateľnosti štatistických metód pre detailnejší opis kvantizovaného modelu.

Z implementačného hľadiska sa ukazuje, že obe metriky sú výpočtovo menej náročné ako sa očakávalo a dajú sa priamo integrovať do užívateľských rozhraní či automatických systémov pre monitorovanie a validáciu komprimovaných modelov. Škálovateľnosť bude ďalším predmetom skúmania keďže pri mimoriadne komplexných modeloch aj takáto záťaž môže byť neprimeraná.