



# **Výstup D5**

## **Pracovný balík WP.2**

### **Seminár**

### **Správa**

Vypracoval: Ing. Roman Budjač, PhD.

## Správa z úvodného seminára č.2

### Projekt: SAMQ-NN - A Statistical Approach to Monitor Quantisation in Neural Network Training

#### Základné informácie o stretnutí

- **Dátum:** 3. Január 2025
- **Miesto:** Výskumné centrum, zasadacia miestnosť č. 3.15

#### Program stretnutia

##### 1. Prezentácia súčasného stavu projektu

Druhý seminár projektu SAMQ-NN sa uskutočnil v rámci pracovného balíka WP2 s cieľom prezentovať dosiahnutý pokrok v implementácii štatistických metód do kvantizačného procesu neurónových sietí. Stretnutie sa zameralo na technické výsledky, praktické výzvy a ďalšie smerovanie projektu v nadväznosti na dokončený prvý pracovný balík.

##### 1. Úvod a predstavenie výskumného problému (WP2)

Na úvod stretnutia boli zhrnuté hlavné ciele projektu SAMQ-NN, s dôrazom na problémy riešené v pracovnom balíku WP2:

- Integrácia identifikovaných štatistických metód do tréningového frameworku
- Výzvy s interpretáciou výsledkov štandardných metrík (accuracy, loss) po kompresii modelu.
- Cieľ WP2: Implementovať štatistické metódy, do procesu kvantizácie. Tj. Zlúčiť ideu analyzovať výsledky štatistických metód pri aplikácii kvantizácie neurónových sietí

##### 2. Predstavenie implementovaných štatistických metód

Táto sekcia detailne prezentovala tri kľúčové štatistické metódy, ktoré boli úspešne implementované a testované v rámci vyvíjaného frameworku. Každá metóda bola vyhodnotená z hľadiska jej vhodnosti pre monitoring kvantizačného procesu.

- **Kullback-Leibler divergencia** - asymetrické meranie vzdialenosti medzi distribúciami
- **Jensen-Shannon divergencia** - symetrická metrika pre stabilné výsledky
- **Kosínusová podobnosť** - meranie zmien v orientácii váhových vektorov

##### 3. Experimentálna implementácia:

Prezentované boli konkrétne výsledky experimentálneho testovania implementovaných metód na rôznych datasetoch neurónových sietí.

- Testovanie na datasetoch MNIST, F-MNIST a CIFAR-10
- Priemerné spomalenie trénovania veľmi nízke
- Úspešná implementácia checkpointového systému
- Validácia na CNN architektúrach

#### 4. Plánovaná architektúra softvérového frameworku

Prezentácia zahŕňala popis algoritmu (vypublikovaný na konferencií CSOC 2025) a jeho jednotlivých komponentov, ktoré umožňujú integráciu štatistických metód do existujúcich tréningových procesov.

- Efektívny systém extrakcie váh z rôznych typov vrstiev
- Automatické zachytávanie stavu modelu pomocou checkpointov
- Optimalizované výpočty s využitím NumPy vektorizácie

#### 5. Prediskutované boli niektoré výzvy, ktoré vyplynuli z doterajšieho riešenia projektu

Táto časť seminára sa zamerala na diskusiu praktických problémov, ktoré sa objavili počas implementácie, a navrhované prístupy k ich riešeniu. Diskusia bola obzvlášť cenná pre identifikáciu potenciálnych problémových oblastí a definovanie stratégií pre ich prekonanie.

- Ako interpretovať rozdiely medzi metrikami a možnosť nastavenia prahových hodnôt
- Ako zohľadniť rozdelenie distribúcie po kvantizácii
- Redukcia použiteľných štatistických metód na rozšírenie benchmarku
- Možné výpočtové dopady pri škálovaní na väčšie architektúry

#### 6. Publikačné výstupy a diseminácia

V tejto časti seminára boli prediskutované výsledky a prehľad dosiahnutých publikačných výstupov a plánovaných aktivít na šírenie poznatkov získaných v rámci projektu.

##### Realizované aktivity:

- Príprava konferenčného príspevku pre CSOC 2025 "Layer-wise Statistical Analysis: A Time-Sensitive Framework"
- Publikácia na konferencii CECIIS 2024 "Proposal for a weather monitoring system utilizing IoT technologies"
- Sprístupnenie výsledkov na GitHub repozitári:  
<https://romanbudjac.github.io/samqnn/>

#### 7. Riziká a ich riešenie

Riziká boli opäť prediskutované a bol poskytnutý aktuálny stav možných rizík a boli odprezentované vykonané opatrenia.

## Aktualizácia stavu rizík:

- Riziko 1 (hardvérové vybavenie): Vyriešené - zabezpečený prístup k výkonnému GPU
- Riziko 2 (vhodnosť štatistických metód): Pod kontrolou - testovaná efektívnosť štatistických metód
- Riziko 3 (výkonnostný dopad): Vyriešené – vplyv na beh programu odpovedá náročnosti operácií a existuje priestor na optimalizáciu implementovaných algoritmov

## 8. Harmonogram a nasledujúce aktivity v rámci WP2

- Pokračovať v dokumentácii projektu na repozitári GitHub.
- Príprava softvérových komponentov v rámci pracovného balíka.
- Príprava písomného zhrnutia výsledkov (D5,6).
- Zverejňovanie kódu a dokumentácie.
- Príprava ďalšieho seminára a publikovanie priebežných výsledkov.

## 9. Pripomienky a odporúčania

- V prípade identifikácie ďalších relevantných metrík bude metodika priebežne dopĺňaná
- Zhodnotiť vhodnosť vizualizácií pre užívateľov (Python, Streamlit, Shiny)
- Zvážiť zahrnutie analýzy vplyvu na inferenčný čas a energetickú efektívnosť modelov



Obrázok 1 Fotodokumentácia z druhého seminára projektu



Seminár úspešne naplnil svoje ciele – pomohol definovať spoločný prístup k experimentálnej aj implementačnej časti pracovného balíka WP2 a stanovil jasné pravidlá pre dokumentovanie výsledkov, a koordináciu ďalšej spolupráce v rámci projektu SAMQ-NN. Stretnutie tak vytvorilo potrebný základ pre efektívne pokračovanie výskumu v nadchádzajúcich fázach projektu.

*Dátum: 3.Jún 2024*

*Ing. Roman Budjač, PhD.*