

INTERIM REPORT

Štatistický prístup k monitorovaniu kvantizácie pri trénovaní neurónových sietí

Vypracoval: Roman Budjač



Financovaný
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD PODPRESEDU VLÁDY
SLOVENSKEJ REPUBLIKY
PRE PLÁN OBNOVY
A ZNALOSTNÚ EKONOMIKU



**VÝSKUMNÁ
AGENTÚRA**

„Štatistický prístup k
sledovaniu kvantizácie pre
tréning neurónových sietí“

Kód projektu:

09103-03-V04-00562

Financované Európskou úniou z
prostriedkov Plánu obnovy a
odolnosti SR

OBSAH

IDENTIFIKÁCIA PROJEKTU

METODIKA RIEŠENIA PROJEKTU

POPIS VYKONANÝCH ČINNOSTÍ

PROBLÉMY, RIZIKÁ A PRIJATÉ OPATRENIA

PRIEBEH A IMPLEMENTÁCIA PROJEKTU

PUBLICITA A KOMUNIKAČNÉ AKTIVITY

POPIS PLÁNOVANÝCH ČINNOSTÍ

Názov projektu: Štatistický prístup k sledovaniu kvantizácie pre tréning neurónových sietí

Kód projektu: 09I03-03-V04-00562

Akronym projektu: SMAQNN

Kód projektu: 09I03-03-V04-00526

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

METODIKA RIEŠENIA PROJEKTU

Metodika projektu je štruktúrovaná do štyroch nadväzujúcich fáz (Míľnikov), kde jednotlivé úlohy sú zapracované vo forme pracovných balíkov (WP), ktoré komplexne riešia výzvy kvantizácie neurónových sietí s integráciou štatistických metód za účelom sledovania zmeny distribúcie váh v modeli.

Prvá fáza zahŕňa analýzu a testovanie vhodných štatistických metód určených na porovnanie rozloženia váh neurónových sietí. V rámci tejto etapy sa identifikujú kľúčové štatistické metriky vhodné na monitorovanie zmien v distribúciách váh, pričom sa vykonávajú predbežné testy na detekciu zmien pred a po ukončení kvantizačného procesu. Táto etapa zahŕňa formalizáciu matematického rámca pre kvantifikáciu zmien v distribúciách váh a implementáciu algoritmov pre výpočet jednotlivých metrík.

Druhá fáza sa zameriava na analýzu implementácie a následnú integráciu vybraných štatistických metód. Projekt sa sústreďí najmä na tri štatistické metódy a to: Kullback-Leiblerova divergencia pre asymetrické meranie vzdialenosti medzi pôvodnou a kvantizovanou distribúciou, Jensen-Shannon divergencia ako symetrická metrika poskytujúca stabilné výsledky a Cosínusová podobnosť pre meranie zmien v orientácii váhových vektorov nezávisle od ich magnitúdy.

Tretia fáza realizuje návrh, vývoj a overenie novej tréningovej techniky pre neurónové siete, ktorá využíva štatistické porovnávanie rozloženia váh. Dôraz je kladený aj na integráciu týchto metód priamo do procesu učenia. Implementuje sa modulárny monitorovací systém pre sledovanie distribúcií váh počas tréningovania, logovacím mechanizmom a vizualizačnými nástrojmi. Navrhnuté riešenie bude doplnené

o kritériá skorého ukončenia. Experimentálna validácia prebieha na štandardných datasetoch (CIFAR-10, CIFAR-100 a iné) s využitím rôznych architektúr neurónových sietí.

Štvrtá fáza realizuje testovanie a vyhodnotenie koncepcie štatistických metód pre proces tréningu neurónových sietí prostredníctvom experimentálnej validácie. Hodnotenie zahŕňa analýzu výkonnostných charakteristík navrhnutých metód pomocou metrik. Validáčny proces predstavuje otestovanie návrhu na rôznych modelových architektúrach a aplikačných doménach s cieľom preskúmať možnosti aplikovateľnosti vyvinutej koncepcie.

POPIS VYKONANÝCH ČINNOSTÍ

Projekt *Štatistický prístup k sledovaniu kvantizácie pre tréning neurónových sietí* je realizovaný v súlade s plánovaným harmonogramom a doteraz boli splnené všetky stanovené míľniky. Projekt sa začal riešiť v júni 2024 a podarilo sa úspešne implementovať úvodné aktivity zamerané na výber a overenie štatistických metód vhodných na porovnávanie distribúcií váh v neurónových sieťach. Prvotné fázy sa sústredili na identifikáciu relevantných prístupov a ich pilotné testovanie na referenčných dátových sadách, čo umožnilo definovať vhodné postupy pre ďalší výskum. Projektové aktivity pokračovali v roku 2025 a projekt sa posunul do etapy integrácie vybraných metód do procesu kvantizácie v experimentálnom prostredí. V rámci tejto integrácie zvolených štatistických prístupov do procesu kvantizácie prebiehala tiež systematická analýza ich dopadu na metriky modelu v priebehu učenia.

Počas doterajšieho riešenia sme nezaznamenali významné komplikácie a jednotlivé aktivity, ako súčasť pracovných balíkov, na seba nadväzujú v súlade s harmonogramom. Získané poznatky boli spracované vo forme reportov, seminárov a publikačnými výstupmi. Zároveň sú výstupy zverejňované na repozitárii GitHub: <https://romanbudjac.github.io/samqnn/>.


A) Pracovný balík WP1 - Analýza a testovanie štatistických metód

Cieľom prvého pracovného balíka bolo vykonať prehľadovú analýzu a otestovanie štatistických metód. Vykonaná analýza vlastností štatistických metód a ich využitie v prostredí modelovania a návrhu neurónových sietí, zameraná na identifikáciu existujúcich štatistických metód vhodných pre porovnávanie distribúcií. Preskúmali sme existujúce využitie štatistických metód v oblasti štatistiky a ich uplatnenie v neurónových sieťach. Boli identifikované tri kľúčové štatistické metódy, ktoré budú ďalej skúmané: Kullback-Leibler divergencia, Jensen-Shannon divergencia a Kosínusová podobnosť. Pre každú metódu sa teoretická analýza zahŕňajúca matematické základy, výpočtovú zložitosť a vhodnosť pre aplikáciu v kontexte neurónových sietí a ich implementáciu do existujúcich procesov.

Vytvorili sme testovacie prostredie v programovacom jazyku Python s využitím frameworku Keras alebo Pytorch. Implementovali sa tri identifikované štatistické metódy (Kullback Leibner divergenciu, Jensen Shanonovu divergenciu a Kosínusovu podobnosť) s jednotným rozhraním a počiatočnými podmienkami. Podkladom boli existujúce verejne dostupné datasety, ktoré sú štandardom v komunite výskumníkov a vývojárov. Takto pripravené datasety sme použili na výpočet distribúcií váh modelov neurónových sietí distribúcie s rôznymi charakteristikami. Tým, že sme použili reálnu dátovú sadu aj distribúcie získané experimentami, zodpovedali reálnym podmienkam. Vyhli sme sa tým využitím syntetickým vygenerovaným údajom, ktoré by poskytli požadované výstupy, ale nezohľadňovali by reálne podmienky zásad tvorby dátových sád. Takto definovaným spôsobom testovania zabezpečuje otestovanie štatistických metód a porovnávanie distribúcií pred kvantizáciou a po kvantizácii jednotným spôsobom a zaručuje pokrytie dátových bodov z rôznych typov dátových sád, ktoré zodpovedajú reálnym objektom.


Testovanie bolo vykonané na datasetoch CIFAR10, CIFAR10, MNIST a FMNIST s použitím jednoduchšej konvolučnej siete. S cieľom pochopiť fungovanie porovnávanie distribúcií váh neurónových sietí na reálnych dátových sadách. Pre každú kombináciu distribúcií sa zaznamenali hodnoty metrík, čas výpočtu a stabilita výsledkov. Analyzovali sa získané výsledky a identifikovali sa silné a slabé stránky jednotlivých metód v kontexte ich použitia pre monitorovanie kvantizácie. Najmä išlo o vplyv a zaťaženie pridaných štatistických metód v procese tréningu neurónových sietí. Na obrázkoch 1 a 2 je možné vidieť typické rozloženie váh v jednej z vrstiev CNN modelu na datasete MNIST.

Weight Distribution for Layer: MNIST (digits)_dense_W1



Obrázok 1 Rozloženie váh vo vrstve dense_W1 na datasete MNIST

Weight Distribution for Layer: cnn_dense_W2




Obrázok 2 Rozloženie váh vo vrstve dense_W2 na datasete MNIST

Ďalej na obrázku č. 3 vidíme rozdielne zmeny rozloženia váh pred kvantizáciou a po kvantizácií. Tieto údaje zobrazujú rozloženie váh po použití 8-bitovej kvantizácie. Na obrázku č. 3 je dobre vidieť, ktoré časti boli upravené kvantizáciou, kde modrá značí pôvodné váhy a červenou je označená početnosť váh v originálnom rozložení. Plocha, ktorá je prekrytá predstavuje údaje ovplyvnené procesom kvantizácie a nenachádzajú sa viac v dátovom priestore matice váh tohto modelu. Kvantizácia teda zredukovala komplexnosť rozloženia váh takým spôsobom, aby sa blížil k ideálnemu tvaru “zvonu”, ktorý je v teoretickej analýze reprezentovaný Gaussovou krivkou.

Tento efekt možno vysvetliť tým, že kvantizácia odstraňuje extrémne hodnoty a zhlukuje váhy okolo dominantných hodnôt, čím dochádza k zúženiu rozptylu a k zvýšeniu špicatosti (kurtózy) výslednej distribúcie. Táto transformácia je teoreticky významná, pretože Gaussovo rozloženie predstavuje optimálnu distribúciu pre dané strednú hodnotu a rozptyl, čo predpokladá, že kvantizácia môže viesť k efektívnejšej reprezentácii informácií v parametrickom priestore neurónnej siete.

Z hľadiska štatistickej analýzy je možné pozorovať, že kvantizácia spôsobila nielen diskretizáciu hodnôt váh, ale aj zmenu v základných momentoch distribúcie - strednú hodnotu, rozptyl, šikmosť a špicatosť. Tento fakt má významné implikácie pre zachovanie informačnej kapacity modelu a jeho schopnosť generalizácie, čo sa odráža v zmene Kullback-Leibler divergencie medzi pôvodným a kvantizovaným rozložením váh.

Weight Distribution Comparison for Layer: MNIST (digits)_dense_W1



Obrázok 3 Rozloženie váh pred a po 8 bitovej kvantizácii na datasete MNIST.


V prvom pracovnom balíku bol zorganizovaný aj úvodný seminár pre prezentáciu výskumného problému a východzieho stavu problematiky projektu.

B) Pracovný balík WP2 - Implementácia štatistických metód do procesu kvantizácie

Ako súčasť projektu bola navrhnutá architektúra softvérového frameworku umožňujúca funkčnú integráciu rôznych štatistických metód. Bol navrhnutý algoritmus systému v podobe funkčného diagramu rozhrania pre jednotlivé komponenty. Tento diagram vysvetľuje základnú logiku navrhnutého frameworku s využitím štatistických metód. Architektúra bola navrhnutá pre jednoduchú integráciu do existujúcich tréningových procesov.

Implementácia bola vykonaná v jazyku Python využívajúci, deep learning framework. Vytvorené boli softvérové komponenty pre extrakciu váh z rôznych typov vrstiev, efektívny výpočet distribúcií a správu referenčných dát. Implementovali sme vlastný mechanizmus volania, ktorý umožňoval automatické zachytávanie stavu modelu v podobe Checkpointov, ktoré boli následne použité pre znovuoobnovenie modelu. S cieľom zníženia záťaže pri experimentálnom implementovaní štatistických metód do procesu tréningovania. V tejto súvislosti boli využité vektorizované operácie s NumPy, implementované bolo sa aj ukladanie medzivýsledkov.

Testovanie prebiehalo na rôznych architektúrach, najmä išlo o CNN na datasete MNIST a CNN architektúry na datasete CIFAR-10. Overila sa nielen funkčnosť výpočtu zmien v distribúcii a ich implementovania vo forme štatistických metód, ale aj praktický vplyv na trénovací proces. Takisto bol overovaný systém ukladania checkpointov v jednotlivých fázach trénovania neurónových sietí a ich dopad. Priemerné spomalenie trénovania predstavovalo len 1.8% (v absolútnom čísle 0.014s), čo potvrdilo praktickú využiteľnosť riešenia na datasete CIFAR10 – obrázok 4.



Obrázok41 Záťaž štatistických metód v implementácii do procesu trénovania a kvantizácie

Súčasťou pracovného balíka bolo aj zorganizovanie dvoch seminárov v rámci pracovného kolektívu na VC Uniza, z ktorého sme vytvorili správu. Hlavným prínosom obidvoch seminárov bolo prediskutovanie aktuálneho stavu projektu a vypočutie si odborného názoru účastníkov.

Diseminačné činnosti v pracovnom balíku WP1 a WP2, predstavovali zorganizovanie úvodného seminára pre prezentáciu výskumného problému a východzieho stavu problematiky projektu. Z poznatkov získaných implementovaním štatistických metód do procesu trénovania neurónových sietí bol vypracovaný konferenčný príspevok na medzinárodnej konferencii CSOC 2025 indexovanej v databáze SCOPUS. Jednalo sa o článok “Layer-wise Statistical Analysis: A Time-Sensitive”. Ďalší publikačný výstup “Proposal for a weather monitoring system utilizing IoT technologies” bol odprezentovaný na konferencii CECIIS 2024 vo Varaždíne bol prezentovaný na vedeckej konferencii a bude indexovaný v databáze SCOPUS.

PROBLÉM, RIZIKÁ A PRIJATÉ OPATRENIA

V priebehu projektu sa objavili určité výzvy, ktoré boli však už od začiatku identifikované v rámci riadenia rizík, a preto boli vyriešené proaktívnym a prediktívnym prístupom ešte pred ich negatívnym dopadom na projekt. Jednalo sa najmä :

Riziko 1: Riziko nedostatočného hardvérového vybavenia. Pravdepodobnosť: stredná, Závažnosť: stredná.

Opatrenie 1: Hostiteľská organizácia zabezpečila prístup k vysokovýkonnému grafickému hardvéru (GPU), ktorý poskytuje dostatočnú výpočtovú kapacitu pre experimenty vykonávané ako súčasť projektu.

Riziko 2: Štatistické metódy nebudú vhodné na porovnanie váh v neurónových sieťach. Závažnosť stredná, pravdepodobnosť nízka.

Opatrenie 2: Negatívnemu vplyvu tohto rizika sme predišli využitím niekoľkých alternatívnych metód porovnávania distribúcií. V prípade nevyhovujúcich výsledkov sme priebežne modifikovali metodiku na základe dosiahnutých dát.

Riziko 3: Štatistické metódy na porovnávanie rozloženia váh nedosiahnu v prípade neurónovej siete očakávané výsledky. Závažnosť: stredná Pravdepodobnosť: nízka až stredná

Opatrenie 3: Negatívny vplyv tohto rizika sme eliminovali iteratívnym prístupom, v rámci ktorého sme priebežne vyhodnocovali účinnosť použitých metód a ich dopad na metriky modelov neurónových sietí.

PRIEBEH A IMPLEMENTÁCIA PROJEKTU

Výskumný projekt zahŕňa 4 pracovné balíky (WP1, WP2, WP3, WP4), tie sú definované štyrmi míľnikmi MS1 – MS4.

Prvý míľnik projektu (MS1) zahŕňa analýzu súčasných štatistických metód vhodných na porovnávanie distribúcií váh v neurónových sieťach a ich modeloch. Prvý míľnik projektu (MS1) zahŕňa analýzu a testovanie existujúcich štatistických metód vhodných na porovnávanie distribúcií váh v neurónových sieťach a ich modeloch.

Druhý míľnik (MS2) je zameraný na analýzu integrácie vybraných štatistických metód priamo do procesu kvantizácie neurónových sietí. V rámci tejto etapy boli analyzované možnosti aplikácie týchto metód na posúdenie vplyvu kvantizácie na rozloženie váh modelov.

Tretí míľnik (MS3) je zameraný na overenie implementácie vybraných štatistických metód priamo v procese tréningu neurónovej siete je zakomponovaný štatistický prístup. Súčasťou je integrácia štatistických metód do tréningu, s cieľom sledovať zmeny v rozložení váh. Výsledkom je implementácia, ktorá umožňuje vyhodnocovanie vplyvu kvantizácie na jednotlivé modely.

Štvrtý míľnik (MS4) zahŕňa experimentálne otestovanie navrhnutého konceptu na reálnych dátach, a záverečnú validáciu implementovaných metód. Súčasťou je publikácia vo vedeckom časopise. Cieľom míľnika je vyhodnotenie koncepcie implementácie štatistických metód pre proces tréningu neurónových sietí.

Zhodnotenie plnenia cieľov projektu:

Počas realizácie projektu sa podarilo úspešne naplniť prvé dva míľniky (MS1-MS2).

Projekt je súčasne rozdelený do štyroch pracovných balíkov (WP1 – WP4), pričom každý z nich pokrýva kľúčové etapy riešenia. Prvý pracovný balík (WP1) sa zameriava na analýzu a testovanie vybraných štatistických metód pre porovnanie rozloženia váh neurónových sietí. V rámci druhého pracovného balíka (WP2) prebieha analýza a implementácia týchto metód v kontexte procesu kvantizácie. Realizácia celého projektu je stanovená štyrmi míľnikmi, ktoré reflektujú postupnosť jednotlivých aktivít projektu.

Cieľ projektu vzhľadom na jednotlivé pracovné balíky v monitorovacom období od začiatku realizácie projektu môžeme zhrnúť nasledovne

- **WP1:** cieľom pracovného balíka WP1 bolo realizovať analýzu a testovanie vhodných štatistických metód určených na porovnanie rozloženia váh neurónových sietí v rôznych štádiách kvantizácie.
- **WP2:** cieľom pracovného balíka WP2 je analýza a následná implementácia vybraných štatistických metód do procesu kvantizácie.
- **WP3:** cieľom pracovného balíka WP3 je návrh, vývoj a overenie novej tréningovej techniky pre neurónové siete, ktorá využíva štatistické porovnávanie rozloženia váh s dôrazom na integráciu týchto metód priamo do procesu učenia a ich experimentálnu validáciu na štandardných dátových sadách.
- **WP4:** Hlavným cieľom pracovného balíka WP4 je komplexné overenie navrhnutého konceptu

Zhodnotenie plnenia cieľov projektu:

Počas realizácie projektu sa podarilo úspešne naplniť ciele prvých dvoch pracovných balíkov (WP1-WP2). Bola vypracovaná analýza a testovanie vhodných štatistických metód na porovnávanie distribúcie váh neurónových sietí. Následne boli vybrané najvhodnejšie metódy implementované do softvérového prostredia a boli realizované experimenty na dátových sadách s cieľom porovnať vplyv kvantizácie na rozloženie váh a výkonnosť modelov. V ďalšom kroku sa podarilo úspešne integrovať vybrané štatistické metódy priamo do procesu kvantizácie neurónových sietí, čím bola umožnená detailná analýza zmien v rozložení váh počas tréningu i po kvantizácii. Všetky aktivity boli zrealizované v súlade s časovým harmonogramom projektu.

Výstupy projektu v monitorovacom období:

V nasledovnom zozname sa nachádzajú dodané výstupy (D1-D9) spolu s mesiacom dodania výstupu podľa harmonogramu projektu.

1. D1 - Seminár (správa) – Mesiac 1
2. D2 - Report Mesiac 3
3. D3 - Zdrojový kód Mesiac 6
4. D4 - Publikácia na vedeckej konferencii Mesiac 7
5. D5 - Seminár (Správa) Mesiac 8

6. D6 - Report Mesiac 10
7. D7 - Zdrojový kód Mesiac 12
8. D8 - Publikácia na vedeckej konferencii Mesiac 12
9. D9 - Priebežný report Mesiac 12

Všetky výstupy projektu sú v súlade so spôsobom overovania výstupov projektu, dodané aj na repozitári GitHub: <https://romanbudjac.github.io/samqnn/>

Zhodnotenie plnenia výstupov projektu:

Výstupy projektu boli definované v súlade s cieľmi jednotlivých pracovných balíkov. Počas realizácie projektu sa podarilo úspešne naplniť výstupy D1 až D9 v súlade s harmonogramom projektu. Bola realizovaná séria odborných seminárov, spracovaná teoretická analýza a testovanie vhodných štatistických metód na porovnávanie rozloženia váh neurónových sietí, implementované do modelového prostredia. Výsledky boli prezentované na vedeckých konferenciách Conference on Information and Intelligent Systems 2024 (CECIIS) a Computer Science On-line Conference 2025, publikované v priebežnej správe a všetky výstupy boli sprístupnené v projektovom repozitári. Všetky výstupy boli splnené v súlade s harmonogramom projektu.

PUBLICITA A KOMUNIKAČNÉ AKTIVITY

Diseminácia výsledkov projektu smerom k vedeckej komunite, ako aj ďalším relevantným cieľovým skupinám prebieha prostredníctvom viacerých kanálov. Výsledky projektu boli prezentované na medzinárodných vedeckých konferenciách, konkrétne išlo o účasť na konferenciách Conference on Information and Intelligent Systems 2024 (CECIIS) a Computer Science On-line Conference 2025. Príspevky z týchto konferencií sú (budú) publikované v zborníkoch indexovaných v rešpektovaných vedeckých databázach (Scopus), čím je zabezpečený široký dosah výstupov projektu. Takisto boli vypublikované dvakarentované články v impaktovaných časopisoch IEEE Access a Applications in Engineering Science vo vydavateľstve Elsevier a IEEE. Oba v kvartile WOS Q2. Projekt kladie dôraz na princípy otvoreného prístupu, preto sú všetky relevantné vedecké výstupy sprístupňované vo verejne dostupnom repozitári, na platforme GitHub.

V súčasnosti vydané publikácie relevantné k projektu:

[1] G. Gašpar, R. Budjač, M. Valášek, M. Bartoň, T. Meravý, and M. Strémy, "Digitizing SMEs in the EU: A scalable model for retrofitting machinery to Industry 4.0,"

Applications in Engineering Science, vol. 23, p. 100230, Sep. 2025, doi: 10.1016/j.apples.2025.100230.

[2] G. Gaspar et al., "Innovative Grouting Process Monitoring: Design and Implementation of a Measurement Device With Datalogger Function," IEEE Access, vol. 13, pp. 19340–19352, 2025, doi: 10.1109/access.2025.3534816.

[3] R. Budjac, G. Gašpar, and M. Valášek, "Proposal for a weather monitoring system utilizing IoT technologies," in Proceedings Central European Conf. Information and Intelligent Systems (CECIIS), Varaždin, Croatia, Sep. 2024, pp. 67-74.

V súčasnosti publikácie v recenzii relevantné k projektu:

[4] Budjac R, Valasek M., T. Meravy, and G. Gaspar, "A Multiservice-Oriented Framework for Enhanced Data Collection and Visualization in Smart City Applications," IEEE Access

V súčasnosti publikácie akceptované čakajúce na vydanie k projektu:

[5] R. Budjac and M. Valasek, "Layer-wise Statistical Analysis: A Time-Sensitive Framework for Implementing Statistical Methods in Neural Network Training Sessions," in Lecture Notes in Networks and Systems, Proceedings: *Artificial Intelligence Algorithm Design for Systems*, Springer, [2025], 18p.

POPIS PLÁNOVANÝCH ČINNOSTÍ

V nasledujúcom období budú pokračovať experimenty zamerané na vývoj a implementáciu stratégie trénovania za účelom porovnávania rozloženia váh v neurónových sieťach pred a po procese kvantizácie. Plánované je rozšírenie testovania na ďalšie typy architektúr hlbokých neurónových sietí s použitím rôznych typov štandardizovaných datasetov, s cieľom overiť robustnosť navrhnutých štatistických metód vo všeobecnejšom kontexte aplikácií umelej inteligencie.

Výsledky získané v rámci projektu budú publikované vo vedeckom časopise indexovanom vo Web of Science (Q2 alebo vyššia kategória) a prezentované na medzinárodných konferenciách.