

Analýza implementácie porovnávania distribúcie váh do procesu tréningu neurónovej siete

Výstup D10 · Pracovný balík WP3

Sumár - Správa – Report

Identifikácia projektu:

Názov projektu: Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí

Akronym projektu: SAMQ-NN

Kód projektu: 09I03-03-V04-00562

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

Hlavný riešiteľ: Ing. Roman Budjač, PhD.

1. Úvod

Predkladaný dokument je výstupom D10 pracovného balíka WP3 (Vývoj a implementácia novej tréningovej stratégie) projektu SAMQ-NN. Analýza priamo nadväzuje na výsledky predchádzajúcich balíkov: vo WP1 boli vybrané a otestované vhodné štatistické metódy na porovnanie rozdelenia váh neurónovej siete, ako sú Kullback-Leiblerova divergencia (KL), Jensen-Shannonova divergencia (JS) a kosínusová podobnosť. V prípade WP2 boli tieto metódy implementované do procesu kvantizácie modelu.

Kým v predchádzajúcich balíkoch sa porovnanie rozdelenia váh vykonávalo prevažne staticky, teda až po dokončení kvantizácie nad uloženými váhami pôvodného a kvantizovaného modelu, ťažiskom WP3 je posunúť toto porovnanie priamo do tréningového procesu. Hlavnou metodickou myšlienkou je sledovať index podobnosti medzi referenčným rozdelením váh pôvodného (nekvantizovaného) modelu a aktuálnym rozdelením váh kvantizovaného modelu.

Cieľom tejto analýzy je rozobrať, akým spôsobom je možné takéto porovnanie integrovať do tréningovej slučky, ktoré z dostupných štatistických metód sú na priebežné monitorovanie najvhodnejšie, aké sú výpočtové dôsledky takejto integrácie a ako možno získaný index podobnosti využiť na riadenie samotného tréningu. Závěry analýzy tvoria priamy vstup pre praktickú implementáciu vo výstupe D12.

2. Východisková architektúra a štatistické metódy

Analýza vychádza zo štatistického jadra implementovaného vo WP2 (výstup D7). To poskytuje výpočet KL divergencie, JS divergencie a kosínusovej podobnosti, doplnkovo aj

Wassersteinovej vzdialenosti. Spoločným základom týchto metrík je reprezentácia množiny váh ako diskrétného pravdepodobnostného rozdelenia získaného histogramom.

2.1 Reprezentácia rozdelenia váh

Váhy zvolenej vrstvy (alebo celého modelu) sa zhrnú do histogramu nad pevnými hranicami binov (intervalou). Aby boli dve rozdelenia porovnateľné, používajú sa identické hranice binov pre referenčné aj aktuálne rozdelenie. Histogram sa následne normalizuje na pravdepodobnostné rozdelenie (súčet hodnôt rovný jednej). Pred normalizáciou sa k početnostiam pripočíta malá konštanta epsilon (napr. $1e-10$), čím sa zabezpečí numerická stabilita a zamedzí výpočtu logaritmu nuly pri KL a JS divergencii.

2.2 Vlastnosti metód z hľadiska monitorovania počas tréningu

Pri výbere metódy pre priebežné monitorovanie sú podstatné jej matematické vlastnosti:

- **KL divergencia:** nesymetrická a neohraničená. Intuitívne vyjadruje mieru odklonu kvantizovaného rozdelenia od referenčného. Aj keď nie je ohraničená, z veľkosti hodnoty je možné pomerne priamo odhadnúť rozsah rozdielu medzi rozdeleniami, preto je vhodná ako primárny index.
- **JS divergencia:** symetrická a ohraničená v intervale $[0, 1]$. Poskytuje stabilný výstup vhodný na prahovanie a optimalizačné kritériá a je robustná aj v prípade neprekrývajúcich sa nosičov, kde by KL divergencia viedla k nedefinovanému výsledku.
- **Kosínusová podobnosť:** meria orientáciu váhových vektorov nezávisle od ich magnitúdy, čím dopĺňa predošlé metriky o štruktúrny pohľad na zmenu váh.

Z pohľadu monitorovania je výhodné, že tieto metódy nie sú výpočtovo náročné, takže v budúcnosti je možné počítat aj viac indexov súčasne a porovnávať ich vývoj.

3. Návrh integrácie do tréningového procesu

3.1 Referenčné rozdelenie

Pred spustením dotrénovania kvantizovaného modelu sa z pôvodného modelu extrahujú váhy a uloží sa ich rozdelenie ako referencia. Toto referenčné rozdelenie sa počas celého dotrénovania nemení a slúži ako pevný bod porovnania. Súčasne sa zafixujú aj hranice binov, aby každé následné porovnanie používalo konzistentnú metriku.

3.2 Mechanizmus výpočtu

Priebežné porovnanie sa realizuje prostredníctvom vlastnej triedy typu callback v rámci frameworku Keras. Callbacky sú množinou metód volaných v rôznych fázach tréningu, testovania a predikcie a sú vhodné na získanie pohľadu na vnútorné stavy a štatistiky modelu počas tréningu. Konkrétne sa využíva metóda volaná na konci každej epochy: vyextrahujú sa aktuálne váhy kvantizovaného modelu, zostaví sa ich histogram nad rovnakými hranicami binov ako referencia, vypočíta sa index podobnosti zvolenou metódou a hodnota sa zapíše do histórie tréningu. Štruktúru takéhoto callbacku ilustruje nasledujúci kód:

```
class SimilarityMonitorCallback(keras.callbacks.Callback):  
    def __init__(self, reference_dist, bin_edges, method="kl"):  
        super().__init__()
```

```
self.reference_dist = reference_dist # rozdelenie vah povodneho modelu
self.bin_edges = bin_edges # pevne hranice binov
self.method = method # "kl" | "js" | "cosine"
self.history = []

def on_epoch_end(self, epoch, logs=None):
    current = flatten_weights(self.model.get_weights())
    index = compare_distributions(self.reference_dist, current,
                                self.bin_edges, self.method)

    self.history.append(index)
    logs[f"sim_{self.method}"] = index
    print(f"Epoch {epoch+1}: index podobnosti "
          f"({self.method}) = {index:.4f}")
```

Funkcie `flatten_weights` a `compare_distributions` predstavujú pomocné rutiny, ktoré budú v plnej podobe implementované v neskorších delivaerables.

3.3 Porovnanie po vrstvách verus globálne

Analýza nám dáva do pozornosti dva pohľady. Porovnanie po jednotlivých vrstvách poskytuje jemnejšiu informáciu o tom, ktoré vrstvy sú kvantizáciou ovplyvnené najviac, a je užitočné pri návrhu adaptívnych kvantizačných stratégií s rôznym počtom bitov pre rôzne vrstvy. Globálny index agreguje všetky váhy do jednej hodnoty a poskytuje súhrnný ukazovateľ stavu modelu počas tréningu. Pre potreby priebežného monitorovania sa odporúča sledovať globálny index ako hlavnú metriku a po vrstvách analyzovať v prípade detekcie výraznej divergencie.

4. Výpočtová náročnosť a vplyv na tréning

Výpočet indexu pozostáva zo zostavenia histogramu a vyhodnotenia entropie, resp. skalárneho súčinu pri kosínusovej podobnosti. Réžia týchto operácií je rádovo zanedbateľná v porovnaní s jedným dopredným a spätným priechodom siete. Z pozorovaní vo WP2 vyplynulo, že počítanie indexu po každej epoche nemalo významný vplyv na priebeh tréningu, a to ani pri súčasnom výpočte viacerých indexov. Integrácia monitorovania do tréningu je teda z hľadiska výkonu prakticky bezplatná, čo je dôležitý predpoklad pre jej nasadenie v reálnom tréningovom cykle.

5. Využitie indexu počas tréningu

Priebežne dostupný index podobnosti otvára niekoľko možností riadenia tréningu, ktoré v statickom (post-kvantizačnom) porovnaní nie sú dostupné:

- **Včasnú ukončenie tréningu:** ak presnosť kvantizovaného modelu počas tréningu nerastie a index sa stabilizoval bez ďalšieho zlepšovania, je možné tréning ukončiť skôr a ušetriť výpočtový čas.
- **Úprava kvantizačných parametrov:** ak je rozdiel medzi rozdeleniami výrazný, je možné zmeniť počet bitov kvantizácie a zopakovať proces s priaznivejším nastavením.
- **Interpretácia degradácie:** výrazne rastúca alebo vysoká divergencia signalizuje degradáciu váh vplyvom kvantizácie, teda nežiaduci dopad kvantizácie na sieť.

Index pritom poskytuje informáciu o rozdieli rozdelení váh, nie priamo o presnosti modelu. Preto sa odporúča sledovať index v kombinácii s presnosťou na testovacej množine, čím sa získa úplnejší obraz o vzťahu medzi zmenou rozdelenia váh a výkonom modelu.

6. Validačné kritériá (WP3.2)

V súlade s cieľom WP3.2 (implementácia štatistických metód do tréningového procesu a validácia voči vopred stanoveným kritériám) navrhuje analýza nasledujúce validačné kritériá pre overenie integrovaného riešenia:

- Prahová hodnota indexu: stanovenie prahu (najmä pre ohraničenú JS divergenciu), pri ktorého prekročení sa rozdelenie považuje za významne odlišné.
- Korelácia indexu s presnosťou: overenie, či vývoj indexu podobnosti zmysluplne súvisí s vývojom presnosti kvantizovaného modelu na testovacej množine.
- Stabilita naprieč epochami: index by sa mal počas tréningu vyvíjať plynulo a reprodukovateľne, bez neopodstatnených skokov.
- Reprodukovateľnosť naprieč datasetmi a architektúrami: overenie konzistentného správania na datasetoch MNIST(alebo modifikácie), CIFAR, s výhľadom na rozsiahlejší dataset (ImageNet) resp. jeho podmnožina.

7. Vstupy pre implementáciu

Z analýzy vyplývajú nasledujúce konkrétne návrhové rozhodnutia, ktoré budú premietnuté do implementácie:

- Použitie uniformnej kvantizácie s voliteľným počtom bitov; vytvorenie a uloženie referenčného rozdelenia váh pred dotrénovaním;
- fixácia hraníc binov pre konzistentné porovnanie; realizácia zobrazovania prostredníctvom triedy typu Keras callback s výpočtom indexu na konci každej epochy;
- podpora metód KL, JS a kosínusovej podobnosti;
- dataset-agnostický návrh s podporou MNIST, CIFAR s možnosťou rozšírenia na ImageNet (alebo subset);
- a výpis indexu podobnosti a presnosti počas tréningu (s popismi grafov v anglickom jazyku). Tak, aby užívateľ mohol sledovať jeho hodnotu.

Uvedený postup môže byť modifikovaný vzhľadom na okolnosti.

8. Záver

Analýza preukázala, že porovnávanie rozdelenia váh je možné integrovať priamo do tréningového procesu kvantizovaného modelu prostredníctvom mechanizmu callbackov, a to s prakticky zanedbateľnou výpočtovou réžiou. Takto získaný index podobnosti poskytuje vývojárovi priebežnú spätnú väzbu o dopade kvantizácie na váhy modelu a umožňuje informované rozhodnutia počas tréningu. Od včasného ukončenia až po úpravu kvantizačných parametrov. Navrhnuté validačné kritériá tvoria rámec (koncept, framework) pre overenie riešenia. Táto analýza je podklad pre implementáciu novej tréningovej stratégie vo výstupe D12 a ďalších výstup.