

D11 - VÝVOJ A IMPLEMENTÁCIA TRÉNINGOVEJ STRATÉGIE

Možnosti riešenia: porovnanie distribúcií a využitie indexu podobnosti



Seminár - implementačné varianty



Ing. Roman Budjač, PhD.

Žilinská univerzita v Žiline (UNIZA)

Projekt 09I03-03-V04-00562 · SAMQ-NN

Kontext a zámer

Seminár v rámci WP3 otvára priestor riešení pre nadchádzajúcu implementáciu (kód D12). Namiesto jediného prístupu predstavujeme a porovnávame viac možností.



Porovnanie distribúcií — Aké štatistické miery použiť na porovnanie rozdelenia váh.



Využitie indexu — Ako z miery spraviť použiteľný signál (granularita, úloha, rozhodovanie).



Granularita kvantizácie — Per-tensor vs per-channel — čo index vlastne „vidí“.



Odporúčaný smer — Výber kombinácie pre D12 s ponechaním rozšírení.

Jadro úlohy

Potrebujeme porovnať rozdelenie váh
referenčného (FP32) a **kvantizovaného** modelu a
premeniť ho na použiteľný signál - index.




Ako porovnávať distribúcie?

Voľba štatistickej miery rozdielu.



Ako využiť index?

Granularita, úloha v tréningu, rozhodovanie.



Metódy porovnania rozdelení



KL divergencia

Asymetrická, citlivá na chvosty; meria informačnú stratu.



JS divergencia

Symetrická, ohraničená $[0,1]$; vhodná na rozhodovanie.



Kosínusová podobnosť

Porovnáva smer váhových vektorov; veľmi lacná.



Wassersteinova vzdialenosť

„Earth-mover“ zvláda aj neprekrývajúce sa rozdelenia.

Porovnanie metrík

Metrika	Ohraničená	Symetrická	Náklady	Vhodné na
KL divergencia	nie	nie	nízke	detekciu informačnej straty
JS divergencia	áno [0,1]	áno	nízke	prahovanie a automatizáciu
Kosínusová podobnosť	áno [-1,1]	áno	veľmi nízke	orientačné porovnanie smeru
Wassersteinova vzdial.	nie	áno	vyššie	geometrické rozdiely

Ako využiť index



Granularita

globálny (celý model)

vs

per-vrstvový (najcitlivejšia vrstva)



Úloha v tréningu

prediktor (pred tréningom — výber bitov)

vs

monitor (počas QAT — po epochách)



Referencia

zmrazená FP32 referencia

vs

epocha-po-epoche (medziepochová zmena)



Rozhodovanie

pevný prah $JS \leq \tau$ (výber hĺbky)

vs

+ včasné ukončenie pri ustálení

Per-tensor vs per-channel

Voľba ovplyvňuje, čo index „vidí“ a ako kvantizácia degraduje hlboké siete.



Per-tensor

jedna škála na celé jadro

- + jednoduché a rýchle
- + menej parametrov škálovania
- pri hlbokých sieťach s odľahlými váhami zlyháva (kolaps presnosti)



Per-channel

vlastná škála na výstupný kanál

- + robustné aj pri nižších bitoch
- + takmer bezstratové pre hlboké siete
- mierne vyššie výpočtové náklady

Odporúčaný smer pre D12



Primárna metrika: JS divergencia (ohraničená, prahovateľná); KL a kosínus potenciál ako doplnkový parameter.



Granularita : globálny aj per-vrstvový — celkový stav aj najcitlivejšia vrstva.



Úloha : prediktor aj monitor — index pred tréningom aj počas QAT.



Kvantizácia : per-channel — robustnosť pre hlboké siete.



Charakterizácia : momenty + entropia + histogramy s konzistentnými hranami.

Ďalšie kroky a diskusia



Implementácia zvoleného smeru ako kód D12, D13.



Overenie na datasetoch a architektúrach (WP4).

Nasleduje diskusia

Ďakujem za pozornosť.

Funded by the EU NextGenerationEU through the Recovery and Resilience Plan for Slovakia under the project No. 09I03-03-V04-00562.