

Výstup D11 · Pracovný balík WP3

Seminár - Správa – Report

Identifikácia projektu:

Názov projektu: Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí

Akronym projektu: SAMQ-NN

Kód projektu: 09I03-03-V04-00562

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

Hlavný riešiteľ: Ing. Roman Budjač, PhD.

Správa zo seminára

Seminár sa konal v rámci pracovného balíka WP3 (Vypracovanie a implementácia stratégie vzdelávania) a zameriaval sa na možné riešenia nadchádzajúcej výzvy. Pozornosť bola zámerne zameraná na dve otázky: ako porovnať rozloženie váh referenčného a kvantizovaného modelu a ako premeniť výsledok na použiteľný signál reprezentovaný jediným indexom podobnosti. Cieľom seminára nebolo predstaviť jediné riešenie, ale predstaviť a porovnať niekoľko možností a na ich základe definovať odporúčaný smer implementácie. Táto správa sumarizuje technické otázky, ktoré boli predmetom prezentácie.

1. Predmet a cieľ seminára

Implementácia v rámci D12 stojí na jadrovej úlohe: porovnať rozdelenie váh plnopresného (FP32) referenčného modelu a jeho kvantizovaného náprotivku a premeniť tento rozdiel na číselný ukazovateľ — index podobnosti. Seminár túto úlohu rozložil na tri rozhodnutia, ku ktorým predstavil alternatívy — voľbu štatistickej miery porovnania, spôsob využitia indexu a granularitu samotnej kvantizácie — a uzavrel ich odporúčanou kombináciou. Takýto prístup umožňuje transparentne zdôvodniť návrh implementácie a ponechať priestor pre budúce rozšírenia.

2. Možnosť A

Prvou možnosťou je voľba miery, ktorou sa porovnávajú histogramy váh postavené na rovnakej mriežke tried. Predstavené boli štyri kandidátske miery. Kullbackova–Leiblerova divergencia je citlivá a neohraničená a dobre odhaľuje informačnú stratu, je však asymetrická. Jensenova–Shannonova divergencia je symetrická a ohraničená na interval $[0, 1]$, a preto je praktická na prahovanie a automatizované rozhodovanie. Kosínusová podobnosť porovnáva celkový smer rozdelení a je výpočtovým zaťažením je veľmi priaznivá. Wassersteinova vzdialenosť pristupuje k rozdielu geometricky a zvláda aj rozdelenia, ktoré sa neprekrývajú. Ako primárna sa odporúča JS divergencia práve pre jej ohraničenosť a symetriu. Na doplnkovú charakterizáciu tvaru rozdelenia slúžia distribučné momenty a entropia.

3. Možnosť B

Druhým rozhodnutím je spôsob, akým sa index využije v praxi; seminár ho rozobral zo štyroch aspektov. Z hľadiska granularity možno počítať globálny index nad váhami celého modelu, alebo per-layer index, ktorý odhalí najcitlivejšiu vrstvu. Z hľadiska úlohy v tréningu môže index slúžiť ako prediktor pred tréningom (na výber bitovej hĺbky), alebo ako monitor počas tréningu (vyhodnocovaný po epochách). Z hľadiska referencie sa rozdelenie váh môže porovnávať voči zmrazenej FP32 referencii, prípadne medzi po sebe idúcimi epochami. A napokon, z hľadiska rozhodovania sa dá použiť pevný prah (napríklad $JS \leq \tau$) na výber hĺbky a včasné ukončenie tréningu pri ustálení indexu.

4. Možnosť C

Tretím rozhodnutím je granularita samotnej kvantizácie, ktorá ovplyvňuje aj to, čo index dokáže zachytiť. Per-tenor kvantizácia používa jednu spoločnú škálu pre celé jadro vrstvy; je jednoduchá a rýchla, no pri hlbokých sieťach s odľahlými hodnotami váh môže viesť ku kolapsu presnosti. Per-channel kvantizácia priradzuje samostatnú škálu každému výstupnému kanálu; za cenu mierne vyšších výpočtových nárokov je výrazne robustnejšia a pri hlbokých sieťach. Voľba granularity preto nie je len technický detail, ale podstatne mení správanie celého reťazca.

5. Odporúčaný smer pre D12

Na základe porovnania variantov na seminári bolo vymedzené odporúčanie kombináciu pre implementáciu D12:

- ako primárnu mieru použiť JS divergenciu (s KL divergenciou a kosínusovou podobnosťou ako doplnkovými), počítať index globálne aj po vrstvách, využívať ho v oboch úlohách ako prediktor aj ako monitor a kvantizovať per-channel kvôli robustnosti pri hlbokých sieťach.
- ostatné možnosti ako Wassersteinova vzdialenosť, medziepochová referencia a monitorovanie aktivácií ostávajú ako otvorené možnosti pre ďalší výskum a vývoj.

6. Ďalšie kroky

V nadväznosti na seminár bude zvolený smer implementovaný ako kód D12 a následne overený na rôznych datasetoch a architektúrach. Priebežné vyhodnotenie umožní podľa potreby zaradiť niektoré z navrhnutých rozšírení.

7. Záver

Seminár naplnil svoj cieľ. namiesto jediného riešenia prehľadne predstavil a porovnal možnosti pre porovnávanie rozdelení a využitie indexu a na ich základe vymedzil jasný a zdôvodnený smer pre implementáciu. Stretnutie tak vytvorilo ucelený základ pre implementačnú fázu projektu.

Ing. Roman Budjač, PhD.