

Výstup D13 · Pracovný balík WP4

Overenie navrhnutého konceptu

Správa, report k experimentálnemu preukázaniu

Identifikácia projektu:

Názov projektu: Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí

Akronym projektu: SAMQ-NN

Kód projektu: 09I03-03-V04-00562

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

Hlavný riešiteľ: Ing. Roman Budjač, PhD.

Zhrnutie

Výstup D13 experimentálne preukazuje koncept monitorovania kvantizácie pomocou štatistického indexu podobnosti rozdelenia váh, navrhnutý vo výstupe D12. Na štyroch malých datasetoch (digits, Fashion-MNIST, MNIST, CIFAR-10) aj na veľkých predtrénovaných modeloch (MobileNetV2 a ResNet50 vyhodnotené na ImageNet-V2) sa potvrdilo, že index monotónne sleduje tvrdosť kvantizácie ($\rho \approx -0,98$), predpovedá pokles presnosti a je počas QAT stabilný aj reprodukovateľný naprieč datasetmi a architektúrami. Všetky štyri validačné kritériá stanovené v D10 sú splnené a samotná kvantizácia prináša reálnu úsporu veľkosti modelu (8-bit približne $4\times$ pri prakticky bezstratovej presnosti). Súčasne je podozrevanie pomenované kľúčové obmedzenie: globálny váhový index nezachytí degradáciu, ktorá sa neprejaví v rozdelení váh (MobileNetV2 pri 4-bit). Tým je naplnené Objective 6, t. j. koncept je dokázaný na štandardných datasetoch a vyhodnotený voči FP32 referencii aj voči kritériám z D10.

1. Cieľ a kontext

Výstup D13 experimentálne preukazuje koncept implementovaný vo výstupe **D12**: monitorovanie kvantizácie neurónovej siete pomocou štatistického indexu podobnosti rozdelenia váh (Jensenova-Shannonova divergencia medzi rozdelením váh kvantizovaného a plnopresného modelu). Notebook priamo napĺňa **Objective 6** („Prove the concept on standard datasets and evaluate results and potential benefits and limitations of the proposed solution“). Overenie prebieha na štandardných datasetoch, voči štyrom validačným kritériám stanoveným v **D10** a voči plnopresnej (FP32) referencii.

2. Metóda a rozsah overenia

- **Index:** JS divergencia medzi rozdelením váh kvantizovaného a FP32 modelu, kvantizácia je per-channel (vlastná škála na výstupný kanál).
- **Malé modely:** digits, Fashion-MNIST, MNIST a CIFAR-10, každý cez 5 nezávislých inicializácií (seedov).
- **Veľké modely:** MobileNetV2 a ResNet50 predtrénované na ImageNete, vyhodnotené na validačnej podmnožine ImageNet-V2 (~5 000 obrázkov).
- **Rozsah:** bitové hĺbky 2, 4, 8, 16 a 32; post-tréningová kvantizácia (PTQ) aj dynamika počas skutočného QAT.

3. Výsledky a validácia voči kritériám z D10

Všetky štyri kritériá z D10 sú na získaných dátach splnené:

Validačné kritérium (D10)	Stav	Kľúčový údaj z merania
1. Prahová hodnota indexu ($\tau = 0,01$)	splnené	Index ostáva nízky práve pri ≥ 8 bitoch (zachovaná presnosť); JS pri 8 b $\approx 0,000$
2. Korelácia indexu s presnosťou	splnené	$\rho(\text{bity}, \text{JS}) = -0,98$ naprieč datasetmi; vyšší index zodpovedá nižšej presnosti aj vyššej chybe
3. Stabilita počas epoch (QAT)	splnené	Smerodajná odchýlka indexu cez epochy $\leq 0,003$; váhy ostávajú reálne kvantizované
4. Reprodukovateľnosť	splnené	Rovnaké správanie na 4 malých datasetoch aj na MobileNetV2 a ResNet50 (ImageNet-V2)

Efektívnosť a kompresia (vyčíslené trojako):

- Teoreticky: 16-bit = $2\times$, 8-bit = $4\times$, 4-bit = $8\times$ menší model; 8-bit pri prakticky bezstratovej presnosti.
- Reálny int8/TFLite export malého modelu: 57,9 kB $\rightarrow$ 21,5 kB ($2,70\times$); pri väčších modeloch sa pomer blíži k teoretickým $4\times$.
- Latencia (CPU, 1 vzorka): FP32 = 0,004 ms vs INT8 = 0,007 ms. Na bežnom CPU sa INT8 nezrýchli (réžiu vyrovná optimalizovaný FP32); výrazné zrýchlenie prináša až hardvér s INT8 akceleráciou (mobilné a hranové NPU).
- ImageNet: ResNet50 pri 8-bit prakticky bezstratový (top-1 0,562 vs FP32 0,563); MobileNetV2 pri 4-bit kolabuje (top-1 0,002).

4. Prínosy a obmedzenia

Prínosy. Index je lacný (réžia zanedbateľná voči jednému priechodu siete) a počíta sa priebežne počas tréningu; je dataset-agnostický a nezávislý od konkrétnej metriky (KL/JS/kosínus sú silne

korelované); funguje ako prediktor (výber bitovej hĺbky pred tréningom) aj ako monitor (stabilný počas QAT). Per-vrstvový rozklad identifikuje najcitlivejšie vrstvy (prvá konvolúcia a výstupná vrstva), čo otvára cestu k zmiešanej presnosti.

Obmedzenie (pochivo pomenované). Globálny váhový index nezachytí degradáciu, ktorá sa neprejaví v rozdelení váh: MobileNetV2 pri 4-bit kolabuje, no globálna JS ostáva mizivá ($\approx 1e-4$). To vymedzuje smer ďalšej práce, t. j. dopĺňajúce monitorovanie na úrovni vrstiev a aktivácií. Prah indexu je navyše potrebné kalibrovať empiricky pre danú architektúru, preto sa odporúča sledovať ho spolu s presnosťou.

5. Záver

Experimenty potvrdzujú navrhnutý koncept: štatistický index podobnosti monotónne sleduje tvrdosť kvantizácie ($\rho \approx -0,98$ naprieč malými datasetmi, $-1,00$ pri ImageNete), predpovedá pokles presnosti, je počas QAT stabilný a reprodukovateľný naprieč datasetmi aj architektúrami, pričom samotná kvantizácia prináša reálnu úsporu veľkosti modelu. Tým je naplnené Objective 6: koncept je dokázaný na štandardných datasetoch a vyhodnotený voči FP32 baseline aj voči kritériám z D10. Výsledky tvoria priamy podklad pre písomné zhrnutie (D15) a záverečnú správu (D17). Úplné merania, grafy a zdrojový kód sú v sprievodnom notebooku D13.