

WP4 — PROVING THE PROPOSED CONCEPT



# A Statistical Approach to Monitor Quantisation in Neural Network Training

*Seminár č. 4 — implementácia a overenie konceptu*



**Ing. Roman Budjač, PhD.**

Žilinská univerzita v Žiline (UNIZA)

Projekt 09I03-03-V04-00562 · SAMQ-NN

# Harmonogram



Zhrnutie spracovaných úloh a výstupov projektu



Predstavenie konceptu: štatistický index podobnosti



Implementácia — jadro kódu a tréningová stratégia



Experimentálne overenie konceptu (WP4)



Zistenia, obmedzenia a ďalšie kroky



Diskusia

# Ciele seminára



**Predstaviť koncept** — Monitorovanie kvantizácie štatistickými metrikami (KL, JS divergencia).



**Vysvetliť jadro kódu** — Charakterizácia, PTQ, skutočné QAT a per-channel kvantizácia.



**Predstaviť stratégiu** — Nová tréningová stratégia riadená indexom podobnosti.



**Doložiť overenie** — Experimenty naprieč datasetmi a architektúrami (WP4).




**Otvoriť diskusiu** — Výsledky a ďalšie smerovanie — záverečná správa D17.

# Východisko: prečo monitorovať kvantizáciu

**Kvantizácia** znižuje váhy siete na menej bitov — šetrí pamäť a výpočet, ale môže zhoršiť presnosť.

- Váhy sa „prichytia“ na mriežku  $2^b$  úrovní namiesto spojitých hodnôt.
- Otázka projektu: vieme štatisticky sledovať vplyv kvantizácie na rozdelenie váh už počas tréningu?
- Cieľ: lacný, interpretovateľný ukazovateľ degradácie.




# Štatistický index podobnosti

**Index = divergencia** medzi rozdelením váh referenčného (FP32) modelu **P** a kvantizovaného modelu **Q**.

- **KL divergencia** — citlivá, neohraničená — detekuje informačnú stratu.
- **JS divergencia** — ohraničená  $[0,1]$ , symetrická — vhodná na prahovanie (predvolená).
- **Kosínusová podobnosť** — orientačné porovnanie celkového smeru rozdelení.

„Teplomer tvaru rozdelenia váh.“



# Ako sa index počíta



**Globálny index** sleduje celý model; **per-vrstvový index** odhalí, ktorá vrstva je na kvantizáciu najcitlivejšia.

# Implementácia: jadro zdrojového kódu



## Charakterizácia váh

Momenty, Shannonova/diferenciálna entropia, histogramy s konzistentnými hranami.



## Post-tréningová kvantizácia

`quantize_array` — prichytenie váh na mriežku  $2^b$  úrovní (per-channel).



## Skutočné QAT (STE)

`QuantConv2D` / `QuantDense` — dopredu kvantizované váhy, gradient cez STE.



## Per-channel kvantizácia

Vlastná min-max škála na výstupný kanál — robustné aj pre hlboké siete.

# Nová tréningová stratégia (SMT)



## SimilarityMonitor

index po každej epoche — naživo



## IndexEarlyStopping

ukončí pri ustálení indexu a presnosti



## auto\_select\_bitwidth

najnižšia hĺbka s  $JS \leq$  prah





## Skutočné QAT riadené indexom podobnosti

tri komponenty spojené do jednej tréningovej procedúry



# Citlivosť na bitovú hĺbku



Statistical similarity index across datasets (3 seeds, mean  $\pm$  std)



Index sleduje tvrdosť kvantizácie takmer dokonale ( $\rho \approx -0,99$ ) a predpovedá pokles presnosti naprieč tromi datasetmi rôznej náročnosti.

# Dynamika počas QAT



In-training dynamics during real 4-bit QAT (3 seeds, mean  $\pm$  std)



Počas QAT index stabilne drží na úrovni danej bitovej hĺbky (**váhy ostávajú reálne kvantizované**), kým presnosť sa udržiava, resp. obnovuje voči naivnému PTQ.

# Generalizácia na ImageNet

ImageNet (imagenet\_v2 subset): accuracy collapse vs weight-distribution index



MobileNetV2 potvrdzuje vzorec; ResNet50 odhalil krehkosť naivnej per-tensor kvantizácie pri hlbokých sieťach — **riešené per-channel kvantizáciou.**

# Zistenia a obmedzenia



## Zistenia

- Index funguje ako prediktor (pred tréningom) aj monitor (počas tréningu).
- Dataset-agnostický — overené na troch datasetoch.
- Nezávislý od voľby metriky (KL/JS/kosínus  $|p| \approx 0,99$ ).
- Integrovaný priamo do tréningovej stratégie.



## Obmedzenia

- Menšie modely a obmedzený počet inicializácií.
- Per-channel kvantizácia je nutná pre hlboké siete.
- Globálny index nevidí aktivačne riadenú degradáciu (ResNet50 pri 8-bit).

→ *motivácia per-layer a aktivačného monitorovania.*

# Ďalšie kroky a diskusia



Dokončenie výstupov WP3 + WP4 a záverečnej správy projektu (D17).



Budúca práca: per-layer a aktivačné monitorovanie, principiálna zmiešaná presnosť.



Väčšie modely, viac inicializácií, reálny int8 / TFLite export.

---

## Diskusia

*Ďakujem za pozornosť.*

