

Výstup D14 · Pracovný balík WP4

Seminár — Správa

Správa zo seminára (WP4 overenie navrhnutého konceptu)

Seminár sa konal v rámci pracovného balíka WP4 „Overenie navrhnutého konceptu“ (*Proving the proposed concept*) a jeho predmetom bolo predstavenie implementovaného konceptu štatistického monitorovania kvantizácie neurónových sietí spolu s jeho experimentálnym overením. Cieľom stretnutia bolo zhrnúť dosiahnutý stav riešenia, od teoretického základu cez jadro zdrojového kódu a navrhnutú tréningovú stratégiu až po výsledky experimentov, a vymedziť ďalšie kroky vedúce k záverečnej správe projektu. Táto správa zhŕňa odbornú problematiku, ktorá bola predmetom prezentácie.

1. Východisko a problematika

Kvantizácia neurónových sietí znižuje počet bitov, ktorými sú reprezentované váhy modelu. Prináša tým výraznú úsporu pamäte a výpočtových nárokov, čo je kľúčové pre nasadenie modelov na zariadeniach s obmedzenými zdrojmi, no súčasne môže zhoršiť presnosť modelu. Zásadným problémom je, že štandardné metriky ako presnosť a chybová funkcia ukazujú až výsledný dopad kompresie, nie jeho príčinu, a neumožňujú sledovať, čo sa s modelom deje na úrovni rozdelenia jeho váh. Ústrednou otázkou projektu preto je, či sa dá vplyv kvantizácie na rozdelenie váh sledovať štatisticky a priebežne — už počas tréningu — a získať tak lacný a interpretovateľný ukazovateľ degradácie.

2. Štatistický index podobnosti

Jadrom navrhnutého konceptu je štatistický index podobnosti, ktorý kvantifikuje rozdiel medzi rozdelením váh referenčného (plného, FP32) modelu a modelu kvantizovaného. Na meranie tohto rozdielu sa využívajú tri štatistické miery: Kullbackova–Leiblerova divergencia, ktorá je citlivá a neohraničená a dobre odhaľuje informačnú stratu; Jensenova–Shannonova divergencia, ktorá je symetrická a ohraničená na interval $[0, 1]$, a preto je vhodná na automatizované rozhodovanie a prahovanie (v implementácii je predvolená); a kosínusová podobnosť, ktorá poskytuje orientačné porovnanie celkového smeru rozdelení. Index možno počítať globálne (nad váhami celého modelu) alebo po jednotlivých vrstvách, čím sa dá identifikovať vrstva najcitlivejšia na kvantizáciu. Index tak funguje ako „teplomer“ tvaru rozdelenia váh — čím vyšší je, tým väčšími sa kvantizované váhy odchýlili od pôvodných.

3. Implementácia — jadro zdrojového kódu

Prezentované bolo jadro zdrojového kódu, ktoré tvorí štyri vzájomne prepojené časti. Prvou je charakterizácia váh prostredníctvom distribučných momentov, Shannonovej a diferenciálnej entropie a histogramov s konzistentnými hranami tried, čo umožňuje porovnateľné merania. Druhou je post-tréningová kvantizácia, ktorá váhy „prichytí“ na mriežku $2b$ úrovní. Treťou je skutočný kvantizačne uvedomelý tréning (QAT), pri ktorom sa v doprednom priechode používajú kvantizované váhy a gradient sa prenáša cez tzv. straight-through estimator; realizujú ho vlastné vrstvy QuantConv2D a QuantDense. Štvrtou — a z hľadiska robustnosti kľúčovou — je per-channel kvantizácia, ktorá priradzuje samostatnú škálu každému výstupnému kanálu namiesto jednej škály pre celé jadro. Práve tento prístup je nevyhnutný pre hlboké siete, kde naivná per-tensor kvantizácia zlyháva.

4. Nová tréningová stratégia

Výstupom riešenia je nová tréningová stratégia, ktorá štatistický index integruje priamo do procesu skutočného QAT a využíva ho na riadenie tréningu. Stratégia stojí na troch komponentoch. Monitorovací komponent po každej epoche vypočíta hodnotu indexu a zobrazuje ju naživo, takže vývoj kvantizačného stavu je priebežne viditeľný. Komponent včasného ukončenia zastaví tréning vo chvíli, keď sa index aj presnosť ustália, čím šetrí výpočtové zdroje. Komponent automatického výberu bitovej hĺbky zvolí najnižšiu hĺbku, pri ktorej index zostáva pod stanoveným prahom. Tieto komponenty sa spájajú do jednej tréningovej procedúry.

5. Experimentálne overenie konceptu

Ťažiskom seminára bolo experimentálne overenie, ktoré tvorí podstatu pracovného balíka WP4. Analýza citlivosti na bitovú hĺbku ukázala, že index takmer dokonale monotónne sleduje tvrdosť kvantizácie a predpovedá pokles presnosti, a to zhodne naprieč tromi datasetmi rôznej náročnosti. Sledovanie dynamiky počas QAT preukázalo, že index počas celého tréningu stabilne drží na úrovni zodpovedajúcej danej bitovej hĺbke, čo dokazuje, že váhy zostávajú skutočne kvantizované a tréning ich „nevracia“ späť do plnej presnosti, kým samotná presnosť sa udržiava, resp. obnovuje voči naivnej post-tréningovej kvantizácii.

Generalizácia na veľké modely (ImageNet) priniesla aj dôležité a poctivo prezentované zistenie o hraniciach metódy. Zatiaľ čo architektúra MobileNetV2 potvrdila očakávaný vzorec, architektúra ResNet50 odhalila krehkosť naivnej per-tensor kvantizácie pri hlbokých sieťach: pokles presnosti nastal už pri vyššej bitovej hĺbke, pričom globálny index váh ho nezachytil, lebo degradácia nemala pôvod v tvare rozdelenia váh. Toto zistenie priamo motivovalo prechod na per-channel kvantizáciu a poukazuje na potrebu dopĺňajúceho monitorovania na úrovni vrstiev a aktivácií.

6. Zistenia a obmedzenia

Z prezentovaných výsledkov vyplýva, že štatistický index funguje v dvoch režimoch — pred tréningom ako prediktor závažnosti kvantizácie a počas tréningu ako jej stabilný monitor — a je pritom nezávislý od konkrétneho datasetu aj od voľby metriky. Súčasne boli korektne pomenované obmedzenia: experimenty sa opierajú o menšie modely a obmedzený počet inicializácií, per-channel kvantizácia je nevyhnutná pre hlboké siete a globálny index nedokáže zachytiť degradáciu, ktorá je riadená aktiváciami a neprejaví sa v rozdelení váh. Tieto obmedzenia vymedzujú smer ďalšieho výskumu.

7. Ďalšie kroky

V nadväznosti na seminár bude riešenie pokračovať dokončením výstupov pracovných balíkov prípravou záverečnej správy projektu (D17). Ako ďalšie smerovanie boli identifikované monitorovanie na úrovni jednotlivých vrstiev a aktivácií, principiálne navrhnutá zmiešaná presnosť, overenie na väčších modeloch s vyšším počtom inicializácií a reálny celočíselný (int8 / TFLite) export modelov.

Záver

Seminár naplnil svoj cieľ, predstavil implementovaný koncept štatistického monitorovania kvantizácie a doložil ho experimentálnym overením, vrátane poctivého pomenovania hraníc

metódy. Stretnutie tak vytvorilo ucelený a podložený základ pre záverečnú fázu projektu a pre spracovanie záverečnej správy.

Ing. Roman Budjač, PhD.