



Financovaný
Európskou úniou
NextGenerationEU

PLÁN [OBNOVY]



ÚRAD PODPREDESEDU VLÁDY
SLOVENSKEJ REPUBLIKY
PRE PLÁN OBNOVY
A ZNALOSTNÚ EKONOMIKU



VÝSKUMNÁ
AGENTÚRA

SAMQNN · PRACOVNÝ BALÍK WP4 · VÝSTUP D15

Štatistický prístup k monitorovaniu kvantizácie neurónových sietí

Monitorovanie kvantizácie počas tréningu cez štatistický index podobnosti rozdelenia váh

Ing. Roman Budjač, PhD.

Projekt 09I03-03-V04-00562 · Plán obnovy a odolnosti SR · Komponent 9, Excelentná veda

1 Kontext a cieľ

- Kvantizácia znižuje pamäťové a výpočtové nároky modelu reprezentáciou váh v nižšej bitovej presnosti než štandardný 32-bitový formát.
- Táto úspora však môže byť vykúpená poklesom presnosti — preto je dôležité dokázať sledovať kvalitu kvantizácie a jej dopad.
- Náš prístup: monitorovať mieru, do akej sa rozdelenie váh kvantizovaného modelu odkláňa od plnopresného (FP32) modelu.
- WP3 prístup implementoval ako novú tréningovú stratégiu; WP4 ho experimentálne overuje.

4×

kompresia pri 8 bitoch

≈ 0


strata presnosti (8-bit)

Prečo štatisticky?

- Rozdelenie váh je priamo to, čo kvantizácia mení.
- Index sa dá počítať priebežne počas tréningu, lacno.
- Funguje ako signál včasného varovania, nie len dodatočný ukazovateľ.

2 Navrhnutá metóda

- Index podobnosti medzi referenčným rozdelením váh FP32 a aktuálnym rozdelením kvantizovaného modelu.
- Primárna metóda: Jensenova–Shannonova divergencia: symetrická, ohraničená na $[0,1]$, vhodná na prahovanie.
- Dopĺňa ju Kullbackova–Leiblerova divergencia a kosínusová podobnosť (miery sú silnekorelované).
- Histogramy na vopred zafixovaných hraniciach tried → konzistentné porovnanie počas celého tréningu.
- Kvantizácia po kanáloch (per-channel), index globálne aj po vrstvách.
- Počíta sa priebežne cez vlastný Keras callback na konci každej epochy.



Obr. 1 Index podobnosti počítaný priebežne počas tréningu cez Keras callback.

3 Spôsob overenia

Dataseť

digits · Fashion-MNIST · MNIST · CIFAR-10 · validačná podmnožina ImageNet-V2

Architektúry

malá konvolučná sieť → predtrénované MobileNetV2 a ResNet50

Metriky

presnosť top-1 (pri ImageNet-V2 aj top-5) a chybová funkcia (loss) vs FP32

4 kritériá z D10

prah indexu · korelácia s presnosťou · stabilita počas epoch · reprodukovateľnosť

4 Index verne sleduje kvantizáciu

-0,98 / -1,00

$\rho(\text{bity}, \text{JS})$: monotónny vzťah

8-bit

prakticky bezstratovo (vrátane ResNet50)


2-bit

kolaps presnosti

Hlavné pozorovania

- Spearmanova korelácia medzi bitovou hĺbkou a JS divergenciou je naprieč datasetmi $\approx -0,99$ (na ImageNete $-1,00$).
- Pri 8 bitoch ostáva presnosť prakticky nezmenená pri štvornásobnej kompresii — vrátane veľkých modelov.
- Počas kvantizačne uvedomelého tréningu je index stabilný — váhy ostávajú reálne kvantizované.
- Analýza po vrstvách: najcitlivejšie sú prvá konvolučná a výstupná vrstva.

5 Kompromis kompresia – presnosť



Obr. 2 Os x: kompresný pomer váhovej pamäte (32/bity, log). Os y: absolútna top-1 presnosť. Pásma okolo 8 bitov je „sweet spot“.

Pásma okolo štvornásobnej kompresie (8 bitov) je takmer bez straty presnosti naprieč modelmi.

6 Index ako signál včasného varovania

Bitová hĺbka	Priemerný pokles top-1	Nárast loss (×FP32)	Priemerný index (JS)	Kompresia
8	0,0 %	1,00×	0,0001	4×
4	-1,7 %	1,11×	0,0819	8×
2	-63,5 %	20,33×	0,6322	16×

- Do 8 bitov index aj presnosť ostávajú nezmenené — štvornásobná kompresia takmer zadarmo.
- Pri 4 bitoch index citeľne narastie, kým presnosť klesne len mierne ($\approx 1,7\%$) — index sa dvíha skôr než degradácia.
- Pri 2 bitoch nastáva kolaps. Práve tento nelineárny predstih robí z indexu signál včasného varovania.

7 Validácia indexu

- Optimálnu bitovú hĺbku neurčuje index, vyplýva z priameho merania presnosti a zavedenej praxe (8 bitov $\approx$ bezstratovo).
- Tento nezávisle známy fakt slúži ako kritérium na overenie indexu.
- Index ostáva pod prahom práve tam, kde je presnosť zachovaná (≥ 8 bitov), a narastá tam, kde klesá (≤ 4 bity).
- Zhoda s referenčným správaním potvrdzuje, že index je použiteľný proxy ukazovateľ kvality kvantizácie.

⚠ Hranica platnosti

- Pri MobileNetV2 (4-bit) váhový index nezachytí kolaps presnosti.
- Degradácia pochádza mimo rozdelenia váh — na úrovni aktivácií.
- Index je spoľahlivý pre testovanú rodinu modelov; prah aj vypovedacia schopnosť (váhy vs aktivácie) sa musia kalibrovať pre danú architektúru.

Vol'ba bitovej hĺbky: 6 vs 8 bitov


6 bitov ako analytické optimum

- Stratégia pri minimalizácii bitov prirodzene volí ≈ 6 bitov.
- Index hlboko pod prahom ($JS \approx 0,001$), presnosť zachovaná.
- Naprieč testovanými datasetmi takmer bezstratové.
- Najúspornejšia voľba bola kompresia 5,33x.

8 bitov ako praktický štandard

- Odporúčaná cieľ pre nasadenie (INT8).
- Celočíselný hardvér ho podporuje natívne: mobilné a hranové NPU, INT8 akcelerátory, jadrá TFLite/ONNX.
- 6 bitov sa nepoužíva v HW-natívnych t.j v praxi by sa aj tak ukladalo do 8 bitov.
- Metóda ponúka oboje: optimum aj nasaditeľný štandard.

9 Stratégia: SMT vs baseline



Obr. 3 SMT (auto ≈ 6 bitov + včasné ukončenie) vs fixný 8-bit baseline pri rovnakom strope epoch.

- SMT pre každý dataset automaticky zvolí bitovú hĺbku podľa prahu indexu a sleduje per-vrstvový index.
- Naprieč všetkými 4 datasetmi volí ≈ 6 bitov ($5,33\times$), prekonáva 8-bit baseline ($4\times$) v úspore pamäte.
- Presnosť ostáva porovnateľná s baseline (rozdiely v rámci šumu), 6 bitov je prakticky bezstratových.
- Včasné ukončenie sa spustilo na 3 zo 4 datasetov $\rightarrow$ výrazná úspora tréningových epoch.

10 Včasné ukončenie ako detektor ustálenia indexu

- Mechanizmus zastaví tréning, keď sa per-vrstvový index ustáli, keď sa rozdelenie váh prestane meniť.
- Bezpečnostná vlastnosť: spustí sa iba pri ustálení, takže nikdy nezastaví predčasne. Ak sa nespustí, tréning len dobehne strop.
- Na plnom behu sa index ustálil rýchlo a ušetril podstatnú časť tréningu bez straty presnosti.
- Epochu ustálenia uvádzame ako mieru rýchlosti dosiahnutia kvantizačnej stability, nie ako zlyhanie.

4–5

epoch (digits, Fashion,
CIFAR)

30

MNIST — dobehol strop

Odporúčané použitie

- Spolu so stropom epoch.
- Spolu s kontrolou presnosti.
- Nie ako jediné kritérium ukončenia.

11 Prínosy a obmedzenia

Prínosy

- Výpočtovo lacný, réžia zanedbateľná voči jednému priechodu siete.
- Dataset-agnostický a nezávislý od voľby metriky.
- Dva režimy: prediktor (výber bitov pred tréningom) a monitor (počas tréningu, vrátane včasného ukončenia).
- Per-channel kvantizácia → robustný na hlbokých sieťach.

Obmedzenia

- Váhový index nezachytí degradáciu mimo rozdelenia váh (MobileNetV2 4-bit → aktivácie).
- Prahová hodnota je architektúrne závislá, treba kalibrovať.
- Odporúča sa sledovať index spoločne s presnosťou.
- ImageNet overený na validačnej podmnožine V2.

Záver a ďalšie smerovanie

Štatistický index podobnosti je použiteľný a nenákladný nástroj na monitorovanie kvantizácie priamo počas tréningu. Spĺňa kritériá z D10 a napĺňa Objective 6, koncept dokázaný na štandardných datasetoch, vyhodnotený voči FP32 aj kritériám z D10.

Ďalšie smerovanie

- Rozšírenie monitorovania z váh aj na aktivácie.
- Stratégia zmiešanej presnosti riadená per-vrstvovým indexom.
- Dôkladnejšia kalibrácia prahových hodnôt.

Výsledky tvoria podklad pre pripravovanú vedeckú publikáciu (D16) a záverečnú správu projektu (D17).