

Výstup D15 · Pracovný balík WP4

Písomné zhrnutie výskumu

Identifikácia projektu:

Názov projektu: Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí

Akronym projektu: SAMQNN

Kód projektu: 09I03-03-V04-00562

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

Hlavný riešiteľ: Ing. Roman Budjač, PhD.

Písomné zhrnutie výskumu

Tento dokument je výstupom D15 pracovného balíka WP4 projektu SAMQ-NN a predstavuje súvislé písomné zhrnutie finalizovanej metódy a výsledkov výskumu. Na rozdiel od výstupu D13, ktorý prináša technický dôkaz konceptu vo forme kódu a experimentálnych grafov, tento dokument podáva metódu a jej overenie čitateľnou prózou, zrozumiteľnou aj bez priameho prístupu k implementácii. Cieľom je zhrnúť, čo bolo navrhnuté, ako sa to overilo a aké sú prínosy a obmedzenia výsledného riešenia.


1. Úvod a kontext

Kvantizácia neurónových sietí znižuje pamäťové a výpočtové nároky modelu tým, že váhy reprezentuje s nižšou bitovou presnosťou než štandardný 32-bitový pohyblivý formát. Táto úspora však môže byť vykúpená poklesom presnosti, a preto je dôležité dokázať sledovať kvalitu kvantizácie a jej dopad na model. Projekt SAMQ-NN navrhuje na tento účel štatistický prístup: monitorovať mieru, do akej sa rozdelenie váh kvantizovaného modelu odkláňa od rozdelenia pôvodného, plnopresného modelu. Pracovný balík WP3 tento prístup implementoval ako novú tréningovú stratégiu a pracovný balík WP4 ho experimentálne overuje. Toto zhrnutie nadväzuje na uvedené práce a uzatvára ich do uceleného obrazu.

2. Navrhnutá metóda

Jadrom metódy je index podobnosti medzi referenčným rozdelením váh plnopresného (FP32) modelu a aktuálnym rozdelením váh kvantizovaného modelu. Obe rozdelenia sa reprezentujú histogramami postavenými na rovnakých, vopred zafixovaných hraniciach tried, a porovnávajú sa štatistickými mierami. Ako primárna sa používa Jensenova–Shannonova divergencia, ktorá je symetrická a ohraničená na interval od nuly po jednotku, a preto je vhodná na prahovanie a automatizované rozhodovanie. Dopĺňa ju Kullbackova–Leiblerova divergencia, citlivá na informačnú stratu, a kosínusová podobnosť, ktorá zachytáva orientáciu váhových vektorov; ako rozšírenie je k dispozícii aj Wassersteinova vzdialenosť.

Index sa nepočíta až po dokončení kvantizácie, ale priebežne počas tréningu, prostredníctvom vlastnej triedy typu callback vo frameworku Keras, ktorá sa spúšťa na konci každej epochy. Referenčné rozdelenie aj hranice tried ostávajú počas celého tréningu nezmenené, čím je každé porovnanie konzistentné. Kvantizácia sa vykonáva po jednotlivých výstupných kanáloch (per-channel), čo sa ukázalo ako nevyhnutné pre robustnosť hlbokých sietí. Index možno vyhodnocovať globálne nad váhami celého modelu, alebo po jednotlivých vrstvách, čím sa odhalí najcitlivejšia vrstva.



Obr. 1 Schéma metódy: index podobnosti medzi rozdelením váh FP32 a kvantizovaného modelu, počítaný priebežne počas tréningu cez Keras callback.

3. Spôsob overenia


Metóda bola overená na štandardných benchmarkových datasetoch — digits, Fashion-MNIST, MNIST, CIFAR-10 a validačnej podmnožine ImageNet-V2 — na architektúrach siahajúcich od malej konvolučnej siete až po predtrénované modely MobileNetV2 a ResNet50. Pri vyhodnotení sa sledovala presnosť (top-1, pri ImageNet-V2 aj top-5) a hodnota chybovej funkcie (loss) v porovnaní s plnopresnou referenciou, a vývoj indexu voči štyrom validačným kritériám stanoveným vo výstupe D10: stanovenie prahovej hodnoty indexu, korelácia indexu s presnosťou, stabilita indexu naprieč epochami a reprodukovateľnosť správania naprieč datasetmi a architektúrami.

4. Hlavné výsledky

Experimenty potvrdili navrhnutý koncept. Index monotónne sleduje tvrdosť kvantizácie — Spearmanova poradová korelácia medzi bitovou hĺbkou a Jensenovou–Shannonovou divergenciou dosahuje naprieč datasetmi približne mínus 0,99. Pri osembitovej kvantizácii ostáva presnosť prakticky bezstratová, a to vrátane modelu ResNet50 na datasete ImageNet, zatiaľ čo agresívna dvojbitová kvantizácia presnosť výrazne zhoršuje. Počas kvantizačne uvedomelého tréningu je index stabilný, s malou smerodajnou odchýlkou naprieč epochami, čo potvrdzuje, že váhy ostávajú reálne kvantizované a tréning ich nevracia do plnej presnosti.

Analýza po vrstvách identifikovala prvú konvolučnú a výstupnú vrstvu ako najcitlivejšie na kvantizáciu.

Samotná kvantizácia prináša reálnu úsporu prostriedkov: teoretický kompresný pomer dosahuje štvornásobok pri ôsmich bitoch a osemnásobok pri štyroch bitoch v porovnaní s plnopresným modelom, čo potvrdil aj reálny export modelu do celočíselného (int8) formátu. Dôležitým zistením je, že vzťah medzi indexom a presnosťou je nelineárny: index reaguje na zmenu rozdelenia váh skôr, než sa prejaví pokles presnosti, čo z neho robí signál včasného varovania a nie iba dodatočný ukazovateľ.



Obr. 2 Kompromis medzi kompresiou a presnosťou naprieč modelmi (digits, Fashion-MNIST, MNIST, CIFAR-10, MobileNetV2, ResNet50). Os x je kompresný pomer váhovej pamäte (32/bity, log), os y absolútna top-1 presnosť. Pásmo okolo štvornásobnej kompresie (8 bitov) je „sweet spot“ — takmer bez straty presnosti.

Validácia indexu. Optimálnu bitovú hĺbku neurčuje index — vyplýva z priameho merania presnosti a je v súlade so zavedenou praxou: osembitová kvantizácia je takmer bezstratová pri štvornásobnej kompresii. Práve tento nezávisle známy fakt slúži ako kritérium na overenie indexu. Index ostáva pod prahom presne tam, kde je presnosť zachovaná (≥ 8 bitov), a narastá tam, kde presnosť klesá (≤ 4 bity), pričom Spearmanova korelácia s bitovou hĺbkou je $\approx -0,99$. Zhoda indexu s týmto referenčným správaním potvrdzuje, že je použiteľným proxy ukazovateľom kvality kvantizácie, meria sa z rozdelenia váh, no vypovedá o tom, čo v praxi funguje. Zhoda však nie je bezvýhradná: pri modeli MobileNetV2 váhový index nezachytí kolaps presnosti pri štyroch bitoch, čo vymedzuje platnosť metódy tk. index je spoľahlivým signálom pre testovanú rodinu modelov, no prah aj samotná vypovedacia schopnosť (váhy verzus aktivácie) sa musia kalibrovať pre danú architektúru.

Voľba bitovej hĺbky (6 vs 8 bitov). Keď index-riadená stratégia minimalizuje bitovú hĺbku pri zachovaní indexu pod prahom, prirodzene volí približne 6 bitov, pri tejto šírke je index hlboko pod prahom ($JS \approx 0,001$) a presnosť ostáva zachovaná, takže 6 bitov je analyticky najúspornejšia, naprieč testovanými datasetmi takmer bezstratová voľba. Odporúčaným cieľom pre nasadenie však ostáva 8 bitov (INT8): celočíselný hardvér a behové prostredia, mobilné a hranové NPU, INT8 akcelerátory, celočíselné jadrá TFLite/ONNX, natívne

podporujú 8 bitov, kým 6 bitov je zriedka hardvérovo natívnych a v praxi by sa aj tak ukladalo do 8 bitov, čím by sa pamäťová výhoda pri behu stratila. Metóda preto ponúka oboje: analytické optimum (≈ 6 bitov) aj prakticky nasaditeľný štandard (8 bitov), ktorý je pre nasadenie kľúčový.

Hlavné číselné výsledky pre jednotlivé datasety a architektúry zhŕňa Tabuľka 1.

Dataset / model	FP32 top-1	8-bit top-1	4-bit top-1	$\rho(\text{bity, JS})$
digits	0,967	0,966	0,964	-0,984
Fashion-MNIST	0,907	0,907	0,900	-0,984
MNIST	0,987	0,987	0,987	-0,984
CIFAR-10	0,638	0,637	0,601	-0,984
MobileNetV2 (ImageNet)	0,573	0,519	0,002	-1,000
ResNet50 (ImageNet)	0,563	0,562	0,365	-1,000

Tabuľka 1 Presnosť (top-1) pri vybraných bitových hĺbkach a Spearmanova korelácia indexu s bitovou hĺbkou. Osembitová kvantizácia je prakticky bezstratová; pri štyroch bitoch závisí pokles od architektúry (MobileNetV2 kolabuje, ResNet50 degraduje miernejšie).

Z tabuľky vyplýva, že osembitová kvantizácia je naprieč všetkými datasetmi prakticky bezstratová: pokles top-1 je v rámci šumu medzi behmi, vrátane modelu ResNet50 na ImageNete. Pri štyroch bitoch začína správanie závisieť od architektúry: malé konvolučné siete aj ResNet50 si presnosť väčšinou udržia, no MobileNetV2 padá takmer na nulu, hoci jeho váhový index ostáva mizivý tj. degradácia teda pochádza mimo rozdelenia váh a globálny váhový index ju nezachytí. Stĺpec $\rho(\text{bity, JS})$ potvrdzuje, že index monotónne sleduje tvrdosť kvantizácie ($\approx -0,98$ pri malých modeloch, $-1,00$ na ImageNete).

Trend naprieč všetkými testovanými bitovými hĺbkami (priemer malých datasetov) zhŕňa Tabuľka 2.

Bitová hĺbka	Priemerný pokles top-1	Priemerný nárost loss	Priemerný index (JS)	Kompresný pomer
32	0,0 %	1,00×	0,0000	1×
16	0,0 %	1,00×	0,0000	2×
8	0,0 %	1,00×	0,0001	4×
4	-1,7 %	1,11×	0,0819	8×
2	-63,5 %	20,33×	0,6322	16×

Tabuľka 2 Priemerný pokles presnosti (top-1), priemerný nárost chybovej funkcie (loss, ako násobok hodnoty FP32) a priemerný index (JS) podľa bitovej hĺbky naprieč malými datasetmi (digits, Fashion-MNIST, MNIST, CIFAR-10). Hodnoty presnosti, loss a indexu sú namerané z tréningu; kompresný pomer (32/bity) je teoretický. Veľký nárost loss pri dvoch bitoch je sčasti spôsobený datasetmi s veľmi nízkou FP32 chybou (napr. MNIST), kde aj malá absolútna zmena znamená veľký násobok.


Tabuľka ukazuje spoločný trend naprieč štyrmi malými datasetmi: do ôsmich bitov index aj presnosť ostávajú nezmenené (štvornásobná kompresia takmer zadarmo). Pri štyroch bitoch index citeľne narastie, kým presnosť klesne len mierne ($\approx 1,7\%$) a loss vzrastie asi o 11 %, index sa teda dvíha skôr, než sa degradácia naplno prejaví na výkone. Pri dvoch bitoch nastáva kolaps: index sa blíži k svojmu hornému ohraničeniu, presnosť padá o vyše polovice a chybová funkcia narastá rádovo. Práve tento nelineárny predstih robí z indexu signál včasného varovania, nie iba dodatočný ukazovateľ.

Stratégia naprieč datasetmi (SMT vs baseline). Navrhnutá stratégia (SMT) pre každý dataset automaticky zvolí bitovú hĺbku podľa prahu indexu a počas kvantizačne uvedomelého

tréningu sleduje per-vrstvový index s možnosťou včasného ukončenia. Aby bolo vidno jej skutočný prínos, porovnávame ju s naivným baseline tj- fixnou osembitovou kvantizáciou na rovnaký strop epoch, bez monitoringu a bez automatického výberu. Výsledky zhrňa Tabuľka 3.

Dataset	SMT bity	SMT epochy	SMT top-1	Baseline (8-bit) top-1	Kompresia (SMT / baseline)
digits	6	4	0,972	0,978	5,33× / 4×
Fashion-MNIST	6	4	0,911	0,902	5,33× / 4×
MNIST	6	30	0,991	0,992	5,33× / 4×
CIFAR-10	6	5	0,649	0,629	5,33× / 4×

Tabuľka 3 Stratégia (SMT) versus fixný osembitový baseline pri rovnakom strope epoch. SMT volí bitovú hĺbku automaticky a využíva index-riadené včasné ukončenie; uvádza sa zvolená hĺbka, počet epoch (30 = včasné ukončenie sa v rámci rozpočtu nespustilo) a dosiahnutá presnosť. Kompresný pomer je teoretický (32/bity).



Obr. 3 Presnosť (top-1) stratégie SMT (automaticky zvolené ≈ 6 bitov + včasné ukončenie) oproti fixnému osembitovému baseline pri rovnakom strope epoch. Popisky uvádzajú zvolenú bitovú hĺbku a počet epoch.

Z porovnania vyplývajú tri zistenia. Po prvé, stratégia naprieč všetkými štyrmi datasetmi konzistentne volí približne šesť bitov (kompresia 5,33×), čím v úspore pamäte prekonáva osembitový baseline (4×). Po druhé, táto úspora nie je vykúpená presnosťou: na všetkých štyroch datasetoch je presnosť SMT porovnateľná s osembitovým baseline a rozdiely sú malé (od -0,6 do +2,0 percentuálneho bodu) a v rámci variability medzi behmi, takže šesť bitov je naprieč testovanými datasetmi prakticky bezstratových. Po tretie, index-riadené včasné ukončenie sa na plnom behu spustilo na troch zo štyroch datasetov (digits, Fashion-MNIST aj CIFAR-10 už v 4.–5. epoche; MNIST dobehol strop 30 epoch), čím podstatne znížilo počet tréningových epoch bez straty presnosti.

Včasné ukončenie ako detektor ustálenia indexu. Mechanizmus zastaví tréning, keď sa per-vrstvový index ustáli, teda keď sa rozdelenie váh relevantné pre kvantizáciu prestane meniť. Má dôležitú bezpečnostnú vlastnosť: spustí sa iba pri ustálení, takže nikdy nezastaví predčasne, ak sa nespustí, tréning jednoducho dobehne stanovený strop a nič sa nestratí. Na plnom behu sa index na väčšine datasetov ustálil rýchlo a mechanizmus tak ušetril podstatnú časť tréningu bez straty presnosti. V prípade digits, Fashion-MNIST aj CIFAR-10 sa ukončili

už v 4.–5. epoche namiesto 30 (napr. digits 0,972 oproti 0,978 pri baseline), kým na MNIST sa index v rámci rozpočtu neustálil a tréning dobehol strop. Epochu ustálenia preto uvádzame ako mieru rýchlosti dosiahnutia kvantizačnej stability, nie ako zlyhanie; mechanizmus sa odporúča používať spolu so stropom epoch a kontrolou presnosti, nie samostatne.

5. Finalizácia, prínosy a obmedzenia

Na základe validačných výsledkov bola metóda revidovaná a doladená do prezentovanej podoby. Kvantizácia sa ustálila na schéme po kanáloch (namiesto po tenzoroch), keďže vernejšie zachováva rozdelenie váh a dáva stabilnejší index; prahová hodnota ($\tau = 0,01$) bola kalibrovaná voči nezávisle nameranej bezstratovosti a chápe sa ako architekturné závislý parameter, nie univerzálna konštanta. Samotný ukazovateľ bol prehodnotený a prerámcovaný z „detektora“ na proxy validovaný voči zavedenej praxi, čím sa explicitne vymedzila jeho platnosť. Hlavným podnetom na ďalšie doladenie je zistený limit váhového indexu pri degradácii mimo rozdelenia váh (MobileNetV2), ktorý vedie k rozšíreniu monitorovania o aktivácie.

Hlavným prínosom riešenia je, že index je výpočtovo lacný a jeho réžia je rádovo zanedbateľná v porovnaní s jedným dopredným a spätným priechodom siete. Dá sa počítať priebežne počas tréningu, dokonca aj viac indexov súčasne. Index je dataset-agnostický a nezávislý od voľby konkrétnej metriky, keďže jednotlivé miery sú navzájom silne korelované. Použiteľný je v dvoch režimoch: ako prediktor na výber vhodnej bitovej hĺbky pred tréningom a ako monitor na sledovanie stavu modelu počas tréningu, vrátane včasného ukončenia. Index-riadené včasné ukončenie funguje a na plnom behu sa spustilo na troch zo štyroch datasetov (digits, Fashion-MNIST aj CIFAR-10), no nemusí sa spustiť všade napr. na MNIST sa index v rámci rozpočtu epoch neustálil a tréning dobehol stro, preto sa odporúča používať ho spolu so stropom epoch a kontrolou presnosti, nie samostatne.

Súčasťou overenia bolo aj vymedzenie rozsahu platnosti metódy. Index cielene sleduje rozdelenie váh, a preto najspoľahlivejšie zachytáva degradáciu, ktorá sa vo váhach prejaví. Experimenty zároveň umožnili identifikovať prípady, keď pokles presnosti pramení mimo rozdelenia váh, napríklad pri modeli MobileNetV2 so štvorbitovou kvantizáciou, kde sa zhoršenie odohráva prevažne na úrovni aktivácií. Toto zistenie presne ohraničuje, na čo je váhový index postačujúci, a prirodzene vymedzuje jeho rozšírenie o monitorovanie aktivácií. Pre robustné správanie na hlbokých sieťach sa využíva kvantizácia po kanáloch a prahová hodnota indexu sa kalibruje pre danú architektúru; index sa preto navrhuje sledovať spoločne s presnosťou, čím sa získa úplný obraz o vzťahu medzi zmenou rozdelenia váh a výkonom modelu.

6. Záver a ďalšie smerovanie

Výskum preukázal, že navrhnutý štatistický index podobnosti je použiteľný a nenákladný nástroj na monitorovanie kvantizácie priamo počas tréningu, ktorý spĺňa validačné kritériá stanovené vo výstupe D10 a naplňuje cieľ projektu: overiť koncept na štandardných datasetoch a vyhodnotiť jeho prínosy aj obmedzenia. Ďalšie smerovanie výskumu vyplýva priamo zo zistení a z vymedzeného rozsahu metódy: rozšírenie monitorovania z váh aj na aktivácie, návrh stratégie zmiešanej presnosti riadenej per-vrstvovým indexom a dôkladnejšia kalibrácia prahových hodnôt. Výsledky zhrnuté v tomto dokumente tvoria podklad pre pripravovanú vedeckú publikáciu (D16) a pre záverečnú správu projektu (D17).

Ing. Roman Budjač, PhD.