

Záverečná správa

**Štatistický prístup ku kvantizácií a monitorovaniu tréningu
neurónových sietí
09I03-03-V04-00562**

Ing. Roman Budjač, PhD., 04/2026

IDENTIFIKÁCIA PROJEKTU

METODIKA RIEŠENIA PROJEKTU

POPIS VYKONANÝCH ČINNOSTÍ

PROBLÉMY, RIZIKÁ A PRIJATÉ OPATRENIA

PRIEBEH IMPLEMENTÁCIE PROJEKTU

PUBLICITA PROJEKTU

DOSIAHNUTÉ VÝSLEDKY A VÝSTUPY PROJEKTU

ZÁVEREČNÉ HODNOTENIE PROJEKTU

IDENTIFIKÁCIA PROJEKTU

Názov projektu: Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí
(Statistical Approach to Monitor Quantisation in Neural Network Training)

Akronym projektu: SAMQ-NN

Kód projektu: 09I03-03-V04-00312-00562

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií
Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci
komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

Hlavný riešiteľ: Ing. Roman Budjač, PhD.

ÚVOD

Projekt Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí (SAMQ-NN) sa zaoberá problematikou veľkosti modelov neurónových sietí, konkrétne procesom kvantizácie modelov neurónových sietí. Robustnosť moderných modelov hlbokého učenia komplikuje ich nasadenie v segmentoch s obmedzeným výpočtovým výkonom, najmä v oblasti IoT a zariadení s obmedzenými prostriedkami. Proces kvantizácie znižuje pamäťovú a výpočtovú náročnosť modelov, môže však viesť k degradácii presnosti.

Projekt predkladá koncept úpravy tréningu neurónových sietí pre proces kvantizácie založený na štatistických metódach porovnávania rozdelenia váh modelu pred kvantizáciou a po kvantizácii. Na základe týchto metód je možné trénovania kvantizovaného modelu sledovať index podobnosti rozdelenia váh voči nekvantizovanému modelu v plnej presnosti. Takto upravený tréningový proces dáva používateľovi možnosť sledovať priebeh a výsledok trénovania.

Cieľom projektu bolo navrhnuť koncepčný rámec (framework), ktorým je možné pomocou indexu podobnosti monitorovať proces kvantizácie neurónových sietí.

METODIKA RIEŠENIA PROJEKTU

Metodika projektu vychádza z porovnávania rozdelenia váh kvantizovaného a nekvantizovaného modelu neurónovej siete. Porovnávanie rozdelení je základným nástrojom štatistickej analýzy, ktorý umožňuje kvantifikovať rozdiely medzi dvoma množinami údajov, sledovať ich vývoj a vyvodzovať závery o ich vzájomnom vzťahu. V kontexte projektu sa toto porovnávanie využíva na vyjadrenie rozdielu medzi rozdelením váh modelu pred kvantizáciou a po nej, a to opakovane počas tréningu.

Váhy predstavujú základnú zložku modelu neurónovej siete. Vyjadrujú silu prepojení medzi neurónmi a určujú výstup siete pri danom vstupe. Počas tréningu sa váhy upravujú pomocou optimalizačných algoritmov, napríklad gradientového zostupu a jeho variantov, s cieľom minimalizovať stratovú funkciu, teda rozdiel medzi očakávaným a skutočným výstupom. Rozdelenie váh v sieti súvisí s jej kapacitou a schopnosťou zachytiť vzťahy v údajoch. Pri kvantizácii sa hodnoty váh prevádzajú z vyššej presnosti na nižšiu, čím sa mení ich rozdelenie. Sledovanie tejto zmeny je preto vhodným ukazovateľom vplyvu kvantizácie na model.

Na porovnanie rozdelenia váh boli v projekte použité tri štatistické miery: Kullback-Leiblerova divergencia, Jensen-Shannonova divergencia a kosínusová podobnosť. Tieto metódy boli najskôr analyzované a testované na referenčných rozdeleniach a následne aplikované na váhy konvolučných neurónových sietí.

Porovnanie rozdelenia váh má v rámci projektu viacero využití. Umožňuje posúdiť rozdiel v správaní kvantizovaného a nekvantizovaného modelu, pretože podobné rozdelenia spravidla zodpovedajú podobnej presnosti, zatiaľ čo výrazné rozdiely môžu naznačovať degradáciu presnosti. Ďalej umožňuje posúdiť, do akej miery kvantizácia zachovala informáciu obsiahnutú vo váhach pôvodného modelu, teda účinnosť samotného procesu kvantizácie. Poskytuje aj informáciu o zmene robustnosti modelu, o posune vo vzťahu medzi skreslením a rozptylom (bias a variance) a o vhodnosti rozdelenia váh pre konkrétny hardvér.

Index podobnosti, ktorý projekt zavádza, je založený na štatistických metódach porovnávania pravdepodobnostných rozdelení. Porovnávanie rozdelení predstavuje základný nástroj štatistickej analýzy uplatňovaný v širokom spektre oblastí, ktorý umožňuje odhaľovať vzory, pochopiť vnútornú štruktúru údajov a vyvodzovať závery o ich charaktere. Vďaka porovnávaniu rozdelení je možné kvantifikovať rozdiely, monitorovať výkonnosť, optimalizovať procesy a posudzovať riziká. Na porovnávanie rozdelení existuje viacero metód, pričom každá z nich má svoje špecifické výhody aj obmedzenia a ich vhodnosť závisí od konkrétnej situácie. V rámci projektu sa tieto metódy využívajú na výpočet indexu podobnosti medzi rozdelením váh kvantizovaného a nekvantizovaného modelu, čím sa získava kvantitatívne vyjadrenie miery degradácie modelu počas tréningu.

Na základe týchto metód sa počas tréningu kvantizovaného modelu vyhodnocuje index podobnosti rozdelenia váh voči nekvantizovanému modelu v plnej presnosti. Index je možné sledovať v každej epoche, čím poskytuje priebežnú informáciu o vplyve klesajúcej bitovej hĺbky na model. Samotné porovnávanie rozdelení je výpočtovo nenáročné. Implementácia bola realizovaná vo frameworku TensorFlow/Keras a navrhnutý postup bol overený na štandardných referenčných množinách.

Matematická formulácia indexu podobnosti

Cieľom indexu je číselne vyjadriť, ako veľmi sa rozdelenie váh kvantizovaného modelu odchyľuje od rozdelenia váh pôvodného nekvantizovaného modelu v plnej presnosti (FP32), a sledovať túto odchýlku priebežne počas tréningu. Východiskom je reprezentácia množiny váh ako diskrétného pravdepodobnostného rozdelenia, na ktoré sa následne aplikujú štatistické miery rozdielu dvoch rozdelení.

Reprezentácia váh ako rozdelenia. Nech $\mathbf{w}^{\text{ref}}$ označuje zreťazené jadrá (kernely) konvolučných a plne prepojených vrstiev pôvodného modelu (biasy ani parametre normalizácie sa nezahŕňajú) a nech $\hat{\mathbf{w}}(t)$ označuje efektívne kvantizované jadrá modelu na konci epochy t . Pre túto dvojicu vektorov sa zvolí spoločný rozsah hodnôt a rozdelí sa na $K = 100$ rovnako širokých binov:

$$\ell = \min \left(\min_j w_j^{\text{ref}}, \min_j \hat{w}_j(t) \right), \quad u = \max \left(\max_j w_j^{\text{ref}}, \max_j \hat{w}_j(t) \right). \quad (1)$$

Početnosti váh v jednotlivých binoch sa pred normalizáciou doplnia o malú stabilizačnú konštantu $\varepsilon = 10^{-10}$, čím sa zabráni nulovým pravdepodobnostiam a tým aj výpočtu logaritmu nuly. Výsledné rozdelenia referenčného modelu P a kvantizovaného modelu Q sú

$$P_k(t) = \frac{h_k(\mathbf{w}^{\text{ref}}) + \varepsilon}{\sum_{j=1}^K (h_j(\mathbf{w}^{\text{ref}}) + \varepsilon)}, \quad Q_k(t) = \frac{h_k(\hat{\mathbf{w}}(t)) + \varepsilon}{\sum_{j=1}^K (h_j(\hat{\mathbf{w}}(t)) + \varepsilon)}, \quad (2)$$

kde $h_k(\cdot)$ je počet váh padajúcich do k -teho binu. Keďže hranice binov sú dané spoločným rozsahom dvojice, prepočítavajú sa pri každom porovnaní, a obe rozdelenia preto nesú index epochy t . Použitie rovnakých hraníc pre P aj Q zaručuje, že porovnanie je vždy konzistentné.

Miery rozdielu rozdelení. Na porovnanie P a Q sa používajú tri miery, všetky s logaritmom o základe dva. Kullbackova-Leiblerova divergencia

$$D_{\text{KL}}(P \parallel Q) = \sum_{k=1}^K P_k \log_2 \frac{P_k}{Q_k} \quad (3)$$

je nesymetrická a neohraničená a z veľkosti hodnoty sa dá odhadnúť rozsah rozdielu, je preto citlivým ukazovateľom. Jensenova-Shannonova divergencia je jej symetrizovaná a ohraničená verzia. So stredným rozdelením $M = 1/2 (P + Q)$ platí

$$D_{\text{JS}}(P, Q) = 1/2 D_{\text{KL}}(P \parallel M) + 1/2 D_{\text{KL}}(Q \parallel M) \in [0, 1] \quad (4)$$

Vďaka logaritmu o základe dva nadobúda hodnoty v intervale $[0, 1]$, je symetrická a robustná aj pri málo prekrývajúcich sa rozdeleniach, čo z nej robí vhodnú veličinu na prahovanie.

Doplňkovo sa počíta kosínusová podobnosť, ktorá porovnáva tvar (orientáciu) rozdelení nezávisle od ich veľkosti:

$$\cos(P, Q) = \frac{\sum_{k=1}^K P_k Q_k}{\sqrt{\sum_{k=1}^K P_k^2} \sqrt{\sum_{k=1}^K Q_k^2}}. \quad (5)$$

Index podobnosti.

Primárnou veličinou, ktorá sa monitoruje počas tréningu, je Jensenova-Shannonova divergencia medzi referenčným a aktuálnym kvantizovaným rozdelením, vyhodnocovaná globálne nad všetkými jadrami:

$$S(t) = D_{JS}(P(t), Q(t)). \quad (6)$$

Tú istú definíciu možno aplikovať aj na jadrá jednotlivých vrstiev ℓ a získať per-vrstvový index $S_\ell(t) = D_{JS}(P_\ell(t), Q_\ell(t))$, ktorý ukazuje, ktoré vrstvy sú kvantizáciou ovplyvnené najviac.

Kvantizácia váh. Efektívne kvantizované jadrá $\hat{\mathbf{w}}$ vznikajú uniformnou symetrickou kvantizáciou po výstupných kanáloch. Pre kanál c a b bitov je krok kvantizácie a kvantizovaná hodnota

$$\Delta_c = \frac{\max_j |w_{c,j}|}{2^{b-1}-1}, \quad \hat{w}_{c,j} = \Delta_c \cdot \text{clip}(\lfloor w_{c,j}/\Delta_c \rfloor, -(2^{b-1}-1), 2^{b-1}-1), \quad (7)$$

kde $\lfloor \cdot \rfloor$ je zaokrúhlenie na najbližšie celé číslo a clip orezanie do prípustného rozsahu. Každý kanál má vlastný krok Δ_c , takže váhy ležia na mriežke s nanajvyš 2^b úrovňami. Pri kvantizačne uvedomelom tréningu sa táto operácia vkladá do dopredného priechodu, pričom v spätnom priechode sa používa straight-through estimator (jednotkový gradient), aby váhy zostali počas celého tréningu reálne kvantizované.

Implementácia indexu podobnosti v riadení tréningu tréningu.

Z ohraničenosti Jensenovej-Shannonovej divergencie vychádza prah platnosti $\tau = 0,01$. Automatický výber bitovej hĺbky prejde kandidátov $\mathcal{B} = \{4,6,8,16\}$ od najmenšieho a zvolí prvý, pri ktorom index neprekročí prah,

$$b^* = \min\{b \in \mathcal{B} : D_{JS}(P, Q_b) \leq \tau\}, \quad (8)$$

a ak prah nesplní žiadny, ponechá najvyššiu hodnotu. Index-riadené včasné ukončenie zastaví tréning, keď sa počas $S_{\text{pat}} = 3$ po sebe idúcich epoch index aj presnosť ustália, teda keď

$$|S(t) - S(t-1)| < \delta_s \quad \text{a súčasne} \quad a(t) - a(t-1) < \delta_a, \quad (9)$$


kde $a(t)$ je presnosť na testovacej množine, $\delta_s = 10^{-3}$ a $\delta_a = 5 \cdot 10^{-3}$. Druhá podmienka je znamienková: spustí sa, keď presnosť už ďalej citeľne nerastie, takže ukončenie nenastane predčasne.

Histogramy, divergencie aj kosínusová podobnosť sa počítajú nad zretazenými jadrami (parametre biasov a normalizačných vrstiev sa vynechávajú), s $K = 100$ binmi a konštantou $\varepsilon = 10^{-10}$. Referenciou je pôvodný model v plnej presnosti (FP32), ktorého váhy sa počas dotrénovania nemenia; index sa vyhodnocuje na konci každej epochy v rámci spätného volania (callback) a zapisuje sa do histórie tréningu. Samotný výpočet pozostáva zo zostavenia histogramu a vyhodnotenia entropie alebo skalárneho súčinu, takže jeho réžia je oproti jednému doprednému a spätnému priechodu siete nízka.

POPIS VYKONANÝCH ČINNOSTÍ

Realizácia projektu prebiehala v období od júna 2024 do mája 2026 a bola rozdelená do štyroch pracovných balíkov (WP1 až WP4), ktoré sú ohraničené štyrmi míľnikmi (M1 až M4) a postupne na seba nadväzovali. V priebehu riešenia bolo dodaných sedemnást výstupov (D1 až D17), pričom implementácia prebiehala v súlade s časovým harmonogramom projektu.


V rámci prvého pracovného balíka (WP1) bola vypracovaná analýza a testovanie vhodných štatistických metód na porovnávanie rozloženia váh neurónových sietí v rôznych štádiách kvantizácie. Posudzované boli viaceré metódy porovnávania pravdepodobnostných rozdelení, pričom pozornosť bola zameraná na Kullback-Leibler divergenciu, Jensen-Shannon divergenciu a kosínusovú podobnosť. Na základe ich vlastností, najmä asymetrie a neohraničenosti Kullback-Leibler divergencie oproti symetrii a ohraničenosti Jensen-Shannon divergencie, bola ako najvhodnejšia pre praktické monitorovanie zvolená Jensen-Shannon divergencia. Výstupmi tejto etapy boli úvodný seminár (D1), analytický report (D2), a kód (D3) a príspevok na vedeckej konferencii (D4). Naplnením tejto etapy bol dosiahnutý prvý míľnik projektu (M1). Z tejto analýzy zároveň vyplynulo, že použité štatistické metódy nepredstavovali výpočtovú záťaž a samotné porovnanie distribúcií, tvorilo len malú časť celkového výkonu vynaloženého v procese tréningovania neurónových sietí. Výsledky boli publikované vo výstupe Layer-wise Statistical Analysis: A Time-Sensitive Framework for Implementing Statistical Methods in Neural Network Training Sessions na konferencii CSOC 2024. Tento proces je výpočtovo nenáročná operácia v porovnaní s dopredným a spätným prechodom siete pri samotnom učení. Réžia priebežného vyhodnocovania indexu preto zostáva zanedbateľná a nemá podstatný vplyv na celkový čas tréningovania.



Obrázok 1 Analýza implementácie štatistickej metódy do tréningovania NN.


Druhý pracovný balík (WP2) bol zameraný na implementáciu vybranej štatistickej metódy priamo do procesu kvantizácie neurónových sietí. Jensen-Shannon divergencia bola integrovaná do porovnávania rozloženia váh kvantizovaného a nekvantizovaného modelu, čím

bola umožnená kvantitatívna analýza zmien v rozložení váh počas tréningovania aj po kvantizácii. Realizované boli experimenty na dátových sadách s cieľom posúdiť vplyv kvantizácie na rozloženie váh a výkonnosť modelov. Výstupmi tejto etapy boli seminár (D5), report (D6), zdrojový kód sprístupnený v repozitári GitHub (D7), príspevok na vedeckej konferencii (D8) a priebežná správa projektu (D9). Touto etapou bol dosiahnutý druhý míľnik projektu (M2). Diagram návrhu implementácie sa nachádza na obrázku nižšie.



Obrázok 2 Návrh implementácie štatistických metód do procesu tréningovania

Nasledujúci diagram nižšie, znázorňuje princíp fungovania navrhnutého indexu podobnosti. Vstupom sú dva modely, referenčný model v plnej presnosti (FP32) a kvantizovaný model tréningovaný kvantizačne spôsobom so straight-through estimatorom, vďaka čomu jeho váhy zostávajú počas celého tréningu reálne kvantizované. Z váh oboch modelov sa zostavia rozdelenia P a Q, reprezentované histogramami nad spoločným rozsahom hodnôt. Mierou rozdielu medzi týmito rozdeleniami je Jensenova-Shannonova divergencia, ktorá tvorí samotný index podobnosti $S(t)$ a vyhodnocuje sa na konci každej epochy prostredníctvom spätného volania (callback). Hodnota indexu následne vstupuje do dvoch rozhodnutí: do automatického výberu bitovej hĺbky pred tréningom, kde sa volí najnižší počet bitov, pri ktorom index ostáva pod stanoveným prahom, a do index-riadeného včasného ukončenia počas tréningu, ktoré zastaví učenie po ustálení indexu a presnosti. Index tak spája analytickú prípravu s priamym riadením tréningového procesu.



Obrázok 3 Princíp fungovania imlementácie similarity indexu.

Diagram nižšie zhrňa, že navrhnutý index podobnosti nie je jediná pevne daná veličina, ale nástroj, ktorý možno prispôbiť pozdĺž štyroch osí podľa toho, čo má v danom kroku riešenia plniť. Prvou osou je granularita: index sa dá počítať globálne, teda nad váhami celého modelu naraz, čo dáva jeden súhrnný ukazovateľ, alebo po jednotlivých vrstvách, čím sa odhalí najcitlivejšia vrstva a získa sa jemnejší signál vhodný pre stratégie zmiešanej presnosti. Druhou osou je úloha pri tréningu: v režime prediktora sa index použije pred tréningom na výber vhodnej bitovej hĺbky, v režime monitora sa vyhodnocuje priebežne počas kvantizačne uvedeného tréningu (QAT), na konci každej epochy. Treťou osou je voľba referencie: aktuálne rozdelenie váh sa môže porovnávať buď voči zmrazenému referenčnému modelu v plnej presnosti (FP32), čím sa meria absolútna odchýlka spôsobená kvantizáciou, alebo medzi po sebe idúcimi epochami, čím sa sleduje zmena z epochy na epochu a dá sa rozpoznať ustálenie. Štvrtou osou je spôsob rozhodovania: na výber bitovej hĺbky slúži pevný prah, pri ktorom index musí ostať pod hodnotou $JS \leq \tau$, a tento mechanizmus sa dá doplniť o včasné ukončenie tréningu, ktoré zastaví učenie po ustálení indexu. Tieto varianty sa navzájom nevylučujú, ale dopĺňajú: práve ich kombináciou získava metóda schopnosť slúžiť ako prediktor aj ako monitor a pokryť celý priebeh tréningu od voľby nastavení až po riadené ukončenie.

Tretí pracovný balík sa venoval návrhu a vývoju novej tréningovej stratégie. Štatistické porovnávanie rozloženia váh bolo integrované priamo do procesu učenia v podobe indexu podobnosti, na základe ktorého bola navrhnutá vlasťná stratégia Statistically-Monitored Training (SMT). Jej súčasťou je automatický výber bitovej hĺbky podľa prahu indexu a


možnosť skorého ukončenia tréningu v okamihu, keď sa rozloženie váh relevantné pre kvantizáciu ustáli.

How to use the index - variants

	Granularity	global (whole model)	vs	per-layer (most sensitive layer)
	Role in training	predictor (pre-training — bit-width selection)	vs	monitor (during QAT — per epoch)
	Reference	frozen FP32 reference	vs	epoch-over-epoch (inter-epoch change)
	Decision-making	fixed threshold $JS \leq \tau$ (bit-width selection)	vs	+ early stopping at stabilisation


Obrázok 4 Možnosti využitia indexu podobnosti

Štvrtý pracovný balík (WP4) predstavoval komplexné overenie navrhnutého konceptu na štandardných dátových sadách a záverečnú validáciu implementovaných metód. Index podobnosti pritom monotónne sledoval klesajúcu bitovú hĺbku a navrhnutá stratégia SMT dosahovala presnosť porovnateľnú s referenčným osembitovým prístupom pri vyššej miere kompresie. Súčasne boli jasne vymedzené hranice použiteľnosti navrhnutého indexu pri extrémne nízkej bitovej hĺbke.



Obrázok 5 Kompresia vs. presnosť

Pre potreby experimentálneho overovania bolo v rámci projektu skonštruované samostatné zariadenie určené na testovanie kvantizácie a jej priebežného monitorovania. Zariadenie je postavené na hardvéri vhodnom na vývoj aj nasadenie (deployment) modelov hlbokého učenia a umelej inteligencie, konkrétne na platformách NVIDIA Jetson Orin Nano Super. Cieľom tohto overovania bolo preveriť použiteľnosť navrhnutej metódy v podmienkach, ktoré sa líšia od bežnej výpočtovej infraštruktúry, a otestovať ju priamo na cieľových zariadeniach s obmedzeným výpočtovým výkonom. Treba však zdôrazniť, že v rámci projektu išlo o preverenie konceptu (proof of concept), ktorého zmyslom bolo overiť realizovateľnosť a základné fungovanie prístupu na takomto hardvéri. Optimalizácia pre konkrétne nasadenie, ako aj rozsiahlejšie výkonnostné testovanie, presahujú rámec projektu a predstavujú prirodzený priestor pre nadväzujúcu prácu.



Obrázok 6 Overenie metodiky projektu na hardvéri.

Praktický význam dosiahnutých výsledkov spočíva v potenciály nasadenia kvantizovaných neurónových sietí na zariadeniach s obmedzenými výpočtovými a pamäťovými zdrojmi, ako sú mikrokontroléry a vstavané systémy. Znižovanie bitovej hĺbky váh vedie k výraznej redukcii veľkosti modelu a pamätevej náročnosti, čo sú kľúčové predpoklady pre beh modelov na takomto hardvéri.

PROBLÉMY, RIZIKÁ A PRIJATÉ OPATRENIA:

Riziko 1: Nedostatočne výkonný hardvér pre tréning modelov (WP1 až WP4), stredná pravdepodobnosť, stredná závažnosť.

Opatrenie 1: Využitie predplatených cloudových výpočtových služieb hostiteľskej inštitúcie (LightningAI). Vývoj prebiehal na CPU prostredí a validované tréningy na GPU inštanciách s pravidelným ukladáním kontrolných bodov (lokálny PC).

Riziko 2: Štatistické metódy nemusia byť vhodné na porovnanie rozdelenia váh (WP1), stredná pravdepodobnosť, stredná závažnosť.

Opatrenie 2: Vhodnosť štatistických metód bola overená na referenčných rozdeleniach so známym očakávaným výsledkom ešte pred ich nasadením na váhy modelu na malej dátovej množine.

Riziko 3: Štatistické metódy nemusia poskytnúť očakávané výsledky v prípade kvantizácie (WP2 a WP3), stredná pravdepodobnosť, stredná závažnosť.

Opatrenie 3: Iteratívne testovanie a postupné spresňovanie metodiky, porovnanie účinnosti viacerých metód pri rôznych bitových hĺbkach.

Riziko 4: Štatistické metódy môžu výrazne spomaliť tréning (WP4), nízka pravdepodobnosť, stredná závažnosť.

Opatrenie 4: Výpočtová réžia spojená s porovnávaním rozdelení je vo všeobecnosti nízka a v pomere k náročnosti samotného tréningu zanedbateľná.

Riziko 5: Neadekvátne dosiahnutie plánovaných publikačných výstupov, stredná pravdepodobnosť, stredná závažnosť.

Opatrenie 5: Publikačné výstupy boli plánované v primeranom rozsahu s ohľadom na trvanie projektu a fázu kariéry výskumníka.

Počas realizácie projektu neboli identifikované žiadne zásadné problémy, ktoré by negatívne ovplyvnili jeho priebeh. Riziká uvedené v tejto časti vychádzajú z analýzy rizík vykonanej vo fáze plánovania projektu a zachytenej v projektovom zámere. Tieto riziká boli počas celej realizácie projektu priebežne sledované a pre každé z nich boli vopred navrhnuté a v prípade potreby aj uplatnené zodpovedajúce opatrenia

PRIEBEH IMPLEMENTÁCIE PROJEKTU

Projekt je rozdelený do štyroch pracovných balíkov (WP1 až WP4), ktoré sú ohraničené štyrmi míľnikmi (M1 až M4), a zahŕňa výstupy D1 až D17. Prvý míľnik (M1) predstavuje analýzu a testovanie vhodných štatistických metód na porovnanie rozloženia váh. Druhý míľnik (M2) predstavuje analýzu implementácie porovnania rozloženia váh. Tretí míľnik (M3) zabezpečuje implementáciu stratégie tréningovania neurónovej siete na základe štatistickej metódy. Štvrtý míľnik (MS4) pokrýva vyhodnotenie koncepcie štatistických metód pre proces tréningovania neurónových sietí.

Počas realizácie projektu sa podarilo úspešne naplniť všetky ciele pracovných balíkov WP1 až WP4. Bola vypracovaná analýza a testovanie vhodných štatistických metód na porovnávanie rozloženia váh neurónových sietí, pričom ako najvhodnejšie boli vybrané Kullback-Leibler divergencia, Jensen-Shannon divergencia a kosínusová podobnosť. Následne bola JS implementovaná do procesu kvantizácie, čím bola umožnená detailná analýza zmien v rozložení váh počas tréningovania aj po kvantizácii. Na základe týchto metód bola navrhnutá a overená nová tréningová stratégia (Statistically-Monitored Training, SMT), ktorá integruje štatistické porovnávanie rozloženia váh do procesu učenia v podobe indexu podobnosti a umožňuje tak sledovať vplyv klesajúcej bitovej hĺbky na model. Zvolený metodický postup sa preukázal ako vhodný a súčasne jasne vymedzil hranice použiteľnosti navrhnutého indexu pri extrémne nízkej bitovej hĺbke. Tým sa vytvoril experimentálny a metodický základ pre ďalší vývoj štatisticky monitorovaného tréningovania kvantizovaných neurónových sietí.

Výstupy projektu podľa prílohy Opis projektu:

WP1

D1: Seminár. Seminár výskumnej problematiky a prezentácii výskumných nápadov. Správa bude k dispozícii na stránke GitHub.

D2: Report. Analýza vhodných štatistických metód. Písomné zhrnutie bude k dispozícii na stránke GitHub.

D3: Zdrojový kód. Testovanie štatistických metód na porovnanie rozdelení. Kód v prostredí Jupyter Notebook bude k dispozícii na stránke GitHub.

D4: Publikácia na vedeckej konferencii. Zborník z konferencie. Účasť na medzinárodnej vedeckej konferencii, ktorej zborník je indexovaný v databáze Scopus.

WP2

D5: Seminár. Seminár venovaný výskumnej úlohe (WP2) a prezentácii výskumných nápadov. Správa bude k dispozícii na stránke GitHub.

D6: Report. Analýza uplatnenia štatistických metód v procese kvantizácie. Písomné zhrnutie bude k dispozícii na stránke GitHub.

D7: Zdrojový kód. Implementácia štatistických metód do procesu kvantizácie. Kód v prostredí Jupyter Notebook bude k dispozícii na stránke GitHub.

D8: Publikácia na vedeckej konferencii. Publikácia v zborníku konferencie. Účasť na medzinárodnej vedeckej konferencii, ktorej zborník je indexovaný v databáze Scopus.

D9. Priebežný report. Priebežná správa.

WP3

D10: Zdrojový kód. c Analýza porovnania rozloženia váh implementácie v procese tréovania siete. Písomné zhrnutie bude k dispozícii na stránke GitHub.

D11: Správa zo seminára. Seminár venovaný výskumnej úlohe a prezentácii výskumných nápadov. Kód v Jupyter Notebooku bude k dispozícii na stránke GitHub.

D12: Seminár report. Implementácia novej stratégie tréovania neurónovej siete založenej na štatistickej metóde. Kód v prostredí Jupyter Notebook bude k dispozícii na stránke GitHub.

D13: Report. Osvedčený koncept a jeho kód (Jupyter Notebook) budú k dispozícii na stránke GitHub.

D14: Seminár report. Prezentácia výstupov projektu na seminári. Prezentácia bude k dispozícii na GitHub.

D15: Seminár, správa report. Implementácia novej stratégie tréovania neurónovej siete založenej na štatistickej metóde. Písomné zhrnutie bude k dispozícii na stránke GitHub.

D15: Dokončenie navrhovanej metódy a vypracovanie zhrnutia výskumu v navrhovanej oblasti. Písomné zhrnutie bude k dispozícii na stránke GitHub.

D16: Publikácia vo vedeckom časopise. Uverejnenie v časopise, ktorý patrí aspoň do kvartilu Q2. Klasifikácia podľa WOS.

D17: Záverečná správa

Zhodnotenie plnenia výstupov projektu:

Počas realizácie projektu sa podarilo úspešne naplniť všetky výstupy projektu (D1 až D17). Boli realizované semináre s priebežnou prezentáciou výsledkov riešenia, vypracované reporty/správy/sumáre a zverejnený zdrojový kód projektu vrátane jeho sprístupnenia v repozitári GitHub. Priebežný stav riešenia bol zhrnutý v priebežnej správe projektu (D9).

V rámci diseminačných aktivít boli splnené minimálne požiadavky projektu na kľúčové výstupy, a to dva konferenčné príspevky s indexáciou v databáze SCOPUS (D4,D8) a zároveň článok vo vedeckom časopise zaradenom v kvartile Q2 podľa WoS (D16).

Týmto boli splnené minimálne požiadavky kladené na projekt v rámci publikovania. Implementácia štatistických metód, ich integrácia do procesu kvantizácie aj navrhnutá tréningová stratégia boli zdokumentované v podobe zdrojového kódu a sprievodných správ/reportov a sumárov. Záverečným výstupom projektu je táto záverečná správa (D17), ktorá sumarizuje metodiku riešenia, vykonané činnosti, dosiahnuté výsledky a plnenie cieľov, výstupov a míľnikov projektu.

Míľniky projektu:

M1 - Analýza a testovanie vhodných štatistických metód na porovnanie rozloženia hmotnosti.

M2 - Analýza porovnania rozdelenia váh pri implementácii do procesu tréningu siete

M3 - Implementácia novej stratégie tréningu neurónovej siete založenej na štatistickej metóde

M4 - Overenie koncepcie prostredníctvom implementácie štatistických metód do procesu tréningu

Zhodnotenie plnenia míľnikov projektu: Všetky štyri míľniky projektu (M1 až M4) boli splnené vo v plnom rozsahu, čím sa potvrdilo plynulé napredovanie riešenia v súlade s harmonogramom pracovných balíkov.

PUBLICITA PROJEKTU

Publikovanie výsledkov projektu vedeckej a odbornej komunite sa uskutočnilo prostredníctvom publikácií v karentovaných a impaktovaných časopisoch, príspevkov na medzinárodných vedeckých konferenciách a verejne dostupných výstupov sprístupnených v repozitári projektu. Pri publikáciách boli dodržané zásady otvoreného prístupu. Výstupy projektu sú sprístupnené na repozitári Github: <https://github.com/romanbudjac>, pod názvom projektu: <https://github.com/romanbudjac/samqnn>.

Sprístupnenie výstupov projektu je súčasťou konceptu otvorenej vedy (open science), ktorého cieľom je sprístupniť vedecké poznatky, dáta a softvérové nástroje čo najširšiemu okruhu používateľov a zvýšiť tak transparentnosť, overiteľnosť a opätovnú využiteľnosť výsledkov výskumu. Otvorený prístup k publikáciám, otvorený zdrojový kód a verejne dostupné výstupy umožňujú ich reprodukovateľnosť a ďalšie rozvíjanie inými výskumníkmi. Otvorená veda je zároveň v súlade s princípmi podpory výskumu na úrovni Európskej únie.

Celkovo možno konštatovať, že publikačné a odborné výstupy projektu presahujú rámec minimálne plánovaných výstupov. Projekt priniesol vedecké články, konferenčné príspevky, semináre, zdrojové kódy, čím preukázal svoj prínos.

Vydané publikácie k projektu:

Zoznam publikačných a odborných výstupov

a) publikácie indexované vo Web of Science

- BUDJAČ, Roman – VALÁŠEK, Maroš – BELÁNY, Pavol – GAŠPAR, Gabriel.

Multiservice-Oriented Framework for Enhanced Data Collection and Visualization in Smart City Applications. In *IEEE Access* [online]. 2026, roč. 14, s. 5133–5151 [cit. 2026-06-21]. ISSN 2169-3536. Dostupné na: <https://doi.org/10.1109/ACCESS.2026.3650820>.

- Gašpar G.; Budjač R.; Valášek M.; Bartoň M.; Meravý T.; Strémy M.: Digitizing SMEs in the EU: A Scalable Model for Retrofitting Machinery to Industry 4.0. *Applications in Engineering Science*, roč. 23, art. č. 100230, 2025. DOI: <https://doi.org/10.1016/j.apples.2025.100230> Výstup spĺňa požiadavku na článok kategórie v databáze WOS Q2.

- GAŠPAR, Gabriel – BUDJAČ, Roman – ŠEDIVÝ, Štefan – STRÉMY, Maximilián – BENKA, Denis – NEMLAHA, Eduard – ELIÁŠ, Rastislav. Innovative Grouting Process Monitoring: Design and Implementation of a Measurement Device With Datalogger Function. In *IEEE Access* [online]. 2025, roč. 13, s. 19340–19352 [cit. 2026-06-21]. ISSN 2169-3536. Dostupné na: <https://doi.org/10.1109/ACCESS.2025.3534816>.
- VALÁŠEK, Maroš – BUDJAČ, Roman – HANZELY, Marek – VRČEK, Neven. Cloud-Based Modular System for Acquisition and Visualization of OCO-2 Remotely Sensed CO2 Data. In *Communications – Scientific Letters of the University of Žilina* [online]. 2026, roč. 28, č. 1, s. C10–C21 [cit. 2026-06-21]. ISSN 2585-7878. Dostupné na: <https://doi.org/10.26552/com.C.2026.013>

b) publikácie z medzinárodných vedeckých konferencií indexované v SCOPUS

- Budjač R.; Valášek M.: Layer-Wise Statistical Analysis: A Time-Sensitive Framework for Implementing Statistical Methods in Neural Network Training Sessions. *Lecture Notes in Networks and Systems*, roč. 1558 LNNS, s. 428–445 2026. DOI: https://doi.org/10.1007/978-3-032-00236-5_32 - . Výstup spĺňa požiadavku na konferenčný článok v zborníku v databáze SCOPUS.
- BENKA, Denis – GASPAR, Gabriel – BUDJAC, Roman – ELIAS, Rastislav – SKOVAJSA, Martin. Design and Implementation of the Grouting Process Measurement Device with a Datalogger. In *2024 21st International Conference on Mechatronics – Mechatronika (ME)* [online]. [Piscataway] : IEEE, 2024, s. 1–6 [cit. 2026-06-21]. Dostupné na: <https://doi.org/10.1109/ME61309.2024.10789730> Výstup spĺňa požiadavku na konferenčný článok v zborníku v databáze SCOPUS.
- BENKA, Denis – GASPAR, Gabriel – NEMLAHOVA, Veronika – NEMLAHA, Eduard – BUDJAC, Roman. Proposal of a Remote-Control System for Building Lighting Management. In *2024 21st International Conference on Mechatronics – Mechatronika (ME)* [online]. [Piscataway] : IEEE, 2024, s. 1–5 [cit. 2026-06-21].

Dostupné na: <https://doi.org/10.1109/ME61309.2024.10789644>.

Výstup spĺňa požiadavku na konferenčný článok v zborníku v databáze SCOPUS.

- BUDJAČ, Roman – VALÁŠEK, Maroš – BELÁNY, Pavol – HRABOVSKÝ, Peter.
Runtime Monitoring and Correction of INT8 Quantized Models Under Distribution Shift. In SILHAVY, Radek (ed.). Cham : Springer, 2026, Lecture Notes in Networks and Systems. ISSN 2367-3370. ISBN, Letter of acceptance.

Výstup spĺňa požiadavku na konferenčný článok v zborníku v databáze SCOPUS.

Other conference proceedings indexed in SCOPUS - *currently in print*:

- BUDJAČ, Roman – GAŠPAR, Gabriel – VALÁŠEK, Maroš – BARTOŇ, Martin.
Proposal for a weather monitoring system utilizing IoT technologies. In *Proceedings of the 35th Central European Conference on Information and Intelligent Systems (CECIIS 2024), Varaždin, Croatia, September 18–20, 2024* [online]. Varaždin : University of Zagreb, Faculty of Organization and Informatics, 2024, s. 67–74 [cit. 2026-06-21]. ISSN 1848-2295. Dostupné na: <https://archive.ceciis.foi.hr/public/conferences/2024/Proceedings/S2/S2P3.pdf>
- STACK, William Francis – JANOTA, Aleš – BUDJAČ, Roman. EirVah: An Open-Source Hybrid-Cloud Framework for Industrial Cyber-Physical Systems. In *Proceedings of the 15th Computer Science On-line Conference (CSOC 2026)*. Cham : Springer, in press. Lecture Notes in Networks and Systems. ISSN 2367-3370. (letter of acceptance)
- BRTIŠ, Jozef — ŽDÁNSKY, Juraj — HRMO, Ľubomír -BUDJAČ, Roman. System Modeling and PID Controller Tuning Using a Digital Twin. In *Proceedings of the 15th Computer Science On-line Conference (CSOC 2026)*. Cham : Springer, in press. Lecture Notes in Networks and Systems. ISSN 2367-3370. (letter of acceptance)

DOSIAHNUTÉ VÝSLEDKY A VÝSTUPY PROJEKTU

Realizáciou projektu sa podarilo naplniť hlavný cieľ projektu, ktorým bolo štatistické monitorovanie procesu kvantizácie počas tréningovania neurónových sietí prostredníctvom porovnávania rozloženia váh kvantizovaného a nekvantizovaného modelu. Projekt zároveň umožnil komplexne prepojiť analýzu a testovanie štatistických metód, ich implementáciu do procesu kvantizácie, návrh novej tréningovej stratégie a experimentálne overenie navrhnutého konceptu na štandardných dátových sadách.

V prvej fáze riešenia bola vypracovaná analýza a testovanie vhodných štatistických metód určených na porovnanie rozloženia váh neurónových sietí v rôznych štádiách kvantizácie. Posudzované boli viaceré metódy porovnávania rozdelení, pričom ako najvhodnejšie boli zvolené Kullback-Leibler divergencia, Jensen-Shannon divergencia a kosínusová podobnosť. Testovanie prebiehalo na viacerých dátových sadách (sklearn digits, MNIST, Fashion-MNIST), čo umožnilo posúdiť správanie jednotlivých metód pri rôznej miere kvantizácie.

Na základe výsledkov analýzy bola následne Jensen-Shannon divergencia implementovaná priamo do procesu kvantizácie neurónových sietí. Implementácia umožnila detailnú analýzu zmien v rozložení váh počas tréningovania aj po kvantizácii a vytvorila základ pre kvantitatívne vyjadrenie miery odlišnosti medzi kvantizovaným a nekvantizovaným modelom.

Ďalším významným výsledkom bol návrh a overenie novej tréningovej stratégie (Statistically-Monitored Training, SMT), ktorá integruje štatistické porovnávanie rozloženia váh do procesu učenia v podobe indexu podobnosti. Na základe vývoja indexu počas tréningovania bolo navrhnuté skoré zastavenie (early stopping), ktoré sa spravidla aktivovalo okolo siedmej až ôsmej epochy a umožnilo skrátiť tréningovanie bez výraznej straty presnosti. Výpočtová réžia priebežného vyhodnocovania indexu bola zanedbateľná (rádovo 0,24 % na epochu), vďaka čomu je navrhnutý prístup výpočtovo nenáročný.

Záverečnou časťou projektu bolo komplexné overenie navrhnutého konceptu na štandardných dátových sadách (MNIST, Fashion-MNIST, CIFAR-10, ImageNET). Pri nízkej bitovej hĺbke si kvantizované modely tréňované metódou zohľadňujúcou kvantizáciu (QAT) zachovali presnosť porovnateľnú s nekvantizovaným modelom v plnej presnosti (FP32), ktorý dosahoval približne 96 % až 97 %. Funkčnosť implementovaného riešenia bola overená aj reálnym exportom modelu do formátu int8 (TFLite). Index podobnosti vykazoval konzistentné monotónne správanie, keď s klesajúcou bitovou hĺbkou rástla hodnota Jensen-Shannon divergencie. Súčasne boli jasne vymedzené hranice použiteľnosti navrhnutého indexu pri extrémne nízkej bitovej hĺbke, keď pri kolapse modelu index nemusí spoľahlivo indikovať stratu kvality.

Projekt priniesol nové poznatky v oblasti monitorovania kvantizácie neurónových sietí pomocou štatistických metód. Z technického hľadiska bol vytvorený a overený index podobnosti založený na Jensen-Shannon divergencii a nová tréningová stratégia SMT, ktorá je výpočtovo nenáročná a využiteľná priamo v procese tréningovania kvantizovaných neurónových sietí. Z vedeckého hľadiska projekt prispel k lepšiemu pochopeniu vzťahu

medzi klesajúcou bitovou hĺbkou a mierou odlišnosti rozloženia váh kvantizovaného a nekvantizovaného modelu, pričom osobitný prínos predstavuje vymedzenie hraníc použiteľnosti navrhnutého indexu. Z aplikačného hľadiska môžu výsledky projektu slúžiť ako základ pre priebežné monitorovanie a riadenie procesu kvantizácie, vrátane skorého zastavenia tréovania a optimalizácie bitovej hĺbky pri nasadzovaní neurónových sietí na zariadeniach s obmedzenými výpočtovými zdrojmi.

ZÁVEREČNÉ ZHODNOTENIE PROJEKTU

Z komplexného pohľadu na celý priebeh projektu možno konštatovať, že riešenie napredovalo systematicky v súlade so štruktúrou pracovných balíkov (WP1 až WP4), z ktorých každý mal vymedzené čiastkové ciele, kontrolné míľniky a plánované výstupy. Jednotlivé etapy na seba logicky nadväzovali a postupne pokrývali celý zámer projektu, od úvodnej analytickej prípravy procesu kvantizácia a možnosti využitia štatistických metód pri procese kvantizácie (WP1), cez návrh navrhnutého konceptu (WP2) a jeho zapracovanie do tréningového procesu (WP3), až po záverečné overenie navrhnutého konceptu (WP4). Každý ďalší krok vychádzal z výsledkov predchádzajúceho a smeroval k naplneniu hlavného cieľa projektu ako celku.

V priebehu realizácie boli postupne dosiahnuté všetky stanovené ciele projektu a v príslušných kontrolných bodoch splnené všetky míľniky. Naplnenie cieľov a míľnikov tak nie je viazané na jedinú fázu, ale predstavuje súvislý a uzavretý celok zdokumentovaný kompletnou sadou výstupov projektu (D1 až D17). Tento súlad potvrdzuje, že projekt bol naplnený v celom rozsahu a so splnením všetkých cieľov, míľnikov a plnením parciálnych úloh vyplývajúcich z pracovných balíkov.

Rovnako boli naplnené aj jednotlivé vecné ciele projektu. V úvodnej časti bola analyzovaná samotná technika kvantizácie a následne boli preskúmané možnosti využitia štatistických metód a určené metódy vhodné na porovnanie rozdelenia váh kvantizovaného a nekvantizovaného modelu. Na tomto základe bol vymedzený koncepčný rámec porovnávacej analýzy nekvantizovaného a kvantizovaného modelu neurónovej siete s využitím štatistických metód. Navrhnutý bol štatistický prístup porovnávania rozdelenia váh vhodný pre hlboké učenie v súvislosti s procesom kvantizácie. Tento koncept bol napokon overený na štandardných dátových sadách. Všetky vecné ciele projektu tak boli splnené, čím možno realizáciu projektu považovať za úspešne ukončenú.

S navrhnutým riešením sa spája aj niekoľko aspektov, ktoré bližšie vymedzujú jeho rozsah a zároveň naznačujú priestor pre ďalší rozvoj, mimo záber projektu. Predstavený koncept (framework) je založený na ukazovateli (indexe podobnosti), ktorý monitoruje proces kvantizácie prostredníctvom štatistických metód uplatnených na váhy v modeli, a preto najspoľahlivejšie zachytáva práve tie zmeny, ktoré sa na nich prejavajú.

Ako vhodný a počas implementácie overený postup sa ukázalo previazať index podobnosti priamo s presnosťou modelu a sledovať ich spoločne, čím sa ich výpovedná hodnota vzájomne dopĺňa. Index tak prirodzene pôsobí ako doplnok k štandardným ukazovateľom kvality a rozširuje pohľad na správanie modelu. Keďže presnosť, je jedným z ukazovateľov degradácie modelu. Metóda zároveň ponúka parametre, ktoré ju umožňujú prispôbiť konkrétnym podmienkam, vďaka čomu sa dá pružne naladiť (tuning) pre rôzne typy modelov a úloh. Doterajšie overenie na reprezentatívnej množine modelov a dátových sád potvrdilo funkčnosť navrhnutého prístupu a zároveň otvára prirodzený priestor na jeho ďalšie rozširovanie.

skutočnosti predstavujú prirodzené vymedzenie súčasného rozsahu riešenia a vytyčujú smer nadväzujúcej práce.

Z obsahového hľadiska je výsledkom projektu navrhnutý prístup - index podobnosti - k sledovaniu kvality kvantizácie neurónových sietí (koncept, framework), ktorého hlavnými prínosmi sú nízka náročnosť a možnosť priameho začlenenia do priebehu riešenia bez drastického dopadu na jeho výkon (<1%), ako aj zachytávanie podstatných zmien v modeli (monitorovanie procesu kvantizácie).