

VÝSTUP D12- Report- PRACOVNÝ BALÍK WP3

Písomné zhrnutie výskumu

Identifikácia projektu:

Názov projektu: Štatistický prístup ku kvantizácii a monitorovaniu tréningu neurónových sietí

Akronym projektu: SAMQNN

Kód projektu: 09I03-03-V04-00562

Názov programu: Plán obnovy a odolnosti SR

Komponent: 9. Efektívnejšie riadenie a posilnenie financovania výskumu, vývoja a inovácií Plánu obnovy a odolnosti Slovenskej republiky

Investícia: 3. Excelentná veda

Schéma pomoci: Schéma štátnej pomoci na podporu výskumu, vývoja a inovácií v rámci komponentu 9 Plánu obnovy a odolnosti SR č. SA.106633

Začiatok realizácie projektu: 06/2024

Ukončenie vecnej realizácie: 05/2026

Hlavný riešiteľ: Ing. Roman Budjač, PhD.

1. Úvod

Kvantizácia patrí medzi najúčinnnejšie techniky kompresie neurónových sietí: prevod váh z 32-bitovej reprezentácie s pohyblivou rádovou čiarkou (FP32) na nižšiu bitovú presnosť (typicky 8 alebo 4 bity) zásadne znižuje pamäťovú aj výpočtovú náročnosť modelu, no nevyhnutne mení rozdelenie jeho váh a môže viesť k poklesu presnosti.

Predchádzajúci výstup D10 preukázal, že porovnávanie rozdelenia váh možno integrovať priamo do tréningu kvantizovaného modelu so zanedbateľnou réžiou a že štatistický index reaguje na závažnosť kvantizácie. Výstup D12 tieto zistenia implementuje do funkčnej tréningovej stratégie, pričom kladie dôraz na metodologickú správnosť kvantizácie.

Podstatným rozdielom oproti zjednodušeným implementáciám je, že stratégia nevyužíva iba simuláciu kvantizácie spojenú s tréningom v plnej presnosti — taký postup by viedol k tomu, že váhy by sa počas tréningu z kvantizačnej mriežky vrátili na ľubovoľné reálne hodnoty a výsledný model by v skutočnosti nebol kvantizovaný. Namiesto toho je implementovaný skutočný kvantizačne uvedomelý tréning, v ktorom dopredný priechod používa kvantizované váhy a spätný priechod využíva straight-through estimator; realnosť kvantizácie sa v notebooku aj numericky overuje.

2. Metodika


2.1 Štatistické jadro a index podobnosti

Množina váh sa reprezentuje ako diskrétné pravdepodobnostné rozdelenie získané histogramom nad spoločným rozsahom oboch porovnávaných množín. Jadro implementuje štyri metriky podobnosti rozdelení: Kullbackovu–Leiblerovu (KL) divergenciu, Jensenovu–Shannonovu (JS) divergenciu, kosínusovú podobnosť a Wassersteinovu (transportnú) vzdialenosť. KL a JS sa počítajú v bitoch (logaritmus o základe 2).

Index podobnosti je jediné skalárne číslo, ktoré v každom okamihu tréningu vyjadruje, nakoľko sa aktuálne rozdelenie váh kvantizovaného modelu líši od rozdelenia váh referenčného

modelu. Pre praktické rozhodovanie je kľúčová **JS divergencia**: je metrická a **ohraničená v** intervale $[0, 1]$, vďaka čomu sa dá stanoviť pevný prah, nad ktorým sa rozdelenie považuje za neprijateľne skreslené, a hodnoty sú priamo porovnateľné naprieč datasetmi.

Zásadné je, že význam indexu je kontextový. Pri post-tréningovej kvantizácii naprieč bitovými hĺbkami vyššia divergencia priamo zodpovedá väčšej degradácii (menej bitov $\rightarrow$ väčší odklon rozdelenia $\rightarrow$ nižšia presnosť). Počas kvantizačne uvedomelého dotrénovania však index typicky rastie spolu s presnosťou, pretože model sa adaptuje a jeho kvantizované váhy sa legitímne vzdávajú od pôvodnej FP referencie — v tomto režime index meria adaptáciu, nie degradáciu. Index sa preto vždy interpretuje spolu s presnosťou.



Obr. 1 — Vizuálne porovnanie rozdelenia váh pred kvantizáciou (FP32) a po nej (4 bity) po jednotlivých vrstvách. Spojité rozdelenie sa rozpadá na úzke „hroty“ zodpovedajúce $2^4 = 16$ kvantizačným úrovňam; práve túto zmenu tvaru kvantifikuje index podobnosti.

2.2 Skutočný kvantizačne uvedomelý tréning (QAT)

Pre tréningovú fázu nestačí post-tréningová kvantizácia: ak by sa model po kvantizácii jednoducho dotrénoval v plnej presnosti, jeho váhy by sa z mriežky vrátili na ľubovoľné reálne hodnoty a model by prestal byť kvantizovaný. Skutočný QAT to rieši tak, že **dopredný priechod používa kvantizované váhy** (sieť sa tak učí byť robustná voči kvantizácii), pričom **gradient sa prenáša cez straight-through estimator (STE)** — operácia zaokrúhľovania má v spätnom priechode jednotkový gradient, takže latentné (plnopresné) váhy sa dajú trénovať, hoci dopredu sa používa ich kvantizovaná podoba. Implementované sú vlastné kvantizované vrstvy QuantConv2D a QuantDense s kvantizáciou **per-channel** (samostatná škála pre každý výstupný kanál).

3. Implementácia stratégie

Jadrom výstupu je tréningová stratégia, ktorá integruje štatistický index do skutočného QAT a využíva ho na riadenie procesu. Stojí na troch komponentoch, ktoré sa spájajú do jednej procedúry:

- **Monitorovací callback** — po každej epoche extrahuje efektívne kvantizované váhy a počíta ich divergenciu voči zmrazenej FP referencii; zaznamenáva históriu indexu (KL/JS/kosínus) aj testovaciu presnosť a voliteľne ich vypisuje naživo počas tréningu.
- **Index-riadené včasné ukončenie** — ukončí tréning, keď sa index aj presnosť ustália (zmena oboch klesne pod prah počas zadaného počtu po sebe idúcich epoch), čím sa šetrí výpočet bez straty kvality.
- **Automatický výber bitovej hĺbky** — pomocou rýchlej post-tréningovej kvantizácie zvolí najnižšiu bitovú hĺbku, pri ktorej globálna JS divergencia neprekročí stanovený prah, t. j. najagresívnejšiu kompresiu zachovávajúcu prijateľnú vernosť rozdelenia.

Kompletná procedúra spája komponenty do postupnosti: (1) index-riadený výber bitovej hĺbky $\rightarrow$ (2) zostavenie QAT modelu inicializovaného z referenčného modelu $\rightarrow$ (3) skutočné QAT

s monitorovaním a index-riadeným včasným ukončením. Loader je dataset-agnostický a podporuje sklearn digits, Fashion-MNIST, MNIST aj CIFAR-10; správanie možno meniť konfiguračnými prepínačmi (napr. `CFG.run_cifar`, `CFG.run_imagenet`, `CFG.full_run`).

4. Experimentálne výsledky

4.1 Referenčné modely

Pre každý dataset bolo natrénovaných 5 nezávislých referenčných (FP32) modelov. Priemerná presnosť $\pm$ smerodajná odchýlka: digits $0,9667 \pm 0,0053$; Fashion-MNIST $0,9073 \pm 0,0041$; MNIST $0,9875 \pm 0,0014$; CIFAR-10 $0,6378 \pm 0,0079$.

4.2 Overenie reálnosti kvantizácie

Aby sa preukázalo, že nejde o pseudo-proces, po krátkom QAT (4 bity) bol spočítaný počet **distinktných hodnôt efektívnych váh na kanál**. Keďže kvantizácia je per-channel, správnym kritériom je počet distinktných hodnôt na kanál, ktorý nesmie presiahnuť $2^b = 16$ — bez ohľadu na počet epoch. Namerané maximá (conv1: 9, conv2: 15, dense1: 15, out: 14) kritérium spĺňajú, čím je reálnosť kvantizácie potvrdená. Pre porovnanie, post-tréningová kvantizácia samotného referenčného modelu dáva pri 8 bitoch globálnu JS = 0,0002 (presnosť nezmenená) a pri 4 bitoch JS = 0,0967.

4.3 Stratégia vs. naivný baseline

Stratégia (SMT: automatický výber bitovej hĺbky + monitoring + index-riadený early-stop) bola porovnaná s naivným baseline (fixná 8-bitová QAT na rovnaký strop epoch, bez monitoringu a bez auto-výberu). Pri kandidátoch 4/6/8/16 bitov stratégia prirodzene volí ≈ 6 bitov (index hlboko pod prahom, presnosť zachovaná) — analyticky najúspornejšiu bezstratovú voľbu s kompresiou $5,33\times$ oproti $4,0\times$ pri 8-bit baseline:


Dataset	FP32	SMT bity	SMT epochy	SMT presn.	SMT kompr.	8-bit epochy	8-bit presn.	8-bit kompr.
digits	0,9750	6	4	0,9722	$5,33\times$	30	0,9778	$4,0\times$
fashion_mnist	0,9091	6	4	0,9114	$5,33\times$	30	0,9021	$4,0\times$
mnist	0,9859	6	30	0,9906	$5,33\times$	30	0,9924	$4,0\times$
cifar10	0,6402	6	5	0,6494	$5,33\times$	30	0,6295	$4,0\times$

Tab. 1 — Porovnanie stratégie (SMT, ≈ 6 -bit) s fixným 8-bitovým baseline. SMT dosahuje porovnateľnú presnosť pri vyššej kompresii, na viacerých datasetoch s výrazne menším počtom epoch vďaka včasnému ukončeniu (napr. digits 4 vs 30 epoch).

Poznámka k nasadeniu: hoci 6 bitov je analyticky najúspornejšia voľba, pre nasadenie ostáva relevantný aj **8-bit (INT8)** — celočíselný hardvér a behové prostredia (mobilné a hranové NPU, INT8 akcelerátory, TFLite/ONNX) podporujú 8 bitov natívne, kým 6 bitov nie.

4.4 Citlivosť na bitovú hĺbku

Pre každý referenčný model bola meraná okamžitá po-quantizačná (PTQ) presnosť a globálna JS divergencia naprieč rozsahom bitových hĺbok. Vzťah **bitová hĺbka** $\rightarrow$ **divergencia** je takmer dokonale monotónny: Spearmanov korelačný koeficient $\rho = -0,984$ ($p = 7,5 \times 10^{-19}$) pre všetky datasety — index teda spoľahlivo sleduje závažnosť kvantizácie. Pre vzťah **divergencia** $\rightarrow$ **presnosť** (zlúčené dáta, $N = 100$) vychádza $\rho = -0,452$ ($p = 2,3 \times 10^{-6}$) a divergencia $\rightarrow$ strata $\rho = 0,403$.



Obr. 2 — Presnosť (vľavo) a globálna JS divergencia (vpravo) ako funkcia bitovej hĺbky pre štyri datasety. Pri vysokých bitových hĺbkach je index blízko nuly a presnosť prakticky nezmenená; pod istou hranicou index výrazne stúpnne a nasleduje strmý pokles presnosti.

4.5 Dynamika QAT a výpočtová réžia


Počas skutočného QAT (4 bity) bol sledovaný vývoj indexu a presnosti po epochách. Keďže sa index počíta z efektívnych kvantizovaných váh, zachytáva reálnu adaptáciu modelu. Réžia monitorovania bola rozložená, aby sa izolovala cena samotného výpočtu divergencie: **samotný výpočet divergencie pridáva iba +2,4 %** k času tréningu; nákladnou zložkou je až voliteľné vyhodnocovanie presnosti po každej epoche (+52 %), ktoré sa v produkčnom režime dá vynechať.

4.6 Škálovanie na ImageNet-V2

Generalizácia na veľké modely bola realizovaná ako post-tréningová kvantizácia viacerých predtrénovaných architektur (MobileNetV2, ResNet50) na validačnej podmnožine ImageNet-V2 (~2 560 obrázkov). Zámerne bola zmiešaná architektúra citlivá na kvantizáciu (MobileNetV2) s robustnejšou (ResNet50). Pri 8 bitoch ostáva presnosť prakticky zachovaná (MobileNetV2 top-1 0,5193 vs FP32 0,5732; ResNet50 0,5617 vs 0,5631). Pri 4 bitoch je ResNet50 stále použiteľný (top-1 0,3646), kým MobileNetV2 sa zrúti (top-1 0,0018) — viď diskusiu k obmedzeniam globálneho indexu nižšie.

4.7 Zhodnotenie naprieč datasetmi

Naprieč všetkými datasetmi — od malých modelov až po veľký predtrénovaný model na ImageNete — sa prejavuje tá istá zákonitosť: index monotónne rastie so znižovaním bitovej hĺbky, pri vysokých bitových hĺbkach je blízko nuly a presnosť nezmenená, a pod istou hranicou výrazne stúpnne, pričom strmý pokles presnosti nasleduje až pri ešte nižších bitoch. Index sa tak správa ako dataset-agnostický včasný indikátor zhoršenia — to je hlavný praktický prínos stratégie.



Obr. 3 — Index podobnosti (vľavo) a relatívny pokles top-1 presnosti (vpravo) ako funkcia bitovej hĺbky naprieč všetkými datasetmi. Keďže JS je ohraničená na $[0, 1]$, hodnoty sú medzi datasetmi priamo porovnateľné.

Hodnoty pri najnižšej testovanej bitovej hĺbke:

Dataset (bit. hĺbka)	Index JS	Pokles top-1
digits (2 bity)	0,748	41,0 %
fashion_mnist (2 bity)	0,573	79,3 %
mnist (2 bity)	0,713	51,9 %
cifar10 (2 bity)	0,495	81,9 %
imagenet – MobileNetV2 (4 bity)	0,000	99,7 %
imagenet – ResNet50 (4 bity)	0,011	35,2 %

Tab. 2 — Index a pokles presnosti pri najnižšej testovanej bitovej hĺbke. Pozoruhodný je riadok MobileNetV2 (4 bity): globálna JS ostáva blízko nuly, hoci presnosť sa zrúti — tomuto prípadu sa venuje diskusia.

5. Diskusia a obmedzenia

Hlavným zistením je, že globálna JS divergencia rozdelenia váh funguje ako **dataset-agnostický včasný indikátor degradácie**: monotónny vzťah s bitovou hĺbkou ($\rho \approx -0,98$), takmer nulová hodnota pri zachovanej presnosti a prahový nárast predchádzajúci strmému poklesu presnosti umožňujú spoľahlivo voliť kompresiu a riadiť tréning.

Dôležité obmedzenie je viditeľné na architektúre MobileNetV2 pri 4 bitoch: globálna JS rozdelenia váh ostáva blízko nuly, no top-1 presnosť sa zrúti (pokles $\sim 99,7$ %). Globálny index rozdelenia váh je teda **nutnou, nie však postačujúcou** podmienkou zachovania presnosti — pri architektúrach citlivých na kvantizáciu (oddeliteľné konvolúcie, BatchNorm) môže byť degradácia sústredená v citlivých vrstvách alebo v rozdelení aktivácií, ktoré globálny index váh nezachytí. Index sa preto vždy interpretuje spolu s presnosťou a pre takéto prípady je potrebná per-layer a aktivačná analýza (WP4).

Druhým obmedzením je **spoľahlivosť včasného ukončenia**: spúšťa sa spoľahlivo len tam, kde sa index počas tréningu ustáli v rámci rozpočtu epoch (digits, MNIST); na iných datasetoch (Fashion-MNIST) sa nemusí spustiť. Odporúča sa preto používať ho spolu so stropom epoch a kontrolou presnosti, nie samostatne.

6. Záver a naplnenie výstupu

Bola implementovaná a experimentálne preukázaná nová tréningová stratégia kvantizovaných sietí, ktorá integruje štatistický index rozdelenia váh priamo do skutočného

kvantizačne uvedomelého tréningu a využíva ho na riadenie procesu. Numericky bolo overené, že efektívne váhy zostávajú počas celého tréningu reálne kvantizované (najviac 2^b distinktných hodnôt na kanál). Stratégia poskytuje dve akčné rozhodnutia — index-riadené včasné ukončenie (preukázateľná úspora epoch pri zachovaní presnosti) a automatický výber bitovej hĺbky podľa prahu divergencie — pri zanedbateľnej réžii samotného výpočtu indexu (+2,4 %).

Naplnenie výstupu D12. Výstup napĺňa svoju definíciu — implementáciu novej tréningovej stratégie neurónovej siete založenej na štatistickej metóde — funkčnou, metodologicky korektnou (skutočné QAT), konfigurovateľnou a dataset-agnostickou stratégiou s experimentálnym preukázaním naprieč viacerými inicializáciami a datasetmi. Všetky merané výsledky (úplná bitová analýza, vývoj počas QAT, per-layer citlivosť, súhrny a ImageNet) sa exportujú do CSV súborov, takže testovanie je auditovateľné a reprodukovateľné. Celkový čas behu referenčného experimentu bol ~4 720 s.

- .